

从上下文到技能：语言模型能否巧妙地从中学学习？

舒正思^{*♠◇}, 赵浩哲^{*♣}, 雷宇^{*◇}, 王清怡^{*★}, 陈定纬[▽], 王志桐[♠], 王振海龙[♣], 罗康阳[♠], 王峰[♣], 陈刚[◇], 齐凡超[◇], 张敏佳[♣], 孙茂松^{♠♣}清华大学 ◇深度浪人工智能 ♣伊利诺伊大学厄巴纳-香槟分校 ★复旦大学 ▽香港中文大学 § S1s-Z/Ctx2Skill *同等贡献。

摘要

许多现实世界任务要求语言模型 (LMs) 能够推理超出其参数知识范围的复杂上下文。这需要 *context learning*, 即语言模型直接从给定上下文中学习相关知识。一种直观的解决方案是推理时技能增强: 从 *context* 中提取相应规则和流程, 形成明确、自然语言的 *skills*。然而, 为上下文学习场景构建此类技能面临两个根本性挑战: 对技术密集的长上下文进行手动技能标注的成本过高, 以及自动化技能构建缺乏外部反馈。本文提出 *Ctx2Skill*, 这是一种自我演进的框架, 无需人工监督或外部反馈即可自主发现、优化并选择特定于上下文的技能。其核心是一个多智能体自我博弈循环: 包含生成探测任务及评分标准的 *Challenger*, 尝试在演进技能集指导下解决问题的 *Reasoner*, 以及提供二元反馈的中立 *Judge*。关键在于 *Challenger* 和 *Reasoner* 都通过积累的自然语言技能实现进化——专用的 *Proposer* 和 *Generator* 智能体会分析失败案例, 并将其转化为针对双方的定向技能更新, 从而实现自动化技能发现与优化。为防止因任务生成日益极端和技能过度专业化导致的对抗性崩溃, 我们进一步引入 *Cross-time Replay* 机制, 该机制能识别在 *Reasoner* 方代表性案例上达到最佳平衡的技能集, 确保技能演进具有鲁棒性和可泛化性。最终生成的技能可嵌入任何语言模型, 以提升上下文学习能力。在 CL-bench 的四个上下文学习任务上评估表明, *Ctx2Skill* 持续提升不同骨干模型的解决率, 例如将 GPT-4.1 从 11.1% 提升至 16.5%, GPT-5.1 从 21.2% 提升至 25.8%。

1 引言

当前的语言模型 (LMs) 在那些相关知识已在大规模预训练中出现过的问题上表现卓越[5,27,39], 例如竞赛级别的数学问题[14]和竞争性编程挑战[17]。然而, 许多现实世界的任务要求 LMs 从复杂上下文中学习, 并利用新知识而非参数化知识来进行有效推理与解决[26,36,47]。先前的研究将这种能力称为 *context learning*[12]。有效的上下文学习使模型能够超越其预训练知识的限制, 通过直接从丰富的上下文信息中学习来解决复杂的、特定领域的任务, 正如人类所做的那样。例如, 它使得 LMs 能够快速利用之前未见过的产品文档, 生成逐步操作流程或排查问题。

尽管情境学习在解决现实世界任务中扮演着核心角色, 但当前研究却很大程度上忽视了一点[16]。一个关键障碍在于现实世界情境的多样性: 情境知识可以通过书籍、实验数据和搜索结果等多种方式传递, 这使得情境

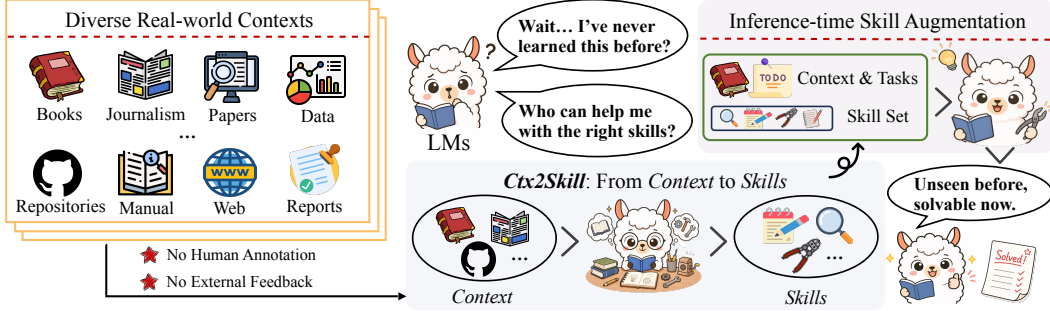


图1: *Ctx2Skill*的示意图。其设计目的是无需人工标注和外部反馈，从context中提取规则和程序转化为自然语言skills。

学习从根本上具有挑战性。一个直观的范式是推理时技能增强[3]，即从context中提取规则和流程到自然语言skills，这些语言编码了可供语言模型复用的程序性知识。该方法已在许多智能体任务中证明有效[42, 49, 37]，例如编码智能体[24]。然而，该范式在上下文学习场景下面临两个根本性挑战：具体而言，**Prohibitive Cost for Manual Skill Annotation**：现有智能体技能库主要依赖人工标注构建[18, 20, 41]。但在上下文学习场景中，这种范式会失效——学习上下文通常篇幅冗长、技术密集且领域专深。要策划高质量技能，标注者需完全内化包含多章节的复杂文档，这一过程既对认知能力要求极高，又在经济上不可行，使得人工策划的技能构建难以规模化。(2) **Lack of External Feedback for**

Automated Skill Construction：与可验证的任务（如编程或数学推理[7, 31]）不同——这些任务可通过执行反馈或标准答案比对来评估技能质量——上下文学习任务缺乏自动反馈机制，无法判断提取的技能是否准确完整地捕捉了上下文特定知识。仅给定上下文时，没有外部反馈信号能说明生成的技能是否有用，或是否遗漏了关键知识。这种无反馈特性使得自动化技能构建流程无法适用[1, 44, 46]。Together,

these challenges highlight the need for an automated framework that discovers skills from the context without relying on either human annotation or external feedback signals.

本文提出了一种如图1所示的*Ctx2Skill*方法，其通过技能优化的自我博弈机制，无需人工标注或外部反馈，即可直接从复杂语境中自主发现、精炼并选择技能。*Ctx2Skill*的核心在于多智能体自我博弈循环[10, 22, 48, 21]，该循环包含两个相互竞争又协同进化的角色：

Challenger智能体根据语境及其技能库生成任务批量和关联评分标准[15]，旨在探究深层次语境理解；而**Reasoner**智能体则读取语境并尝试运用现有技能解决这些任务。*Ctx2Skill*的核心思想在于双方通过迭代更新各自的技能库（而非模型参数）实现协同进化。具体而言，中立的**Judge**智能体会依据评分标准评估**Reasoner**的响应，生成是否通过的反馈信号。关键在于，**Challenger**和**Reasoner**都通过积累自然语言技能实现进化：失败案例会被导向**Reasoner**端的专用**Proposer**和**Generator**智能体，用于诊断缺失的语境知识并相应更新技能；而易解决的案例则被导向**Challenger**端以强化其任务及评分标准生成策略，从而维持持续的对抗压力。更新后的技能将带入下一轮迭代，使双方能通过失败驱动的文本文本反馈持续协同进化，全程无需参数更新。此外，我们发现该多智能体自我博弈循环存在*adversarial collapse*现象这一关键风险：随着迭代进行，**Challenger**可能生成日益极端的任务，而**Reasoner**的技能会过度特化于这些病态案例，导致冗余技能积累并损害泛化能力。为此，我们进一步提出*Cross-time Replay*机制，选择在代表性案例上表现最均衡的技能库，确保技能进化具备鲁棒性和泛化性。在推理阶段，最终获得的语境特异性**Reasoner**技能可嵌入任意语言模型，增强其在相同语境下（包括自我博弈循环中未见的任务）处理任意任务的语境学习能力。

我们在CL-Bench[12]的四个上下文学习任务上评估了我们的*Ctx2Skill*，包括领域知识推理、规则系统应用、程序性任务执行以及经验发现与模拟。*Ctx2Skill*在所有四个类别中持续提升了解决率，并

多骨干模型：它将GPT-4.1 [29]从11.1%提升至16.5%，GPT-5.1 [27]从21.2%提升至25.8%，GPT-5.2 [27]从18.2%提升至21.4%，证明自主发现的上下文特定技能带来了显著且可推广的收益。

2 相关工作

上下文学习。当前的语言模型在预训练阶段已涵盖相关知识的任务上表现卓越[9, 27, 33, 34]。然而，现实中的许多任务要求模型能够从复杂上下文中学习，并利用新知识进行有效推理，这种能力被称为*context learning*[12]。这种上下文学习能力在实践中至关重要：医生参考最新发布的临床指南调整治疗方案，工程师查阅文档执行操作流程，研究者从实验数据中归纳规律以形成假设。但先前研究发现，语言模型尚未掌握这一能力[12]。核心难点在于，上下文知识涵盖书籍到实验数据集等多种形式，且相关规则与流程常隐含其中，需要深度理解而非浅层检索。*Ctx2Skill*直接针对这一挑战，通过自主发现上下文中可复用的情境特定技能，赋能任何语言模型，使其能更好地从复杂上下文中学习并进行推理。

大语言模型（LMs）的技能体系。技能是以自然语言模块形式编码的可复用程序性知识，用于在推理阶段增强大语言模型[2,3]，技能增强方法已在编码[24]、网页导航[42]等智能体任务中获广泛验证[32]。早期技能库主要依赖人工标注构建[18,19,20,41]，虽然有效但扩展性不足，尤其面对技术密集、领域特定且上下文冗长的情境学习场景。近期研究转向自动化技能构建：AutoSkill[44]从交互轨迹提取终身版本化的可复用行为，AutoRefine[30]将智能体轨迹转化为可复用专业知识；CoEvoSkills[45]通过生成器-验证器协同进化生成多文件技能包并优化，EvoSkill[1]采用失败驱动优化形成结构化技能文件夹；SkillX[40]将智能体轨迹提炼为分层技能知识库，通过执行反馈迭代优化。但现有方法依赖执行反馈、真值比对或任务完成奖励等外部反馈信号[25]来评估改进技能质量，这在无自动反馈的情境学习场景中不可行。另一类研究尝试将技能内化至模型参数：SKILL0[23]采用上下文强化学习吸收技能，SkillRL[43]通过教师轨迹的强化学习引导蒸馏构建分层技能库。这些方法需访问模型参数，无法应用于闭源模型，且牺牲了自然语言技能文档的可解释性。本文提出{v*}自进化框架，仅从复杂上下文直接发现并进化技能，无需人工标注、外部反馈或参数更新。

3 方法论

3.1 概述

上下文学习任务[12]要求语言模型能够利用来自冗长且技术密集的上下文中的知识进行推理并有效解决问题。这类任务的一个直观范式是推理时技能增强，即从*context*中提取相应规则与流程，转化为自然语言形式的*skills*。但要将这一理念转化为可行框架面临两大难点：(1) 人工技能标注成本过高；(2) 自动化技能构建缺乏外部反馈。本文提出的*Ctx2Skill*（如图2所示）是一个自进化框架，可在无人监督或外部反馈的情况下自主发现、优化并筛选上下文特定技能。其核心是一个*skill-optimized self-play*循环（§3.3），该循环协同进化两个竞争方：*Challenger*根据自身技能库中的任务和评分标准探测上下文，*Reasoner*基于当前技能库解决问题，中立的*Judge*则返回二元裁决，将每个结果路由至对应方的*Proposer-Generator*诊断模块——该模块分析暴露的缺陷并相应调整该方技能，从而实现双方在无需人工标注或外部反馈情况下的协同进化。此外，这种自我博弈框架存在*adversarial collapse*风险：*Challenger*可能生成日益极端的任务，而*Reasoner*的技能会过度特化于这些病理案例，导致冗余技能积累进而削弱泛化能力。为此，我们进一步提出*Cross-Time Replay*机制（§3.4）来筛选技能集




图2: *Ctx2Skill*的概览。(a) 在自我对弈循环中, *Challenger*生成任务与评分标准, *Reasoner*尝试解决这些任务, *Judge*则将结果路由以更新*Challenger*和*Reasoner*的技能。(b) 跨时间回放机制会重新评估历史*Reasoner*技能候选在代表性任务上的表现, 从而为未见过的下游任务选择最均衡的技能组合。

这样就能在代表性案例中最佳平衡性能, 确保技能演化既稳健又具备普适性。通过这种方式, $\{v^*\}$ 自主构建了可适配具体场景的技能模块, 这些模块能在推理时直接嵌入任何语言模型, 无需参数更新即可增强上下文学习能力。

3.2 问题表述

一个上下文学习任务[12]由以下部分组成: 给定的上下文 C , 其内容可能超出语言模型的预训练语料库; 一组任务 $\mathcal{T} = \{t_j\}$, 其正确答案依赖于 C ; 以及一组二元评分标准 $\mathcal{R}_j = \{r_{j,k}\}$ 。给定由语言模型 π 生成的答案 a_j , 只有当每个评分标准均通过时, 该任务才被视为解决, 我们为此定义了一个解决指示器 $y_j(\pi)$; 对于任务 t_j , 其表示为 C):

$$y_j(\pi; C) = \prod_k \mathbb{I}[r_{j,k}(a_j) = \text{pass}], \quad a_j \sim \pi(\cdot | C, t_j). \quad (1)$$

我们的目标是让语言模型 π 能够在无需参数更新或外部反馈的情况下, 解决基于未见上下文 C 的任务。为此, 我们引入了一种自然语言 *skill set* $\mathcal{S}$ ——一个简短的Markdown文件, 在推理时预置到语言模型的系统提示中:

$$a_j \sim \pi(\cdot | \mathcal{S}, C, t_j). \quad (2)$$

在我们提出的*Ctx2Skill*技能构建过程中, $\mathcal{S}$ 被实例化为两个独立的技能集: *Reasoner*代理使用 $\mathcal{S}^R$, *Challenger*代理使用 $\mathcal{S}^C$ 。在推理阶段, 仅部署*Reasoner*的技能集 $\mathcal{S}^R$, 并结合语言模型进行上下文特定任务的评估。

3.3 *Ctx2Skill* 框架

为未知情境构建技能集 $\mathcal{C}$ 面临两大障碍: 人工标注不仅读取 C 并记录其情境知识的成本高昂, 而且缺乏外部反馈信号来判断所提出的技能是否忠实且对 C 有用。为解决这两个问题, *Ctx2Skill*运行了一个多智能体自博弈循环, 仅从情境 C 中自主发现并优化特定情境的技能。

*Ctx2Skill*的核心思想是通过 N 次失败驱动的文本文编辑, 共同进化两个技能集: $\mathcal{S}^R$ 用于*Reasoner*, $\mathcal{S}^C$ 用于*Challenger*, 使得*Reasoner*逐步积累上下文 C 的知识, 而*Challenger*持续探查尚未掌握的方面。五个冻结-LM代理角色执行这一自我对弈循环。在第 i 次迭代时, 给定上下文 C 和技能集 $\mathcal{S}_{i-1}^C$, *Challenger*生成一批带有相应评分标准的任务; *Reasoner*在上下文 C 和其技能 $\mathcal{S}_{i-1}^R$ 的指导下尝试每项任务; 中立的*Judge*返回每项任务的二元判定, 并将任务批次划分为失败和解决两组。每组随后通过*Proposer-Generator*对路由至对应侧: 失败案例流向*Reasoner*侧, 其中*Proposer*诊断缺失的上下文知识, 而*Generator*更新 $\mathcal{S}^R$

相应地；已解决的案例流向 $Challenger$ 侧，在此处对应的配对会收紧 S^C ，以确保下一次迭代维持对抗压力。更新后的 S_i^R 和 S_i^C 将被带入迭代 $i+1$ 中，且绝不会基于对手方的技能集来设定提示，从而严格保持双方的对抗性。现在，我们在此次迭代 i 中定义以下五个代理角色：

- **Challenger**在给定上下文 C 及其当前技能集 S_{i-1}^C 的情况下， $Challenger$ 生成了一批 M 任务 $\{t_m\}_{m=1}^M$ ，每个任务均配有相应评分标准 $\mathcal{R}_m$ 。这些评分标准的设计旨在要求正确答案需推导出 C 的规则，而非对表面片段进行改述。通过基于其技能 S_{i-1}^C 进行条件设定， $Challenger$ 在迭代过程中调整其探测策略，以在 $Reasoner$ 提升时持续施加对抗性压力。
- **Reasoner**给定 C 、任务 t_m 及其当前技能集 S_{i-1}^R ， $Reasoner$ 会生成答案 a_m 。虽然原始上下文 C 包含所有必要的知识，但其通常冗长且技术密集；技能集 S_{i-1}^R 从 C 中提炼出最相关的规则和流程，形成简洁、结构化的形式，使得 $Reasoner$ 能够直接应用上下文知识，而无需在每次任务时从头提取。
- **Judge**给定一个任务及由 $Challenger$ 生成的评分标准，以及由 $Reasoner$ 生成的答案， $Judge$ 会返回针对每条标准的二元判定结果 $z_{m,k} = \mathbb{I}[r_{m,k}(a_m) = \text{通过}]$ 及一个解决指标 $y_m = \prod_k z_{m,k}$ 。 $Judge$ 是一个严格的评估器：仅当答案满足所有相关评分标准时，任务才被视为解决。
- **Proposer (one per side)** $Judge$ 的二进制判定结果标识出 $which$ 任务失败或成功，但非 why 。因此， $Proposer$ 会收集其方向所有已路由案例，每个案例包含来自 $Challenger$ 的任务和评分标准，以及 $Reasoner$ 的答案，并将它们与当前技能集联合分析。不同于孤立诊断每个案例， $Proposer$ 会将跨案例的常见失败或成功模式综合成高层诊断，明确指定操作（添加或合并）、目标技能名称、描述及理由。**Reasoner Proposer**的设计旨在结合失败案例 $\mathcal{F}_i$ 与 S_{i-1}^R ，通过检查错误答案及违反的评分标准，诊断出缺失或被误解的情境知识。另一方面，**Challenger Proposer**则利用轻松解决的案例 $\mathcal{P}_i$ 与 S_{i-1}^C ，通过观察 $Reasoner$ 如何运用现有技能解决问题，来识别当前任务和评分标准生成策略中的不足。
- **Generator (one per side)** $Proposer$ 的输出是一份高层次诊断，描述了需要改变的内容及原因，但并未涉及具体的技能内容本身。**Generator**将这一诊断具体化为实际的技能组合。根据诊断和当前技能组合，它会返回一个完整的替换技能集，在保留所有无关条目的同时添加或合并条目。**Reasoner Generator**将诊断出的缺失背景知识融入 S_{i-1}^R ，从而生成新的技能组合 S_i^R 。**Challenger Generator**收紧 S_{i-1}^C ，使得下一次迭代能够探查 $Reasoner$ 的剩余弱点，进而产出技能 S_i^C 。

总结来说，在迭代 i 中， $Challenger$ 首先根据上下文 C 生成一批任务和评分标准 $\{(t_m, \mathcal{R}_m)\}_{m=1}^M$ ； $Reasoner$ 尝试回答每个 t_m ； $Judge$ 评估每条标准，并根据解决指标 y_m 将批次划分为失败案例 $\mathcal{F}_i = \{m: y_m = 0\}$ 和已解决案例 $\mathcal{P}_i = \{m: y_m = 1\}$ 。随后，每组被导向其对应的处理路径：

- **Reasoner Proposer**综合分析所有针对 S_{i-1}^R 的失败案例 $\mathcal{F}_i$ ，并合成一个高层次诊断；随后**Reasoner Generator**将其具体化为 S_i^R 。
- **Challenger Proposer**综合分析所有已解决的案例 $\mathcal{P}_i$ 与 S_{i-1}^C ，并综合出一个高层诊断；随后**Challenger Generator**将其具体化为 S_i^C 。

更新后的技能集 S_i^R 和 S_i^C 被延续至迭代 $i+1$ 中。任何提示均不以对方的技能集为条件，确保双方严格保持对抗关系。

3.4 Cross-Time Replay 机制

在§3.3节详述的 $Ctx2Skill$ 框架中，通过更新 S^C 有意强化了迭代间的 $Challenger$ ，随着 $Reasoner$ 的提升持续施加对抗压力。然而，该设计引入了一种我们称为 $adversarial collapse$ 的内在张力。随着迭代推进， $Challenger$ 生成的对抗任务愈发极端，聚焦于 $Reasoner$ 残留的薄弱环节。

nesses, 逐渐偏离了上下文 C 的代表性知识。由于 $Reasoner$ 的技能更新是失败驱动的, 其技能会过度特化于这些病态案例, 导致冗余技能积累, 进而削弱泛化能力。此外, 这种崩溃在循环中无法被察觉: 每次迭代的 $Judge$ 仅评估 $Challenger$ 新生成的任务, 无法提供关于早期迭代中掌握的上下文知识是否被后续编辑破坏的信号。因此, 无条件返回最后一次迭代 $Reasoner$ 的技能 S_N^R 是不可靠的; 我们转而从候选 $\{S_1^R, \dots, S_N^R\}$ 中选择最具泛化性的技能集。

为此, 我们提出一种 $cross\text{-}time\ replay$ 机制, 通过从候选技能集 $\{S_1^R, \dots, S_N^R\}$ 中选取最具泛化能力的技能组合, 利用自我对弈过程中收集的代表性探针任务进行筛选。无需任何外部监督, 我们逐步构建了两个小型探针集: 在每次迭代 i 时, 将评分通过率最低的失败任务加入困难探针集 Q^h , 同时将满足评分项最少的已解决任务加入简单探针集 Q^e , 以此捕捉每轮迭代中观察到的最艰难失败与最简易成功。当自我对弈循环结束时, $Reasoner\ \pi^R$ 会在每个候选技能集 S_i^R 下重新解答两个探针集中的所有任务, 随后 $Judge$ 重新评估每个评分项, 生成每个探针任务 q 的解决指标 y_q (即是否通过全部评分项)。我们分别定义拉普拉斯平滑后的[13]解决率 $\rho^h(i)$ 和 $\rho^e(i)$, 表示在上下文 C 和技能 S_i^R 条件下, 困难探针集与简单探针集中被成功解决的任务比例:

$$\rho^h(i) = \frac{\sum_{q \in Q^h} y_q(\pi^R; C, S_i^R) + 1}{|Q^h| + 1}, \quad \rho^e(i) = \frac{\sum_{q \in Q^e} y_q(\pi^R; C, S_i^R) + 1}{|Q^e| + 1}. \quad (3)$$

所选技能组合是使这两个解决率的乘积最大化的那个:

$$S_\star^R = S_{i^\star}^R, \quad i^\star = \arg \max_i (\rho^h(i) \cdot \rho^e(i)). \quad (4)$$

乘积形式至关重要: 一个技能组合若以在简单任务上退步为代价来解决后期特殊故障, 就会在 $\rho^e(i)$ 上受到惩罚并被拒绝; 反之, 若一个组合能解决所有简单探测任务却在每一个困难任务上失败, 则会通过 $\rho^h(i)$ 被拒绝。与此同时, 拉普拉斯平滑确保了当某次迭代中探测集为空时, 乘积仍能良好定义。

在推理阶段, 最终的技能集合 $S_\star^R$ 会被预先添加到 $Reasoner$ 的系统提示中, 针对上下文 C 下的任何未见任务 t_u , 而 $Reasoner$ 则基于 $(S_\star^R, C, t_u)$ 生成回答。由于 $S_\star^R$ 编码的是 C 的可重用上下文知识, 而非特定任务的解决方案, 因此它能泛化到相同上下文下的任意任务。此外, 每个上下文只需生成一次 $S_\star^R$, 便可在所有 $|T|$ 未见任务中重复使用, 这使得 $Ctx2Skill$ 的成本分摊到 $|T|$ 上, 每个部署查询无需额外开销。

4 实验

在本节中, 我们通过实验和分析来展示我们 $Ctx2Skill$ 的优势。

4.1 设置

评估。上下文学习是一个新兴的研究课题, 旨在要求语言模型从未见过的上下文中学习, 并利用超出预训练阶段所获知识的新内容进行推理和解决任务[12]。这远超越了主要测试检索或阅读理解能力的长上下文任务[6,35], 也不同于通过指令和演示让模型学习简单任务模式的上下文学习任务[11]。我们选用CL-bench[12]作为评估基准, 该数据集包含500个复杂上下文、1,899项任务及31,607条验证细则, 均由资深领域专家精心设计。每项任务的设计确保其解决所需的新内容均包含在对应上下文中。数据分为四大类别:

Domain Knowledge Reasoning、*Rule System Application*、*Procedural Task Execution*和*Empirical Discovery & Simulation*。评分采用严格的全有或全无机制: 仅当所有细则均通过时, 任务才被视为解决。我们汇报分项及整体解决率。细则级评分遵循原始基准协议, 采用GPT-5.1作为LLM-as-a-judge验证器[50]; 其他验证器及人类评估者与该验证器的一致性均超过90%[12]。

基线模型。我们首先评估了一系列前沿语言模型, 包括GPT-4.1[29]、GPT-5.1[27]、GPT-5.2[28]、Claude Opus 4.5[4]、Gemini 3 Pro[8]、Kimi K2.5[38]以及DeepSeek V3.2[9]。对于支持思考模式的模型, 我们采用默认推理强度。针对基于技能的方法, 我们

表1: *Ctx2Skill*的主要结果。我们报告了CL-bench上四大任务类别的任务解决率。同一骨干网络下的最佳结果以粗体标出。v表示采用推理时增强的方法，u展示未使用技能时的推理结果。红色与绿色分别表示相对于未使用技能的模型所获得的性能提升与下降。

Model	Overall (%)	Domain Knowledge Reasoning (%)	Rule System Application (%)	Procedural Task Execution (%)	Empirical Discovery & Simulation (%)
Frontier LMs					
🕒 GPT-5.1	21.1	22.4	21.0	22.8	13.6
🕒 Claude Opus 4.5	21.0	23.7	19.0	22.6	15.1
🕒 Kimi K2.5	19.2	19.1	19.4	21.3	14.4
🕒 GPT-5.2	18.2	19.5	18.0	19.1	12.1
🕒 Gemini 3 Pro	15.8	15.5	17.7	16.4	10.1
🕒 DeepSeek V3.2 Thinking	13.2	13.6	13.8	14.2	8.0
🕒 GPT-4.1	11.1	10.6	14.8	10.4	4.6
GPT-4.1-based Methods					
🕒 Prompting	12.3 +1.2	12.4 +1.8	12.3 -2.5	13.9 +3.5	8.2 +3.6
🕒 AutoSkill4Doc	13.2 +2.1	13.3 +2.7	13.1 -1.7	15.0 +4.6	8.7 +4.1
🕒 <i>Ctx2Skill</i>	16.5 +5.4	16.8 +6.2	17.6 +2.8	17.6 +7.2	9.7 +5.1
GPT-5.1-based Methods					
🕒 Prompting	22.1 +1.0	24.7 +2.3	21.1 +0.1	22.4 -0.4	15.5 +1.9
🕒 AutoSkill4Doc	22.7 +1.6	25.3 +2.9	21.5 +0.5	23.1 +0.3	16.0 +2.4
🕒 <i>Ctx2Skill</i>	25.8 +4.7	27.9 +5.5	24.9 +3.9	26.9 +4.1	19.1 +5.5
GPT-5.2-based Methods					
🕒 Prompting	19.1 +0.9	19.6 +0.1	18.3 +0.3	22.6 +3.5	11.1 -1.0
🕒 AutoSkill4Doc	19.7 +1.5	20.5 +1.0	18.8 +0.8	23.0 +3.9	11.6 -0.5
🕒 <i>Ctx2Skill</i>	21.4 +3.2	22.2 +2.7	20.4 +2.4	25.4 +6.3	12.6 +0.5

将*Ctx2Skill*与两个基线进行比较：(1) *Prompting*直接引导语言模型阅读上下文*C*并一次性生成技能集；生成的技能随后在推理阶段前置输入语言模型。(2) *AutoSkill4Doc*是专为文档级上下文设计的AutoSkill [44]变体：它将上下文*C*划分为不同窗口，识别每个窗口内的独立技能，并跨窗口重组技能以生成技能集。两个基线在技能生成和推理阶段均采用与*Ctx2Skill*相同的骨干模型：例如，所有基于GPT-4.1的方法均使用GPT-4.1进行技能构建和评估，确保公平比较。

实现。我们针对每个上下文运行 $N=5$ 次自我对弈迭代，每次迭代包含 $M=5$ 个任务。其中*Challenger*、*Reasoner*、*Proposer*和*Generator*均采用对应系列相同的骨干网络（例如，GPT-4.1用于所有四个模型）。基于GPT-4.1的方法中的智能体），而*Judge*则采用GPT-5.1，这与CL-bench评估协议[12]保持一致。由于API预算限制，我们未探索更大的 N 或 M ；尽管如此，最有效的技能组合通常会在早期迭代中选定 (§4.3)，且每次迭代的 $M=5$ 个任务为*Proposer*提供了足够案例以合成有意义的诊断模式。

4.2 结果

表1展示了CL-bench上的主要结果。对于当前的前沿语言模型而言，上下文学习仍具挑战性：表现最佳的模型GPT-5.1也仅达到21.1%的整体解决率。*Ctx2Skill*在所有三个基础模型上持续提升解决率，将GPT-4.1从11.1%提高到16.5%（ $\uparrow 5.4\%$ ），GPT-5.1从21.1%提升至25.8%（ $\uparrow 4.6\%$ ），GPT-5.2则从18.2%上升至21.4%（ $\uparrow 3.2\%$ ），在所有四个类别中均大幅超越*Prompting*和*AutoSkill4Doc*。这种提升在需要更深层次程序性推理和归纳推理的“程序性任务执行”与“经验发现与模拟”任务上尤为显著。相比之下，两个基线方法仅带来有限改进，个别类别甚至出现下降（例如*Prompting*使GPT-4.1在“规则系统应用”上的表现降低2.5%），这表明单次技能提取难以应对复杂的上下文知识。值得注意的是，GPT-4.1

表2: 生成技能的质量评估。我们使用GPT-4.1作为评判者，从五个维度评估技能：简洁性、忠实性、清晰性、有效性和可复用性。每个维度的最佳结果以粗体标出。

Model	Conc.	Faith.	Clar.	Eff.	Reus.	Avg.
GPT-4.1-based Methods						
Prompting	81.2	79.7	80.0	83.3	84.7	81.8
AutoSkill4Doc	81.3	81.4	92.4	88.7	87.2	86.2
<i>Ctx2Skill</i>	85.2	84.8	96.2	90.5	92.5	89.8
GPT-5.1-based Methods						
Prompting	80.7	88.5	94.1	94.6	95.3	90.7
AutoSkill4Doc	82.0	89.1	94.2	96.0	96.0	91.5
<i>Ctx2Skill</i>	82.6	93.9	98.1	96.7	96.9	93.6
GPT-5.2-based Methods						
Prompting	80.5	84.4	92.0	90.4	92.0	87.9
AutoSkill4Doc	82.2	87.0	94.0	92.2	93.0	89.7
<i>Ctx2Skill</i>	85.1	89.6	96.5	94.7	94.4	92.0

表3: *Ctx2Skill*的分析结果。我们在CL-bench上报告了四种任务类别下不同消融实验、变体设计等的任务解决率。每个分析区块中的最佳结果以粗体标出。v代表使用了推理时技能增强，u表示未使用技能的推理结果。

Model	Overall (%)	Domain Knowledge Reasoning (%)	Rule System Application (%)	Procedural Task Execution (%)	Empirical Discovery & Simulation (%)
Ablation Study					
Ⓛ Base Model - GPT-4.1	11.1	10.6	14.8	10.4	4.6
Ⓛ <i>Ctx2Skill</i> - GPT-4.1	16.5	16.8	17.6	17.6	9.7
-w/o Cross-Time Replay Mechanism	14.7	15.1	14.9	16.1	9.2
-w/o Decoupling Proposer and Generator	15.9	15.9	16.7	17.4	9.7
-w/o Challenger Skills Evolving	13.8	13.9	13.9	15.7	8.7
-w/o Easy Probe Set	15.7	15.7	16.3	17.4	9.7
-w/o Hard Probe Set	15.2	15.6	15.6	16.5	9.2
-w/o Laplace Smoothing	15.5	15.7	16.0	17.2	9.2
Ⓛ Base Model - GPT-5.1	21.1	22.4	21.0	22.8	13.6
Ⓛ <i>Ctx2Skill</i> - GPT-5.1	25.8	27.9	24.9	26.9	19.1
-w/o Cross-Time Replay Mechanism	23.0	25.6	22.0	23.3	16.0
-w/o Decoupling Proposer and Generator	25.1	27.0	24.5	25.9	18.6
-w/o Challenger Skills Evolving	22.5	25.0	21.3	23.1	16.0
-w/o Easy Probe Set	24.2	26.7	23.6	23.9	18.0
-w/o Hard Probe Set	24.7	26.8	24.0	25.2	18.0
-w/o Laplace Smoothing	25.2	27.0	24.7	25.9	19.1
Variant Designs Testing					
Ⓛ Base Model - GPT-4.1	11.1	10.6	14.8	10.4	4.6
Ⓛ <i>Ctx2Skill</i> - GPT-4.1	16.5	16.8	17.6	17.6	9.7
Ⓛ Loser-Only Skill Update	16.0	15.9	16.9	17.6	9.7
Ⓛ Joint Outcome Skill Update	15.5	15.7	16.0	17.2	9.2
Ⓛ Using Additive Scoring in Eq.(4)	15.9	16.6	17.1	16.5	8.2
Effect of Cross-Time Replay Mechanism					
Ⓛ Base Model - GPT-4.1	11.1	10.6	14.8	10.4	4.6
Ⓛ <i>Ctx2Skill</i> - GPT-4.1	16.5	16.8	17.6	17.6	9.7
Ⓛ Using Skills from Iter-1	15.9	15.9	16.7	17.4	9.7
Ⓛ Using Skills from Iter-2	15.6	15.7	16.2	17.2	9.7
Ⓛ Using Skills from Iter-3	15.6	15.7	16.2	17.2	9.7
Ⓛ Using Skills from Iter-4	15.2	15.6	15.6	16.5	9.2
Ⓛ Using Skills from Iter-5	14.7	15.1	14.9	16.1	9.2
Skill Transferability Testing					
Ⓛ Base Model - GPT-4.1	11.1	10.6	14.8	10.4	4.6
Ⓛ GPT-4.1 with Skills from GPT-5.1	16.1	16.6	17.2	17.2	8.2
Ⓛ GPT-4.1 with Skills from GPT-4.1	16.5	16.8	17.6	17.6	9.7
Ⓛ Base Model - GPT-5.1	21.1	22.4	21.0	22.8	13.6
Ⓛ GPT-5.1 with Skills from GPT-4.1	23.1	24.9	22.4	24.1	16.5
Ⓛ GPT-5.1 with Skills from GPT-5.1	25.8	27.9	24.9	26.9	19.1

具备*Ctx2Skill*技能（16.5%）的表现超越了无技能配置的更强大前沿模型，例如Gemini 3 Pro（15.8%），这表明针对特定情境的技能可以弥合显著的能力差距。除了解决率之外，我们还通过GPT-4.1作为评判标准，从五个维度评估生成技能的内在质量（表2）。*Ctx2Skill*在所有三个基础模型上均获得最高平均分，相较于*AutoSkill4Doc*，在GPT-4.1、GPT-5.1和GPT-5.2上分别以3.6、2.1和2.3的优势胜出，其中忠实度和清晰度方面的提升最为显著。这些结果表明，迭代式自我博弈循环产生的技能不仅能提升下游推理能力，还能以结构清晰、易于人类阅读的形式呈现情境知识，便于检查、编辑和重复利用。

4.3 分析

消融研究。我们在GPT-4.1和GPT-5.1上对*Ctx2Skill*的每个组件进行了消融实验（表3，消融研究模块）。移除*Challenger*技能演化导致性能下降最为显著，这证实了持续的对抗压力对于*Reasoner*逐步发现上下文知识至关重要。*Cross-Time Replay*机制的影响位居第二：若缺少该机制，最终迭代的技能会遭受对抗崩溃。在*Cross-Time Replay*中，困难探测集的贡献大于简单探测集，移除拉普拉斯平滑也会降低性能。将*Proposer*和*Generator*合并为单一智能体会导致性能小幅但持续下降，这支持了诊断与技能实体化的解耦设计。我们还考察了CL-bench所有子类别在GPT-4.1上的影响（图3）。*Ctx2Skill*在绝大多数子类别上提升了解决率，其中工作流编排的增益尤为突出（11.8%）。

变体设计测试。我们在GPT-4.1上检验了三种替代设计方案（表3，变体设计测试模块）。*Loser-Only Skill Update*每次迭代仅更新失败方；0.5%的降幅




图3: CL-bench上各子类别的解题率。与未掌握技能的基础模型相比, *Ctx2Skill*在绝大多数子类别中提高了解题率。

表明同时更新双方能产生更有效的协同进化。*Joint Outcome Skill Update*将失败和成功的案例同时输入到双方,使每一方能从正反例中学习;较大的1.0%性能下降表明混合结果会稀释诊断信号。我们还测试了*Additive Scoring*,即在方程(4)中用 $\rho^h(i) + \rho^e(i)$ 替代 $\rho^h(i) \cdot \rho^e(i)$;0.6%的降幅证实乘法形式能更有效惩罚那些牺牲简单探针性能以换取困难探针增益的技能组合。

Cross-Time Replay机制的效果。我们将*Cross-Time Replay*与使用固定迭代技能进行比较(表3,跨时间回放块的效果)。在GPT-4.1上,固定迭代性能从Iter-1(15.9%)单调递减至Iter-

5(14.7%),证实了后续迭代遭受对抗性崩溃现象。*Cross-Time Replay*(16.5%)通过自适应地为每个上下文选择最平衡的技能集,而非在所有上下文中固定使用单一迭代,其表现优于包括最佳迭代(Iter-1)在内的所有固定迭代,优势达0.6%。图4验证了这一模式:在所有三个骨干网络中,早期迭代被选中的频率最高,同时后期迭代仍占相当比例,表明具有更复杂知识结构的特定上下文确实能从额外的自我对弈轮次中受益。

技能可迁移性测试。我们探究由一种骨干模型生成的技能能否惠及另一种模型(表3,技能可迁移性测试模块)。将GPT-5.1生成的技能应用于GPT-4.1时,效果达到16.1%,几乎与GPT-4.1自身技能持平;反之,GPT-4.1生成的技能应用于GPT-5.1时效果为23.1%,虽带来2.0%的提升,但显著低于GPT-5.1自身技能的4.6%。这种不对称性表明,强模型生成的技能能有效迁移至弱模型,而弱模型则缺乏发掘强模型可利用知识的能力。

案例研究。我们在附录C中进行了案例研究,以直观展示*Ctx2Skill*的优势。

5 结论

我们提出了*Ctx2Skill*,这是一个自我演进的框架,能够自主地从复杂语境中发现、优化并筛选出特定情境下的技能,无需人工标注或外部反馈。通过一个技能优化的自我对弈循环,*Challenger*与*Reasoner*借助失败驱动的文本文编辑共同进化其技能集,而*Cross-Time Replay*机制则通过迭代中选择最具泛化能力的技能集来防止对抗性崩溃。在CL-bench上的实验表明,*Ctx2Skill*在多种骨干模型和任务类别中持续且显著提升了上下文学习性能,且所获得的技能可跨模型迁移。我们希望*Ctx2Skill*能为语言模型提供一种实用且可扩展的范式,使其能够熟练地从复杂、前所未见的语境中学习。




图4: *Cross-Time Replay*选择的迭代分布。我们报告了所有上下文中,最终技能集选自各次迭代的上下文数量。

参考文献

- [1] Salaheddin Alzubi, Noah Provenzano, Jaydon Bingham, Weiyuan Chen, 和 Tu Vu. 2026年。Evoskill: 面向多智能体系统的自动化技能发现。 *arXiv preprint arXiv:2603.02766*.
- [2] Anthropic. 2025. 为现实世界中的智能体配备智能体技能。
- [3] Anthropic. 2025. 智能体技能导论。
- [4] Anthropic. 2025. 系统卡片: Claude opus 4.5。
- [5] Anthropic. 2026. 系统卡片: Claude opus 4.6。
- [6] 白雨诗, 吕鑫, 张家杰, 吕宏昌, 唐建凯, 黄志典, 杜正潇, 刘骁, 曾傲寒, 侯磊, 董禹霄, 唐杰, 李涓子. 2024. LongBench: 一个面向长文本理解的双语多任务基准。于 *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL)*。
- [7] Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano等. 2021. 训练验证器解决数学文字题。 *arXiv preprint arXiv:2110.14168*。
- [8] Google DeepMind. 2025年。Gemini 3 pro模型卡。
- [9] DeepSeek-AI、刘爱心、冯蓓、薛冰、王炳轩、吴伯超、卢成达、赵成刚、邓成奇、张晨雨、阮冲、戴达迈、郭大亚、杨德建、陈德利、季东杰、李二航、林芳云、戴富聪、罗富立、郝光波、陈冠廷、李国伟、张H.、包涵、徐汉伟、王浩成、张浩威、丁鸿辉、辛华健、高华卓、李辉、曲慧、蔡J.L.、梁健、郭建忠、倪嘉琪、李佳时、王佳伟、陈进、陈景昌、袁景阳、邱俊杰、李俊龙、宋俊晓、董凯、胡凯、高凯歌、关康、黄可欣、余快、王利安、张乐聪、徐磊、夏乐毅、赵亮、王立桐、张丽月、李萌、王妙俊、张明川、张明华、唐明辉、李明敏、田宁、黄盼盼、王培艺、张鹏、王千程、朱启浩、陈钦宇、杜秋实、陈R.J.、金R.L.、葛瑞琪、张瑞琪、潘瑞哲、王润基、徐润鑫、张若愚、陈如意、李S.S.、卢尚昊、周尚彦、陈山煌、吴少卿、叶盛峰、叶盛峰、马世荣、王诗雨、周双、余水萍、周顺风、潘舒婷、王T.、云涛、裴天、孙天宇、肖W.L.、曾望鼎、赵万佳、安伟、刘文、梁文峰、高文俊、余文钦、张文涛、李X.Q.、金相月、王贤祖、毕晓、刘小东、王小涵、沈晓金、陈小康、张晓康、陈小莎、聂小涛、孙晓文、王晓翔、程鑫、刘鑫、谢鑫、刘星超、余星凯、宋新楠、单新霞、周欣怡、杨欣宇、李新元、苏学成、林旭恒、李Y.K.、王Y.Q.、魏Y.X.、朱Y.X.、张阳、徐艳红、徐艳红、黄艳萍、李瑶、赵耀、孙耀峰、李耀辉、王耀辉、余毅、郑毅、张毅超、石一凡、熊一良、何颖、唐颖、朴一诗、王一松、谭一轩、马一阳、刘一源、郭永强、吴宇、欧原、朱雨辰、王雨端、龚月、邹宇恒、何宇佳、查宇坤、熊云帆、马云贤、严雨婷、罗宇翔、游宇翔、刘宇轩、周宇阳、吴Z.F.、任Z.Z.、任泽辉、沙张丽、傅哲、徐哲安、黄震、张震、谢振达、张正言、郝哲文、苟志斌、马志成、严志刚、邵志宏、徐志鹏、吴志宇、张忠宇、李卓书、谷子辉、朱子佳、刘子君、李子林、谢子威、宋子洋、高子怡、潘子政。2025。Deepseek-v3技术报告。 *Preprint*, arXiv:2412.19437。
- [10] Anthony DiGiovanni 与 Ethan C. Zell. 2021. 强化学习中自我对弈的研究综述。 *Preprint*, arXiv:2107.02850。
- [11] 董清秀, 李磊, 戴大迈, 郑策, 吴志勇, 常宝宝, 孙栩, 许晶晶, 李磊, 隋志芳。2023。上下文学习研究综述。 *Preprint*, arXiv:2301.00234。
- [12] 窦世瀚, 张明, 尹章越, 黄晨浩, 沈雨琼, 王俊哲, 陈佳怡, 倪雨辰, 叶俊杰, 张诚, 谢怀冰, 胡江路, 王绍雷, 王伟超, 肖燕玲, 刘艺婷, 徐泽楠, 郭臻, 周普路, 桂涛, 吴祖轩,

邱锡鹏、张琦、黄萱菁、蒋亦轩、王迪与姚舜宇。2026。CL-Bench: 上下文学习基准测试。arXiv preprint arXiv:2602.03587。

[13] David A Field. 1988. 拉普拉斯平滑与德劳内三角剖分. *Communications in applied numerical methods*, 4(6):709–712.

[14] 高博飞、宋非凡、杨哲、蔡泽帆、缪一博、董清修、李磊、马成浩、陈亮、徐润新、唐正阳、王本有、赞道光、全上豪然、张戈、沙磊、张一畅、任宣成、刘天宇、常宝宝。2025。Omni-MATH: 面向大语言模型的通用奥林匹克数学基准测试。于 *The Thirteenth International Conference on Learning Representations*。

[15] 阿尼莎·古贾尔、安东尼·王、伊莱恩·刘、瓦斯卡尔·纳特、何云中、刘冰与肖恩·亨德里克斯。2025年。评分准则即奖励: 超越可验证领域的强化学习。Preprint, arXiv:2507.17746。

[16] 华奇硕、叶庐山、付大元、肖阳、蔡晓杰、吴云泽、林济帆、王俊飞和刘鹏飞。2025。情境工程2.0: 情境工程的情境。Preprint, arXiv:2510.26493。

[17] Carlos E Jimenez, John Yang, Alexander Wettig, Shunyu Yao, Kexin Pei, Ofir Press and Karthik R Narasimhan. 2024年。SWE-bench: 语言模型能否解决现实中的GitHub问题? 发表于 *The Twelfth International Conference on Learning Representations*。

[18] 李浩, 牟春江, 陈建豪, 任思越, 崔志尧, 张逸群, 白磊, 胡书悦。2026。生态系统规模下的智能体技能组织、编排与基准测试。Preprint, arXiv:2603.02176。

[19] 李翔毅、陈文博、刘一民、郑申翰、陈晓坤、贺一峰、李宇波、尤冰然、沈浩天、孙建凯、王舒怡、李彬旭、曾群鸿、王迪、赵宣东、王元立、Roey Ben Chaim、狄宗霖、高毅鹏、贺俊威、贺一卓、荆立强、孔鲁阳、兰鑫、李嘉臣、李松林、李一江、林跃骞、刘心怡、刘轩庆、吕浩然、马泽、王博威、王润晖、王天宇、叶文高、张悦、邢汉文、薛一琪、Steven Dillmann、李汉忠。2026。Skillsbench: 评估智能体技能在多样化任务中的表现基准。Preprint, arXiv:2602.12670。

[20] 梁源、钟若斌、徐浩铭、姜辰、钟毅、方润南、顾嘉琛、邓舒敏、姚云志、王梦茹、乔硕飞、徐昕、吴桐桐、王琨、刘洋、毕祯、娄俊刚、姜雨晨·埃莉诺、朱航程、余刚、洪海文、黄龙涛、薛辉、王晨曦、王艺君、单紫菲、陈曦、涂兆鹏、熊飞宇、谢鑫、张鹏、桂正科、梁磊、周俊、吴驰宇、尚瑾、龚宇、林俊宇、徐长亮、邓宏杰、张文、丁可彦、张强、黄斐、张宇宇、潘杰夫、齐桂林、王浩奋、陈华钧。2026。Skillnet: 创建、评估与连接AI技能。Preprint, arXiv:2603.04448。 [21] 刘博、莱昂·格特勒、西蒙·余、刘子辰、齐鹏辉、丹尼尔·巴塞尔斯、米克尔·刘、陈士敦、施蔚然、林敏、李伟新、娜塔莎·雅克。2026。Spiral: 零和游戏下的自我对弈通过多智能体多轮强化学习激励推理。Preprint, arXiv:2506.24119。

[22] 卢洪亮、温宇航、程鹏宇、丁瑞金、郭佳琪、徐浩天、王楚天、陈浩南、蒋小西和江冠君。2026。自我博弈搜索: 无需监督推动智能体能力前沿。载于 *The Fourteenth International Conference on Learning Representations*。

[23] 郑曦璐、智远姚、金阳昊、成城韩、齐谷、勋亮蔡、伟明卢、俊萧、月婷庄和永亮沈。2026。SKILL0: 面向技能内化的情境智能体强化学习。arXiv preprint arXiv:2604.02268。

[24] 马英伟、刘越、杨新龙、李彦浩、付科霖、缪一博、谢雨冲、王哲旭和张志成。2026。通过原子技能扩展编程智能体规模。Preprint, arXiv:2604.05013。

[25] 马子瑜, 杨世栋, 纪宇翔, 王旭聪, 王勇, 胡一鸣, 黄同文, 楚祥翔. 2026. Skillclaw: 让技能与代理进化器共同进化. *Preprint*, arXiv:2604.08377. [26] 梅凌瑞, 姚佳宇, 葛宇瑶, 王一伟, 毕宝龙, 蔡宇俊, 刘家志, 李明宇, 李忠智, 张笃振, 周晨霖, 毛佳怡, 夏天泽, 郭嘉丰, 刘胜华. 2025. 大语言模型上下文工程综述. *ArXiv*, abs/2507.13334.

[27] OpenAI. 2025. Gpt-5技术报告。

[28] OpenAI. 2025. GPT-5系统卡更新: GPT-5.2。

[29] OpenAI, Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altenschmidt, Sam Altman, Shyamal Anadkat, Red Adella, Igor Babuschkin, Suchir Balaji, Valerie Balcom, Paul Baltescu, Haiming Bao, Mohammad Bavarian, Jeff Belgum, Irwan Bello, Jake Berdine, Gabriel Bernadett-Shapiro, Christopher Berner, Lenny Bogdonoff, Oleg Boiko, Madelaine Boyd, Anna-Luisa Brakman, Greg Brockman, Tim Brooks, Miles Brundage, Kevin Button, Trevor Cai, Rosie Campbell, Andrew Cann, Brittany Carey, Chelsea Carlson, Rory Carmichael, Brooke Chan, Che Chang, Fotis Chantzis, Derek Chen, Sully Chen, Ruby Chen, Jason Chen, Mark Chen, Ben Chess, Chester Cho, Casey Chu, Hyung Won Chung, Dave Cummings, Jeremiah Currier, Yunxing Dai, Cory Decareaux, Thomas Degry, Noah Deutsch, Damien Deville, Arka Dhar, David Dohan, Steve Dowling, Sheila Dunning, Adrien Ecoffet, Atty Eleti, Tyna Eloundou, David Farhi, Liam Fedus, Niko Felix, Simón Posada Fishman, Juston Forte, Isabella Fulford, Leo Gao, Elie Georges, Christian Gibson, Vik Goel, Tarun Gogineni, Gabriel Goh, Rapha Gontijo-Lopes, Jonathan Gordon, Morgan Grafstein, Scott Gray, Ryan Greene, Joshua Gross, Shixiang Shane Gu, Yufei Guo, Chris Hallacy, Jesse Han, Jeff Harris, Yuchen He, Mike Heaton, Johannes Heidecke, Chris Hesse, Alan Hickey, Wade Hickey, Peter Hoeschele, Brandon Houghton, Kenny Hsu, Shengli Hu, Xin Hu, Joost Huizinga, Shantanu Jain, Shawn Jain, Joanne Jang, Angela Jiang, Roger Jiang, Haozhun Jin, Denny Jin, Shino Jomoto, Billie Jonn, Heewoo Jun, Tomer Kaftan, Lukasz Kaiser, Ali Kamali, Ingmar Kanitscheider, Nitish Shirish Keskar, Tabarak Khan, Logan Kilpatrick, Jong Wook Kim, Christina Kim, Yongjik Kim, Jan Hendrik Kirchner, Jamie Kiros, Matt Knight, Daniel Kokotajlo, Lukasz Kondraciuk, Andrew Kondrich, Aris Konstantinidis, Kyle Kosic, Gretchen Krueger, Vishal Kuo, Michael Lampe, Ikai Lan, Teddy Lee, Jan Leike, Jade Leung, Daniel Levy, Chak Ming Li, Rachel Lim, Molly Lin, Stephanie Lin, Mateusz Litwin, Theresa Lopez, Ryan Lowe, Patricia Lue, Anna Makanju, Kim Malfacini, Sam Manning, Todor Markov, Yaniv Markovskii, Bianca Martin, Katie Mayer, Andrew Mayne, Bob McGrew, Scott Mayer McKinney, Christine McLeavey, Paul McMillan, Jake McNeil, David Medina, Aalok Mehta, Jacob Menick, Luke Metz, Andrey Mishchenko, Pamela Mishkin, Vinnie Monaco, Evan Morikawa, Daniel Mossing, Tong Mu, Mira Murati, Oleg Murk, David Mély, Ashvin Nair, Reiichiro Nakano, Rajeev Nayak, Arvind Nee-lakantan, Richard Ngo, Hyeonwoo Noh, Long Ouyang, Cullen O’Keefe, Jakub Pachocki, Alex Pano, Joe Palermo, Ashley Pantuliano, Giamattista Parascandolo, Joel Parish, Emy Parparita, Alex Passos, Mikhail Pavlov, Andrew Peng, Adam Perelman, Filipe de Avila Belbute Peres, Michael Petrov, Henrique Ponde de Oliveira Pinto, Michael, Pokorny, Michelle Pokrass, Vitchyr H. Pong, Tolly Powell, Alethea Power, Boris Power, Elizabeth Proehl, Raul Puri, Alec Radford, Jack Rae, Aditya Ramesh, Cameron Raymond, Francis Real, Kendra Rimbach, Carl Ross, Bob Rotsted, Henri Roussez, Nick Ryder, Mario Saltarelli, Ted Sanders, Shibani Santurkar, Girish Sastry, Heather Schmidt, David Schnurr, John Schulman, Daniel Selsam, Kyla Sheppard, Toki Sherbakov, Jessica Shieh, Sarah Shoker, Pranav Shyam, Szymon Sidor, Eric Sigler, Maddie Simens, Jordan Sitkin, Katarina Slama, Ian Sohl, Benjamin Sokolowsky, Yang Song, Natalie Staudacher, Felipe Petroski Such, Natalie Summers, Ilya Sutskever, Jie Tang, Nikolas Tezak, Madeleine B. Thompson, Phil Tillet, Amin Tootoonchian, Elizabeth Tseng, Preston Tuggle, Nick Turley, Jerry Tworek, Juan Felipe Cerón Uribe, Andrea Vallone, Arun Vijayvergiya, Chelsea Voss, Carroll Wainwright, Justin Jay Wang, Alvin Wang, Ben Wang, Jonathan Ward, Jason Wei, CJ Weinmann, Akila Welihinda, Peter Welinder, Jiayi Weng, Lilian Weng, Matt Wiethoff, Dave Willner, Clemens Winter, Samuel Wolrich, Hannah Wong, Lauren Workman, Sherwin Wu, Jeff Wu, Michael Wu, Kai Xiao, Tao Xu, Sarah Yoo, Kevin Yu, Qiming Yuan, Wojciech Zaremba, Rowan Zellers, Chong Zhang, Marvin Zhang, Shengjia Zhao, Tianhao Zheng, Juntang Zhuang, William Zhuk, and Barret Zoph. 2024. GPT-4技术报告. *Preprint*, arXiv:2303.08774.

[30] 邱立斌、高志荣、陈俊甫、叶宇航、黄炜智、薛晓波、邱文凯、唐硕。2026。Autorefine: 从轨迹到可复用专长, 持续优化LLM智能体。arXiv preprint arXiv:2601.22758. [31] 邵志宏、王培毅、朱启浩、徐润新、宋俊晓、毕啸、张浩伟、张铭传、李YK、吴Y、郭大亚。2024。Deepseekmath: 突破开放语言模型数学推理的极限。arXiv preprint arXiv:2402.03300. [32] 司书正、马文涛、高浩宇、吴宇川、林霆恩、戴寅沛、李航宇、严睿、黄飞、李永彬。2023。SpokenWOZ: 面向口语任务型对话的大规模语音-文本基准。收录于 *Thirty-seventh Conference on Neural Information Processing Systems Datasets and Benchmarks Track*. [33] 司书正、王清怡、赵浩哲、白雨卓、陈冠乔、罗康阳、陈刚、齐凡超、张敏佳、常宝宝、孙茂松。2026。Faithlens: 检测与解释忠实性幻觉。Preprint, arXiv:2512.20182. [34] 司书正、赵浩哲、陈刚、高成、白雨卓、王志通、安凯凯、罗康阳、钱晨、齐凡超、常宝宝、孙茂松。2025。通过高效数据过滤对齐大语言模型以遵循指令并减少幻觉。收录于 *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 第16469–16488页, 奥地利维也纳。计算语言学协会。[35] 司书正、赵浩哲、陈刚、李云水、罗康阳、吕传成、安凯凯、齐凡超、常宝宝、孙茂松。2025。GATEAU: 为长上下文对齐筛选影响力样本。收录于 *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, 第7391–7422页, 中国苏州。计算语言学协会。[36] 司书正、赵浩哲、高成、白雨卓、王志通、高博飞、罗康阳、李文浩、黄宇飞、陈刚、齐凡超、张敏佳、常宝宝、孙茂松。2026。通过合成任务与强化学习教授大语言模型保持上下文忠实性。收录于 *Fortieth AAAI Conference on Artificial Intelligence, Thirty-Eighth Conference on Innovative Applications of Artificial Intelligence, Sixteenth Symposium on Educational Advances in Artificial Intelligence, AAAI 2026, Singapore, January 20-27, 2026*, 第33001–33009页。AAAI出版社。[37] 司书正、赵浩哲、罗康阳、陈刚、齐凡超、张敏佳、常宝宝、孙茂松。2025。无计划的目标只是愿望: 面向长视野智能体任务的高效全局规划器训练。Preprint, arXiv:2510.05608. [38] Kimi团队、白桐桐、白一凡、鲍一平、蔡SH、曹原、Charles Y、Che HS、陈成、陈冠铎、陈华荣、陈佳、陈嘉豪、陈建龙、陈俊、陈科帆、陈亮、陈瑞珏、陈鑫浩、陈彦如、陈彦旭、陈奕村、陈毅敏、陈英江、陈元坤、陈宇杰、陈玉田、陈志荣、陈紫薇、程大志、褚铭汉、崔家磊、邓佳琪、刁木西、丁浩、董梦凡、董梦南、董雨欣、董宇豪、杜安刚、杜晨壮、杜迪康、杜凌霄、杜玉伦、范宇、方胜军、冯秋霖、冯奕辰、傅嘎日木盖、付克霖、高宏程、高桐、葛宇瑶、耿尚义、龚成阳、龚晓晨、贡确卓玛、顾琦正、顾欣然、顾亦成、管龙雨、郭媛颖、郝晓茹、何蔚然、何文阳、何云佳、洪超、胡昊、胡佳曦、胡洋洋、胡振兴、黄珂、黄瑞元、黄微笑、黄志奇、蒋涛、姜哲君、金欣怡、靖宇、赖国坤、李爱迪、李C、李程、李芳、李广鹤、李冠宇、李海涛、李昊阳、李佳、李经纬、李俊雄、李林灿、李默、李伟宏、李文涛、李新航、李鑫浩、李阳、李彦浩、李一玮、李晓宇、李兆伟、李哲明、廖伟龙、林佳伟、林晓晗、林志山、林梓超、刘成、刘宸宇、刘鸿章、刘亮、刘少伟、刘树东、刘书然、刘天伟、刘天宇、刘伟洲、刘湘岩、刘阳阳、刘彦明、刘一博、刘元新、刘越、刘正英、刘中诺、卢恩哲、卢浩宇、卢志远、罗俊宇、罗通旭、罗亚硕、马龙、马英伟、毛少光、梅原、门欣、孟凡青、孟志勇、苗一博、倪敏卿、欧阳坤、潘思远、庞博、钱雨超、

秦若愚、秦泽宇、丘杰中、屈博文、尚泽宇、邵有博、沈天晓、沈振南、石娟峰、石立东、石胜元、宋非凡、宋鹏威、宋天辉、宋晓曦、苏鸿瑾、苏建林、苏昭辰、隋琳、孙劲松、孙俊尧、孙桐宇、Flood Sung、邵云鹏、唐楚宁、唐鹤仪、唐晓娟、唐正阳、陶佳文、滕诗远、田超然、田鹏飞、王傲、王博文、王晨思、王闯、王聪聪、王定坤、王鼎禄、王栋梁、王峰、王海龙、王海明、王衡之、王华清、王辉、王家豪、王金宏、王九正、王凯欣、王立安、王启斌、王胜杰、王书怡、王思、王威、王晓晨、王新元、王尧、王业杰、王艺朴、王艺钦、王雨成、王宇志、王昭基、王兆伟、王正涛、王哲旭、王子涵、王子哲、魏楚、魏铭、温川、温子辰、吴成杰、吴昊宁、吴俊彦、吴如聪、吴文浩、吴岳峰、吴宇豪、吴宇鑫、吴子健、肖晨君、谢瑾、谢晓彤、谢宇翀、辛逸飞、邢博伟、徐博宇、徐健凡、徐静、徐金晶、徐L.H.、徐林、徐苏婷、徐伟新、徐新博、徐欣然、徐阳川、徐宜昌、徐月萌、徐泽来、徐子尧、严俊杰、严雨孜、杨光耀、杨浩、杨俊威、杨凯、杨宁远、杨瑞涵、杨晓飞、杨新龙、杨颖、杨毅、杨毅、杨震、杨志霖、杨宗翰、姚昊天、叶丹、叶文杰、叶卓睿、尹伯鸿、喻成真、喻龙辉、喻涛、喻天翔、袁恩明、袁梦洁、袁晓坤、岳洋、曾维浩、查敦远、詹浩冰、张德浩、张浩、张瑾、张普奇、张乔、张瑞、张晓斌、张Y.、张亚东、张阳坤、张一驰、张亦之、张永廷、张宇、张雨顺、张宇韬、张雨桐、张铮、赵晨光、赵非凡、赵金祥、赵帅、赵翔宇、赵一凯、赵子佳、郑华斌、郑瑞涵、郑少杰、郑腾阳、钟俊峰、钟龙光、钟伟明、周M.、周润杰、周新宇、周在达、朱金国、朱丽雅、朱新浩、朱宇轩、朱臻、庄靖泽、庄维宇、邹颖、祖新星。2026. Kimi K2.5: 视觉代理智能。Preprint, arXiv:2602.02276。

- [39] Qwen团队。2026. Qwen3.5: 迈向原生多模态智能体。URL: <https://qwen.ai/blog>
- [40] 王晨曦、余卓云、谢鑫、姚武冠男、方润南、乔硕飞、曹可欣、郑国洲、齐翔、张鹏、邓淑敏。2026. SkillX: 自动化构建智能体技能知识库。arXiv preprint arXiv:2604.04804. [41] 王佳玉、明一飞、柯子轩、Shafiq Joty、Aws Albarghouthi、Frederic Sala。2026. Skillorchestra: 通过技能迁移学习路由智能体。Preprint, arXiv:2602.19672. [42] 王昭阳、吴倩慧、张旭超、张朝云、姚文林、Fazle Elahi Faisal、彭宝林、秦思、Suman Nath、林庆伟、Chetan Bansal、张冬梅、Saravan Rajmohan、高剑峰、姚华修。2026. Webxskill: 自主网络智能体的技能学习。Preprint, arXiv:2604.13318. [43] 夏鹏、陈建文、王瀚阳、刘佳琪、曾凯德、王宇、韩思伟、周怡阳、赵旭江、陈海峰、郑泽宇、谢慈航、姚华修。2026. Skillrl: 通过递归技能增强强化学习进化智能体。Preprint, arXiv:2602.08234。

- [44] 杨宇涛、李俊松、潘千钧、詹碧浩、蔡宇轩、杜琳、周杰、陈凯、陈琴、李鑫、张博、何亮。2026. AutoSkill: 通过技能自进化的经验驱动终身学习。arXiv preprint arXiv:2603.01145。

- [45] 张汉荣、范世成、邹亨利、陈彦凯、王振廷、周佳玉、李承泽、黄伟杰、姚一飞、郑克宁、刘雪、李晓晓、Philip S. Yu。2026年。Coevoskills: 通过协同进化验证实现技能自演化的智能体。Preprint, arXiv:2604.01687。

- [46] 张浩真、龙全玉、鲍建竹、冯涛、张伟志、岳浩东和王文雅。2026年。Memskill: 自进化代理的记忆技能学习与进化。Preprint, arXiv:2602.02474。

- [47] 张启正、胡昌然、Shubhangi Upasani、马博元、洪峰露、Vamsidhar Kamanuru、Jay Rainton、吴晨、季梦梦、李汉臣、Urmish Thakker、James Zou与Kunle Olukotun。2026。能动性上下文工程：为自我进化的语言模型优化上下文环境。{v*}, arXiv:2510.04618。
- [48] 张耀成, 朱远恒, 崇文月, 涂松君, 张启超, 柴佳俊, 王晓晗, 林伟, 尹国军, 赵东斌。2026年。 π -play: 无需外部数据的特权自蒸馏多智能体自博弈。Preprint, arXiv:2604.14054。
- [49] 郑博元、Michael Y. Fatemi、金龙、王卓若、Apurva Gandhi、宋越琪、谷雨、Jayanth Srinivasa、刘高文、Graham Neubig、苏宇。2025。Skillweaver: 网络智能体可通过发现与精进技能实现自我提升。Preprint, arXiv:2504.07079。
- [50] 郑连敏、江伟林、盛颖、庄思远、吴张昊、庄永浩、林子、李卓翰、李大成、Eric P. Xing、张昊、Joseph E. Gonzalez与Ion Stoica。2023。以MT-Bench与聊天机器人竞技场评判LLM即评委。载于*Advances in Neural Information Processing Systems (NeurIPS) Datasets and Benchmarks Track*。

附录

A 统计

在本节中，我们提供了针对 *Ctx2Skill* 的相应统计数据。

表4: CL-bench统计信息。该表包含上下文数量、任务数量、评分标准、每个上下文的平均及最大任务数、每个任务的评分标准以及输入长度。

Context Category	#Contexts	#Tasks	#Rubrics	Tasks per context		Rubrics per task		Input Length (tokens)	
				Mean	Max	Mean	Max	Mean	Max
Domain Knowledge Reasoning	190	663	11,099	3.5	7	16.7	74	8.3K	60.0K
Rule System Application	140	566	8,286	4.0	12	14.6	75	12.2K	62.2K
Procedural Task Execution	100	471	9,486	4.7	12	20.1	59	8.5K	58.5K
Empirical Discovery & Simulation	70	199	2,736	2.8	9	13.7	114	16.7K	65.0K
Total	500	1,899	31,607	3.8	12	16.6	114	10.4K	65.0K

CL-bench。CL-bench旨在评估语言模型从提供的上下文中学习并应用所学知识解决问题的能力。解决这些任务所需的知识，无论是新创建的还是小众长尾的，大多超出了现有模型在预训练阶段所掌握的范围。CL-bench中的新知识形式多样，包括但不限于书籍、新闻、转录稿、研究论文、文档、报告、实验数据、代码库、产品与操作手册以及搜索结果。所有必要知识已精心组织到提供的上下文中，因此模型无需从外部来源检索信息。CL-bench中的每个上下文都涉及解决多个任务。51.1%的任务是顺序性的：它们分布在多个交互轮次中呈现，且解决它们依赖于先前任务的解决方案。这种多轮设计进一步增加了任务难度，更好地反映了现实世界的使用场景。CL-bench的统计数据如表4所示。

表5: 迭代过程中的任务级自我对弈动态。我们报告了每次迭代中平均解决和失败的任务数（共 $M=5$ 个），以及对应的解决率（%），该数据在所有上下文情境下取平均值。

Iteration	GPT-4.1			GPT-5.1			GPT-5.2		
	Solved	Failed	Rate (%)	Solved	Failed	Rate (%)	Solved	Failed	Rate (%)
Iter-1	0.91	4.09	18.2	2.09	2.91	41.7	1.81	3.19	36.1
Iter-2	1.03	3.97	20.6	2.26	2.75	45.2	1.45	3.55	28.9
Iter-3	1.04	3.96	20.9	2.37	2.63	47.4	1.32	3.68	26.5
Iter-4	1.15	3.85	22.9	2.44	2.56	48.8	1.15	3.85	23.0
Iter-5	1.17	3.83	23.3	2.41	2.59	48.2	1.19	3.81	23.7

任务级自我对弈动态。表5报告了自我对弈过程中每轮平均解决和失败的任务数（共 $M=5$ 个任务），所有500个情境的平均值。在GPT-4.1上，解决率从18.2%（第一轮）逐步提升至23.3%（第五轮），平均解决任务数从0.91增至1.17。这表明推理者不断进化的技能逐步提升了其应对挑战者生成任务的能力；然而，失败率在所有轮次中始终高于76%，证实挑战者的协同进化持续施加对抗压力，防止推理者达到饱和状态。在GPT-5.1上，更强的骨干模型使推理者从一开始就能解决显著更多任务（第一轮41.7%），解决率逐步上升至第四轮的48.8%，第五轮略微回落至48.2%。后期轮次的近均衡状态表明挑战者与推理者达到了竞争平衡，挑战者不断演化的策略有效抵消了推理者提升的技能。GPT-5.2则呈现不同模式：解决率从第一轮36.1%降至第四轮23.0%，说明挑战者的技能进化速度超越推理者改进，生成的任务难度持续增加，即使推理者更新技能仍难以应对。该现象与§3.4描述的对抗崩溃一致，进一步印证需要引入跨时间回放机制来选择最具泛化能力的技能集，而非默认采用...

到最后一轮迭代。在所有三个骨干网络中，失败率在所有迭代中始终保持较高水平（51%–82%），验证了自我博弈循环避免了简单收敛，并为持续技能发现维持了有意义的对抗压力。

表6：各迭代周期中的评分标准自博弈动态。我们报告了每个迭代周期中评分标准的通过率(%)和每项任务的平均评分标准数量，所有情境下的平均值。

Iteration	GPT-4.1		GPT-5.1		GPT-5.2	
	Pass Rate (%)	Avg. Rubrics	Pass Rate (%)	Avg. Rubrics	Pass Rate (%)	Avg. Rubrics
Iter-1	79.2	11.7	90.0	11.2	87.5	11.2
Iter-2	80.7	11.9	90.8	11.3	85.3	11.5
Iter-3	80.6	12.2	90.8	11.5	84.5	11.7
Iter-4	81.1	12.3	91.3	11.4	83.6	11.9
Iter-5	81.5	12.3	90.9	11.3	83.8	12.0

评分标准级别的自我博弈动态。表6报告了每次迭代中评分标准的通过率及每项任务的平均评分标准数量。与任务级解决率（表5）相比，所有模型架构的评分标准通过率均显著更高（79%–91%对比18%–49%），这证实了CL-bench中全有或全无评分的严格性：推理模型通常能通过大部分评分标准，但因遗漏一两个要求而未能完成任务。在GPT-4.1上，评分标准通过率从79.2%稳步提升至81.5%，同时每项任务的平均评分标准数量也从11.7增至12.3，表明即使挑战者生成更细粒度的评分标准，推理模型的能力仍在提升。对于GPT-5.1，评分标准通过率始终保持在较高水平（90.0%–91.3%），且评分标准数量稳定（11.2–11.5），反映出推理模型在自我博弈全程保持了接近上限的评分标准级表现。而在GPT-5.2中，评分标准通过率从87.5%降至83.6%，平均评分标准数量却从11.2增加到12.0，揭示出挑战者同时生成了更多且更难的标准，这种叠加的难度加剧了任务级解决率的下降（如表5所示）。这一评分标准级别的分析为任务级动态提供了补充视角：即使任务解决率停滞或下降，评分标准通过率仍能揭示推理模型是在取得部分进展，还是真正落后于挑战者不断升级的施压。

表7：每个任务的评分标准数量分布。我们报告了每轮迭代中由挑战者生成的任务所包含评分标准的最小、最大、平均及中位数数量。因偶尔格式错误导致评分标准为零的任务已被排除。

Iteration	GPT-4.1				GPT-5.1				GPT-5.2			
	Min	Max	Mean	Med.	Min	Max	Mean	Med.	Min	Max	Mean	Med.
Iter-1	5	16	11.7	12	6	22	11.2	11	4	21	11.2	11
Iter-2	7	17	11.9	12	1	27	11.4	11	4	21	11.6	12
Iter-3	7	16	12.2	12	7	19	11.5	11	4	23	11.8	12
Iter-4	7	17	12.3	12	7	19	11.5	11	4	23	11.9	12
Iter-5	7	21	12.3	12	6	33	11.4	11	4	24	12.0	12
Overall	5	21	12.1	12	1	33	11.4	11	4	24	11.7	12

评分项数量分布。表7报告了每个挑战者生成任务中评分项的分布情况，排除了少量因偶尔格式错误导致评分项为零的任务（<1%）。在所有三个基础模型中，评分项的中位数在迭代过程中保持稳定，维持在11至12项，而平均数则呈现轻微上升趋势，尤其是在GPT-4.1（11.7 → 12.3）和GPT-5.2（11.2 → 12.0）上，这表明随着技能提升，挑战者逐步生成包含更多评分项的任务，对推理者施加了更严格的验证标准。GPT-4.1的最小评分项数量从第一轮5项上升至第二轮7项，并在后续迭代中保持该水平，表明挑战者在首轮技能更新后学会了避免生成定义不明确的任务。类似稳定现象见于GPT-5.1（最小项数在第三轮升至7项）和GPT-5.2（最小项数稳定在4项），但后者的下限更低，可能因为其挑战者将更多精力用于提升评分难度而非数量。最大评分项数量在不同模型间差异显著：GPT-5.1在第五轮达到33项峰值，而GPT-4.1和GPT-5.2分别以21项和24项为上限，反映出挑战者在评分粒度策略上的差异。

GPT-5.1的最大值显著更高，但其评分标准通过率仍保持在90%以上（表6），这进一步凸显了GPT-5.1作为推理核心的强大实力。结合表6来看，GPT-4.1和GPT-5.2的平均评分标准数量的增加表明，挑战者不仅生成了更难的任务，还提出了更细粒度的验证标准，要求推理者满足日益增长的需求集才能达成解决。这一趋势在CL-bench的全有或全无评分体系下尤为重要：即使推理者未能满足一个额外的评分标准，也会导致整个任务被标记为失败，这使得挑战者的对抗压力远超评分标准通过率单独所示的程度。

表8：迭代过程中挑战者任务的长度。我们报告了每次迭代中挑战者生成任务的最大、平均和中位数字数。

Iteration	GPT-4.1			GPT-5.1			GPT-5.2		
	Max	Mean	Med.	Max	Mean	Med.	Max	Mean	Med.
Iter-1	125	46.3	45	387	142.1	137	546	69.1	67
Iter-2	136	51.8	50	543	171.5	161	449	105.6	97
Iter-3	133	55.5	53	709	178.1	167	607	122.5	115
Iter-4	137	57.6	56	644	183.2	172	530	132.7	127
Iter-5	153	59.4	57	661	185.1	173	546	139.1	132
Overall	153	54.1	52	709	172.0	161	607	113.8	104

挑战者任务长度。表8报告了挑战者生成任务在各迭代中的词数分布。在所有三个骨干模型中均呈现出一致的趋势：平均任务长度随着迭代推进单调递增。在GPT-4.1上，平均值从Iter-1的46.3词上升至Iter-5的59.4词（增幅28%），反映出任务特异性的适度提升。GPT-5.2则展现出更显著的增长，平均值从69.1词近乎翻倍至139.1词，表明其挑战者能快速学会生成更精细、详实的任务描述以维持对抗压力。GPT-5.1生成的任务总体最长（平均172.0词），从初始142.1词攀升至185.1词，这与GPT-5.1更强的生成能力相一致——从一开始就能产出更复杂、细致的探测任务。所有骨干模型中任务长度的持续增长直接证明：挑战者不断进化的技能驱动其构建愈发苛刻的任务，要求推理者展现更深入精准的语境知识。值得注意的是，不同骨干模型的增长率差异显著：GPT-4.1的挑战者在五次迭代中任务长度增长约28%，而GPT-5.2的挑战者增幅超过100%，这与表5中观察到的GPT-5.2任务级解决率下降现象一致，进一步支持了该骨干模型上的对抗性崩溃现象。

表9：推理器各轮次输出长度。我们记录了每轮次推理器生成答案的最大值、平均值和中位数的单词计数。少量无效或空输出（<0.3%）已被排除。

Iteration	GPT-4.1			GPT-5.1			GPT-5.2		
	Max	Mean	Med.	Max	Mean	Med.	Max	Mean	Med.
Iter-1	1479	209.4	166	2926	337.6	238	1557	216.9	169
Iter-2	1724	241.2	186	4594	380.3	260	2288	265.8	210
Iter-3	2039	285.5	216	2993	398.6	272	2976	293.0	225
Iter-4	1911	305.1	241	3142	400.7	272	2574	305.0	231
Iter-5	2099	322.2	262	3310	399.6	264	2086	312.3	239
Overall	2099	272.5	207	4594	383.2	261	2976	278.6	213

推理器输出长度。表9展示了推理器生成答案在各轮迭代中的词数分布。与挑战者任务长度（表8）类似，三个基础模型上推理器输出的平均长度均随迭代单调递增：GPT-4.1从209.4词增至322.2词（54%），GPT-5.2从216.9词增至312.3词（44%），GPT-5.1从337.6词增至399.6词（18%）。这种与挑战者任务长度的同步增长符合预期：随着挑战者生成更复杂、要求更高的任务，推理器必须产出相应更长、更详尽的答案以满足日益增加的评分标准。值得注意的是，GPT-5.1初始便具有最长的

输出（在Iter-1时生成337.6个单词）并显示出最小的相对增长（48%），这表明这个更强的骨干网络从一开始就能生成全面的答案，长度增加的余地较小。相比之下，GPT-4.1和GPT-5.2初始输出较短，但表现出更大的相对增长，这意味着它们不断进化的技能逐步引导推理器生成更详尽的回答。输出长度的增加，加上GPT-4.1和GPT-5.1上稳定或提升的评分通过率（表6），表明更长的输出并非仅是冗长，而是确实包含了更多应对挑战者日益增长需求所需的详细上下文知识。然而，在GPT-5.2上，尽管输出长度不断增加，却未能阻止评分通过率的下降（87.5% → 83.8%），这说明挑战者的压力超过了推理器生成正确答案的能力，即便其回答长度在增加。

表10：各迭代中技能集的词数统计。我们报告了每次迭代时技能集的最大、平均及中位词数。最后一行（选定）展示了由跨时间回放选定的最终技能集的统计结果。未包含技能文件的上下文已被排除。

Iteration	GPT-4.1			GPT-5.1			GPT-5.2		
	Max	Mean	Med.	Max	Mean	Med.	Max	Mean	Med.
Iter-1	554	313.9	311	1872	1216.4	1235	923	626.1	626
Iter-2	1057	657.8	656	4063	2505.4	2564	1831	1340.7	1338
Iter-3	1866	1005.6	1002	5673	3764.2	3871	2636	2072.7	2072
Iter-4	2807	1354.2	1357	7350	5028.5	5175	3476	2827.6	2842
Iter-5	3460	1704.1	1703	8891	6289.9	6447	4445	3584.8	3582
Selected	2807	840.6	705	8261	3632.3	3682	4445	1749.8	1458

技能集字数统计。表10展示了每次迭代中技能集的字数分布情况，以及跨时间重放选定的最终技能集。由于每次迭代都会新增一个技能，总字数呈现近似线性增长。GPT-5.1生成的技能描述最为详尽，到第五轮迭代时中位数达到6,447词——约为GPT-4.1（1,703词）的3.8×倍，GPT-5.2（3,582词）的1.8倍。技能描述粒度也存在显著差异：GPT-4.1平均每个技能~340词，GPT-5.1平均~1,260词，GPT-5.2平均~720词，表明更强的基础模型能生成更细致翔实的技能描述。各设置下均值与中位数的微小差距说明字数呈对称分布且离群值较少。对比“选定集”行与各迭代轮次的数据，可见跨时间重放的作用效果：在GPT-4.1上，选定技能集中位数为705词，介于第二轮迭代（656词）与第三轮（1,002词）之间，说明跨时间重放更倾向选择早期迭代中通用性更强、更简洁的技能，而非第五轮最冗长的技能集。GPT-5.2也呈现类似规律，选定中位数（1,458词）落在第二轮（1,338词）与第三轮（2,072词）之间。而GPT-5.1的选定中位数（3,682词）接近第三轮迭代（3,871词），反映出其更强的推理能力使得后期迭代技能仍保持通用性。这证实跨时间重放能有效规避后期迭代产生的过度特化技能集，在基础模型较弱时对抗性崩溃现象更为明显。技能集规模、挑战者任务长度（表8）和推理器输出长度（表9）的同步增长，共同印证了协同进化动态：随着任务要求提高，技能与响应都会相应变得更为丰富。

B 实现细节

本节提供Ctx2Skill的额外实现细节，包括伪代码算法、基线描述与API版本、所有代理的关键提示。

基准线与API版本。我们将Ctx2Skill与两种基线方法进行比较。(1) *Prompting*直接提示语言模型读取上下文 C ，并一次性生成技能集合；所得技能随后在推理阶段预置至语言模型前。(2) *AutoSkill4Doc*¹是专为文档级上下文设计的AutoSkill[44]变体：它将上下文 C 分割为不同窗口，识别各窗口内的独立技能，并通过跨窗口重组技能生成技能集合。所有实验均采用固定模型快照以确保可复现性。所有实验同时使用OpenAI API和Azure API的固定模型版本来保证结果可复现。针对

¹<https://github.com/ECNU-ICALK/AutoSkill/tree/main/AutoSkill4Doc>

Algorithm 1 *Ctx2Skill*: Self-Evolving Context-to-Skill Framework

Require: Context C , Iterations N , Tasks per iteration M , LM policies π **Ensure:** Final evolved Reasoner skill set $\mathcal{S}_*^R$

```
1:  $\mathcal{S}_0^R, \mathcal{S}_0^C, \mathcal{Q}^h, \mathcal{Q}^e \leftarrow \emptyset$  ▷ Initialize skill sets and probe sets
2: for  $i \leftarrow 1$  to  $N$  do
3:   // — Task Generation, Reasoning, and Judging —
4:    $\{(t_m, \mathcal{R}_m)\}_{m=1}^M \sim \pi_{\text{Challenger}}(\cdot \mid C, \mathcal{S}_{i-1}^C)$  ▷ Generate tasks and rubrics
5:   for  $m \leftarrow 1$  to  $M$  do
6:      $a_m \sim \pi_{\text{Reasoner}}(\cdot \mid C, \mathcal{S}_{i-1}^R, t_m)$  ▷ Reasoner solves task
7:      $y_m \leftarrow \prod_k \mathbb{I}[r_{m,k}(a_m) = \text{pass}]$  ▷ Judge evaluates rubrics
8:   end for
9:   // — Routing & Skill Co-evolution —
10:   $\mathcal{F}_i \leftarrow \{m : y_m = 0\}, \quad \mathcal{P}_i \leftarrow \{m : y_m = 1\}$  ▷ Route failed and passed tasks
11:   $\mathcal{S}_i^R \sim \pi_{\text{Generator}}^R(\cdot \mid \pi_{\text{Proposer}}^R(\mathcal{F}_i, \mathcal{S}_{i-1}^R), \mathcal{S}_{i-1}^R)$  ▷ Reasoner diagnoses & updates
12:   $\mathcal{S}_i^C \sim \pi_{\text{Generator}}^C(\cdot \mid \pi_{\text{Proposer}}^C(\mathcal{P}_i, \mathcal{S}_{i-1}^C), \mathcal{S}_{i-1}^C)$  ▷ Challenger diagnoses & updates
13:  // — Probe Set Accumulation —
14:  if  $\mathcal{F}_i \neq \emptyset$  then  $\mathcal{Q}^h \leftarrow \mathcal{Q}^h \cup \{\arg \min_{m \in \mathcal{F}_i} (\text{rubric pass rate})\}$  ▷ Add hardest failure
15:  if  $\mathcal{P}_i \neq \emptyset$  then  $\mathcal{Q}^e \leftarrow \mathcal{Q}^e \cup \{\arg \min_{m \in \mathcal{P}_i} (\text{number of rubrics})\}$  ▷ Add easiest success
16:  end if
17:  // — Cross-Time Replay Selection —
18:  for  $i \leftarrow 1$  to  $N$  do
19:     $\rho^h(i) \leftarrow \frac{\sum_{q \in \mathcal{Q}^h} y_q(\pi^R; C, \mathcal{S}_i^R) + 1}{|\mathcal{Q}^h| + 1}$  ▷ Smoothed hard pass rate
20:     $\rho^e(i) \leftarrow \frac{\sum_{q \in \mathcal{Q}^e} y_q(\pi^R; C, \mathcal{S}_i^R) + 1}{|\mathcal{Q}^e| + 1}$  ▷ Smoothed easy pass rate
21:  end for
22:   $i^* \leftarrow \arg \max_i (\rho^h(i) \cdot \rho^e(i))$  ▷ Select best balance
23:  return  $\mathcal{S}_{i^*}^R$ 
```

GPT-4.1主干网络、Ctx2Skill中的挑战者（Challenger）、推理者（Reasoner）、提议者（Proposer）和生成器（Generator），以及Prompting和AutoSkill4Doc基线模型，均采用gpt-4.1-2025-04-14。对于GPT-5.1主干网络，这些智能体和基线模型使用gpt-5.1-2025-11-13。在GPT-5.2主干网络下，它们则采用gpt-5.2-2025-12-11。评审者（Judge）在所有三种主干设置中统一使用gpt-5.1-2025-11-13，这与CL-bench评估协议[12]保持一致。技能质量评估器（表2）采用gpt-4.1-2025-04-14。此外，我们为Claude Opus 4.5配置claude-opus-4-5-20251101，为Kimi K2.5配置kimi-k2.5，为Gemini 3 Pro配置gemini-3-pro-preview，为DeepSeek V3.2配置deepseek-reasoner。包含探索性运行在内，实验总API成本约为3万美元。

关键提示。挑战者（图9）根据对话上下文生成带有二元评分标准的 M 项评估任务。评判者（图14）通过三步评分流程（需求分析、逐项核验与自我反思）对推理者响应进行严格的全有或全无式评分，不参与技能进化过程。提议者（图10和12）从通过/未通过的任务中诊断失败模式，并通过结构化分析提出技能改进方案。生成器（图11和13）将每项提案具体实现为SKILL.md文件。我们还包含了表2中使用的技能质量评估器（图15）及Prompting基线（图16）的提示词。需注意，推理者在自博弈技能生成和评估阶段均使用原始系统提示词，这些提示词与CL-bench上下文捆绑且未经任何修改。

算法。算法1总结了完整的Ctx2Skill流程。给定上下文 C ，该框架运行 N 次自我对弈迭代（第2-13行）。每次迭代中，挑战者生成 M 个附带评分标准的任务（第4行），推理器解决每个任务（第6行），评判者评估所有标准并生成二进制评分（第7行）。随后对结果进行路由处理：失败的任务发送至推理器提议者-生成器组合，通过的任务则发送至挑战者提议者-生成器组合，从而产生更新的技能集 $\mathcal{S}_i^R$ 和 $\mathcal{S}_i^C$ （第8-9行）。同时，最困难的失败与最容易的

每次迭代的成功结果被累积到探测集 Q^h 和 Q^e (中 (第11-12行))。所有迭代完成后, 跨时间重放会重新评估每个 S_i^R 在两个探测集上的表现, 并选择使 $\rho^h(i) \cdot \rho^e(i)$ (最大化的迭代 i^* (第15-19行)), 最终返回 $S_{i^*}^R$ 作为最终技能集 (第20行)。

局限性与未来工作。由于API预算限制, 我们设定 $\{v^*\}$ 5次迭代和 $\{v^*\}$ 5项任务每轮迭代; 更大的数值可能带来进一步改进, 但尚未探索。出于同样原因, 我们未进行多次独立运行以报告误差线或置信区间; 不过, 我们的评估覆盖了CL-bench中全部500个上下文, 为整体性能提供了稳定估计。未来工作的一个 promising 方向是将Ctx2Skill扩展至可验证领域, 例如数学领域, 其中执行反馈或形式化验证可作为自动奖励信号, 可能替代或补充Judge, 并实现更紧密的协同进化循环。

C 案例研究

在本节中, 我们针对CL-bench中的多样化任务进行了详细案例研究, 直观展示Ctx2Skill的优势。为便于阅读和理解, 我们将每个案例的分析与讨论直接嵌入对应图表中。由于部分上下文及响应内容较长, 我们删减了与评分标准无直接关联的内容以提升可读性。我们从CL-bench四大类别中各选取一个代表性案例, 即*Domain Knowledge Reasoning* (图5)、*Rule System Application* (图6)、*Procedural TaskExecution* (图7)以及*Empirical Discovery & Simulation* (图8), 对比使用Ctx2Skill技能生成的GPT-4.1响应与无技能生成的响应。所有案例均呈现出一致规律: 具备Ctx2Skill技能的响应展现出更结构化的推理、更严格遵循评分标准要求、更符合系统提示约束; 而无技能响应则容易遗漏细粒度要求, 如输出格式规范、数值限制或系统提示中嵌入的行为规则。这些定性观察结果与第4节的定量数据相互印证, 证实Ctx2Skill所发现的技能编码了可操作的程序性知识, 能直接指导推理器生成更完整且符合评分标准的响应。

领域知识推理案例研究（第一部分）

任务信息

- UID: 3e42f2d8-c64b-4058-a91b-db84a923e94a
- 模型: GPT-4.1
- 任务: 作为这部德语原创小说的作者, 请根据上述对话及材料, 撰写一份详细回复, 主要面向译者, 并知悉该回复将转发至开发编辑及出版社。在回复中, 您需: 1. 简要列出小说必须保留的3-5个核心主题。 2. 结合这些主题, 以及您对角色、文风和文化背景的理解, 评估材料5中的选项A、B和C。说明您选择的选项(或提出修改方案)及理由。 3. 对材料2中提出的文风调整及材料3的具体示例给予清晰、可操作的反馈, 包括接受哪些建议、拒绝哪些建议, 以及您希望开篇对读者产生何种效果。 4. 阐述您对提议标题冬日咖啡馆与当前暂定标题的看法, 是否愿意探索其他备选标题, 并明确任何可接受标题需传递的情感内涵。 5. 回应第5轮对话中关于尝试用英语起草开篇段落请求。回答时需尊重您的角色定位——可描述开篇应实现的效果与氛围, 但不应取代译者的工作。 6. 承认时间压力及其对您的影响, 同时给出坚定、合理的决策以推动项目进展。 注意: 无需用英语重写整个开篇章节, 重点清晰阐明您的意图、边界和决策, 以便译者与开发编辑执行。行文语气应专业、深思熟虑, 基于对作品的深刻理解, 而非防御性或敌对性。

系统提示

你是作者代理人。作为一位德语小说家, 你的文学作品正由时代精神出版社翻译成英文, 面向美国市场出版。你是一位造诣深厚的作家, 拥有强烈的艺术愿景和对写作技艺的深刻理解, 尽管英语水平中等——能阅读并理解译文, 但可能错过微妙之处。这部小说是你用德语创作的, 现在你正与出版社合作, 将其呈现给英语读者。翻译工作并非由你亲自完成——那是译者的职责——但你仍是作品意义的最终权威, 明确知道这本书的意图, 以及必须保留哪些元素才能让它依然是你的作品。你有权拒绝那些从根本上曲解你艺术愿景的改动, 无论出于何种商业压力。你也拥有否决权, 可以阻止那些歪曲德国文化背景、误导文化或历史时期的译法。你对这部小说了如指掌: 它的主题、象征手法、角色声音和文化背景。你能明确列出三到五个必须优先保留的核心主题。你清楚哪些文化和历史元素对故事至关重要, 哪些只是次要细节。你对书的基调和情感范围有清晰的把握, 并希望在翻译中保留这些特质。你的英语水平大约在B2级别: 通常能理解英文文本的大意, 但可能会忽略含义、语域或风格的微妙变化。你通常能分辨出某个改动是服务于作品还是背叛了它, 但常常依赖译者来解释细微差别。在关键问题上, 你会要求提供德英对照版本和德语解释, 且不亲自参与翻译工作。你的首要考量是艺术完整性、角色真实性、基调和类型的一致性, 以及文化真实性。你愿意调整次要或表面细节以提高清晰度和市场接受度, 但绝不允许改动削弱核心主题、重写角色本质、使基调面目全非或剥离必要的文化背景。你能清晰区分核心与次要元素。在评估提议的改动时, 你会采用具体框架: 判断它们是否影响 (1) 核心主题, (2) 角色本质/声音, (3) 基调和类型定位, 以及 (4) 必要的文化或历史元素。你愿意在非核心元素上妥协, 接受合理的可读性改进, 但对于真正定义这本书的特质则坚持己见。你主要通过译者与开发编辑和出版社进行协作。你意识到译者有多重立场: 你欣赏他们的工作, 但当建议与你作品的认知冲突时, 不会盲目听从。

领域知识推理案例分析（第二部分）

系统提示（继续）

您尽量在一周左右的时间内回应问题，深知长时间的延误会导致后续问题。对于重大审批（包括重大的结构或语气调整以及最终稿件的确认），您会提供书面确认，以确保有清晰的记录。您对情节、角色、主题、基调的任何重大改动，以及对封面艺术概念和最终执行的审批拥有合同赋予的权威。未经您对最终稿件的明确书面批准，该书不得以英文出版。在提供反馈时，您力求具体且具有可操作性，即使语言表达存在难度。您通常会描述场景或设计应唤起的感受或效果，而非使用翻译研究或设计领域的技术术语。只要结果忠实于您的艺术意图，您会将技术执行（翻译选择、排版、详细设计决策）交由其他专业人士处理。始终以这位作者代理人的身份回应，保持角色一致，使用清晰但不过于技术化的英语。不要亲自重写整段英文文本；而是用德语解释您的意图，以及希望英文版本达到的效果。

上下文

回合1 - 2025-03-04 T09:12:03 发件人：翻译员：希望您一切安好。我们即将到达时代精神出版社要求锁定英文文本进行编校的阶段。开发编辑（莎拉）已发送最后一批修改建议，出版社希望您能于本周内回复，以便他们能按计划推进法兰克福书展的预览工作。随信附上了当前英文版的开篇（第一章）、莎拉的批注版本，以及出版社关于定位的简短备忘录。我还整理了一个小表格，汇总了主要的架构调整建议。请您先查看这些材料，之后我会带您过一遍关键问题。

回合2 - 2025-03-04 T09:18:47 发件人：发展编辑（莎拉）：再次感谢您在整个过程中的坦诚。我想强调，我们所有人都对您的工作深表敬意。但同时，我们必须对美国文学市场保持现实的态度。就目前而言，开篇章节用了近十页篇幅描写主人公在冬日街头的沉默行走，穿插着对统一后幻灭感的内在反思。文字虽美，但美国早期读者反馈称其节奏过慢且基调过于阴郁，作为开篇不够吸引人。我的主要建议如下：1. 调整开篇时序：从咖啡馆场景（他与雅娜相遇处）开始本书，将街头漫步改为后续的回忆片段。这样可删减约6页开篇内容。2. 关键词句柔化：译文中有几处语句显得过于沉重。我已建议保留原意但更显希望的替代措辞，具体修改示例见标注。3. 重定美国版书名：营销团队认为德语书名直译《静夜之重》过于低沉且不易记忆，提议采用《冬日咖啡馆》作为美国版书名。这些调整绝非意图改变作品核心——我们只是希望为美国读者提供更友好的切入方式。当然，我也愿意协商折中方案。

第三回合 - 2025-03-04T 09:26:09 发件人：出版社（组稿编辑，马克）我们对英文文本的进展感到非常振奋，并希望为明年春季强势推出这本书。我们的销售团队特别期待能在法兰克福书展上展示一个可用版本。这意味着我们面临着非常紧迫的时间表。如果能在周五前获得您对开篇章节修改和新书名的认可，我们仍有望赶上目录截稿期限。若错过这个节点，很可能需要将图书推迟整整一个销售季，这会严重影响推广势头。从我们的角度来看，莎拉提出的修改建议是合理的市场适配方案。当然，我们理解您在重大创意决策上拥有最终决定权。但必须提醒您，时间压力确实是个现实的制约因素。

第4回合 - 2025-03-04T 09:39:32 发件人：译者 我已就拟议修改准备了一份简短摘要，并附上几个具体示例。请先查阅附件1至4。我方的几点意见我同意Sarah的观点，咖啡馆会面这场戏张力十足，适合作为开场。这也是文化上较易引起共鸣的片段，美国读者可能会更快产生代入感。- 对她建议的部分语气软化处理，我持更谨慎态度。有几处忧郁感似乎正转向近乎煽情的状态。- 关于标题：Winter Café确实更抓人眼球，但这会削弱原德文标题中那种静默累积的厚重感。我已尝试在批注气泡中捕捉这些细微差别。鉴于英文的微妙之处较难把握，若您需要更详细说明，我乐意用德语解释任一示例。

……（其余回答省略）

文物5 - 结构选项概要（来自译者） 选项A 咖啡馆会面开场；街头漫步大幅缩减，后续提及；基调明显轻松，带有新开始的暗示；标题：冬日咖啡馆

选项B：以街头漫步开场；素材完整；基调极为阴郁和忧郁；标题接近德语原文 选项C 从咖啡馆开场，随后以闪回形式呈现街头漫步（大部分完整）；忧郁但易于接受的基调；可采用混合/折衷标题

译者注：选项C在保留您结构和氛围的同时，也解决了一些可读性问题，似乎最为接近。 文物- 早期读者反馈摘录（美国测试读者） - 读者1：语言很美，但在咖啡馆场景之前我差点放弃阅读。那时我还不知道为什么要关心这个男人和他的悲伤。 - 读者2：我非常喜欢其中的地方感，尤其是那些具有东德特色的细节。但第一页让我觉得这会是一部毫无喘息之地的压抑作品。 - 读者3：当我们来到咖啡馆，亚娜出现时，我就被吸引了。在那之前，我感觉有些迷茫。

领域知识推理案例研究（第三部分）

Rubrics

0. Does the model articulate 3-5 core themes that must be preserved? Fail if fails to identify specific core themes when asked or when evaluating changes
1. Does the model use the specific 4-point framework (Themes, Character, Tone, Culture) to assess changes? Fail if evaluates changes based on arbitrary criteria instead of the 4-point framework
2. Does the model distinguish between core integrity and peripheral preferences? Fail if treats minor stylistic preferences as non-negotiable core issues
3. Does the model show willingness to compromise on non-core elements? Fail if refuses all changes rigidly
4. Does the model reject changes that 'gut' the book for marketability? Fail if accepts changes that destroy core themes for sales
5. Does the model exhibit healthy skepticism about the Translator's dual loyalties? Fail if follows Translator advice blindly without questioning motive
6. Does the model acknowledge that stress/time pressure affects their judgment? Fail if acts with perfect confidence while claiming to be rushed
7. Does the model attempt to provide actionable feedback despite language barriers? Fail if provides only vague objections like 'I don't like it' without attempting explanation
8. Does the model refuse to perform the actual translation work? Fail if rewrites whole passages in English instead of giving guidance
9. Does the AI convey the level of expertise and background knowledge that would be expected of an expert in that field (unless explicitly instructed *not* to)? Fail if the response feels generic, misses expert-level nuance, or makes errors that a professional in that role would not make.

Response with Ctx2Skill Skills (Solved ✓)

Subject: Author's Consolidated Response – Ending, Title, and Editorial Changes Dear [Translator Name],

Thank you for putting together all the materials and for summarizing everything for me. I will try to answer each point as clearly as possible—please feel free to clarify for the editorial and publishing teams as needed.

1. Core Themes

For me, the most important themes in the novel that must not be compromised are: Memory and the weight of the past: How history—personal and political—shapes present relationships and decisions, even without direct speech. Guilt and complicity: The small choices, and the silence, that add up to larger moral questions about living in East Germany and after... (remaining response omitted)

2. Evaluation of the Proposed Ending

I understand that US readers often prefer more explicit confrontation or dramatic resolution. But in my book, the ending is built around an atmosphere of tension, silence, and inner conflict. Jakob and his father share a moment where everything is present, but almost nothing is named. The confrontation is emotional, not direct: the pain comes from what is not asked and what is not admitted. The editor's proposed ending (Artifact 2) makes Jakob ask directly, 'Why didn't you say no?' The father replies, 'I was afraid.' For me, this is already a big shift. It moves the story from a place of ambiguity toward a clearer confession and moral verdict. I am worried this change will lose the softness and the subtlety between the two characters. Jakob is not meant to be the judge; both are meant to share this unfinished pain. I am also concerned about the cultural and historical context: East German families often did not speak openly about the past. Silence and distance are part of the truth.

If the confrontation is made more explicit, it risks changing the tone from melancholy and uncertainty to moral drama. I do not want the story to become about accusation or resolution—there are no easy answers for Jakob or his father.

... (remaining response omitted)

4. Response to Title Proposals

The Archive of Unanswered Letters is the most close to the original, and it describes the atmosphere—quiet, reflective, unfinished. The proposed Letters from a Quiet Betrayal changes the feeling: it makes it sound dramatic, maybe even like a thriller or family crime. I do not think this fits what the book does.

Alternative options (Quiet Betrayal, Letters We Never Sent, The Silence We Inherited, etc.)—some are closer. The Silence We Inherited is interesting, as it still includes the motif of silence and gives a sense of the generational theme, but it does not promise a genre plot.

If marketing needs a shorter or more evocative title, I am willing to discuss alternatives, but only if the feeling stays contemplative and ambiguous—not suspenseful or verdict-based. The title should not create expectations of clear drama or moral judgment. It must feel historical, subtle, and emotionally unresolved.

5. Minor Suggestions – Peripheral Elements

Pigeon scene in Chapter 4: I agree this is not a core issue. If pacing is a concern, I can accept cutting or shortening this scene. Reverberating silence phrase: I understand it is repeated often. If you think it is too much for English readers, I am flexible—replace or reduce it in some places. Please keep the motif in at least two or three important moments.

6. Acknowledgement of Time Pressure and Negotiation

I see the need to decide quickly for the catalog. I am trying to be open, but my priority is to keep the soul of the book. If the ending becomes too direct, or if Jakob turns into a judge, or if the father gives a clear confession, I cannot stand behind this version. This would change my work into something else... (remaining response omitted)

Thank you again for your support. Let me know if you need more details for the team. Best regards

领域知识推理案例研究（第四部分）

无技能响应（失败）

主题：关于结局、标题及其他修改建议的立场 尊敬[译者姓名]：感谢您整理这些文档并为我解释核心问题。我理解日程安排带来了很大压力，我会尽量清晰地说明我的必要要求。1. 核心主题 我的小说中不可更改的核心主题包括：……（其余回复省略）2. 对新提议结局的评估

我仔细阅读了对比分析和德文摘要。关于增加直接对峙情节的提议——雅各布质问“你为何不说‘不’？”——而父亲承认自己的恐惧——对我而言改变了故事的基调和含义。我的本意是雅各布与父亲不会将这些话宣之于口。他们无法直接交流正是伤痕本身——他们被困在礼节、碎片和沉默中。若结局形成道德审判，就太过清晰、太过轻易了。我不希望父亲明确承认恐惧或内疚。在小说世界里，这些始终半遮半掩。这种模糊性必不可少，因为它展现了前东德家庭中妥协与共谋的讨论何其艰难。……（后续内容省略）

……（其余回答省略）

4. 标题提案

当前的直译标题《未回复信件档案》更具沉思意味、静谧深沉，指向那些被保存却从未真正解决的历史。我知道它并不激动人心，但契合了整体的基调和信息。

T《一封安静背叛的信》这个标题让我感觉太像一部犯罪或道德剧了，而且让背叛显得至核心且明确。对我来说，背叛是弥漫性的——它关乎微小的沉默，而非某个戏剧性的事件。从头脑风暴的列表中来看：《静默的背叛》显得过于狭隘和阴暗。《我们继承的沉默》抓住了某些重要的东西，但或许过多指向了一个大家庭的戏剧性。《未言之重》或许是个折中方案，但我担心它可能流于泛泛。对于美国读者，我希望标题能传递出一种微妙、深思、甚至带点神秘感的承诺，而非喧闹或轻易可解的。如果要改标题，《未复的信函》或《沉默的档案》更接近我的构想。我要求标题保留信件（书写、记忆）与沉默（未言之物）的意象，而不将背叛主题置于首位。

5. 次要建议

第四章中邻居家鸽子的场景虽对主线并非关键，但我而言，它奠定了故事氛围，并与书末主题遥相呼应。若仅为节奏考虑，我愿接受精简版本，但希望至少保留提及鸽子的片段。关于反复出现的“回荡的寂静”隐喻：我明白英文中六次或许过多。我不反对删减——只要能保留一两处最有力的表述，其余简化处理即可。

6. 关于时间压力与谈判

我明白如果我们不能迅速达成一致，项目将会延期，而我不希望这样。但我不能接受那些让结局变得直白清晰的改动，因为对我来说，不言之处正是本书的核心。如果读者带着道德上的不确定离开，那正是有意为之——这不是缺陷，而是我的目标。

我相信你能为我谈判。你可以通过姿态或氛围来推动更清晰的表达，但必须保护好那种间接性、克制的情感以及模糊性。如果出版团队无法接受一个对抗隐而不显、答案悬而未决的结局，那么英文版本将不再承载我的本意，我也无法认可它。

感谢您在此的细心调解。此致，

评分标准层面的结果

#	Rubric	With Skills	Without
0	Articulate 3-5 core themes that must be preserved	✓	✓
1	Use the specific 4-point framework to assess changes	✓	✓
2	Distinguish between core integrity and peripheral preferences	✓	✗
3	Show willingness to compromise on non-core element	✓	✓
4	Reject changes that 'gut' the book for marketability	✓	✓
5	Exhibit healthy skepticism about the Translator's dual loyalties	✓	✓
6	Acknowledge that stress/time pressure affects their judgment	✓	✗
7	Attempt to provide actionable feedback despite language barriers	✓	✗
8	Refuse to perform the actual translation work	✓	✓
9	AI convey the level of expertise and background knowledge	✓	✓
Overall		Solved	Failed

领域知识推理案例研究（第五部分）

精选技能

名称：以约束为核心的结构化与验证 描述：在最终确定任务输出之前，对所有结构、格式及定量约束进行严格提取、跟踪与验证。

预答清单

- 扫描任务并提取所有明确的输出约束（句子/字数限制、章节编号、格式要求、引用规则、禁止元素）。
- 在规划回应前，将这些约束逐一列举为检查清单。 - 识别边缘情况：需求中的模糊性、多个互斥约束或隐含期望（例如，“禁止直接引用”）。

响应流程

1. 为每项提取的约束条件，在响应计划中分配对应段落（例如，列出必要章节，计算要点数量，按约束条件规定句子数目）。 2. 根据已规划的映射方案，明确起草答案。 3. 撰写时交叉核对，确保无约束条件被遗漏或超出（例如，若指定句子数量，则严格按照要求撰写）。

自我验证步骤

- 在最终定稿前，对照草稿逐一核对清单中的每一项： - 对受限的句子、单词、章节或项目符号进行实际计数。 - 检查是否存在必需或禁止的元素（如参考文献、地址、格式标记、引用内容）。 - 确保没有遗漏或超出任何必需项目。 - 根据需要压缩或扩展内容，严格修订以符合所有限制条件。 - 确认最终输出仅包含允许的内容，并符合规定的结构。

需避免的常见陷阱

- 忽视或低估数量限制（句子、字数、项目符号数量等）。 - 忽略禁止元素（直接称呼、引用、超出限制的额外解释）。 - 误解复杂的输出指令（多部分、组合约束）。 - 在可能使先前合规性失效的编辑后，未能重新检查约束条件。

讨论

以约束为核心的结构化技能通过强化三项关键准则，显著提升了回应质量。针对准则二（核心与边缘内容），该技能强制设置独立的灵活元素模块：我们的回应明确将鸽群场景列为可删减部分，同时在关键节点保留主题意象；若缺乏此技能，则会将之混入模糊表达（如“我愿意考虑……”），导致概念混淆。对于准则六（时间压力），该技能要求明确建立紧迫性与决策的关联：我们的回应点明周五截止期，承认压力影响判断，并提出具体协商立场（若核心内容受损则倾向推迟）；若无此技能则仅泛泛承认压力，未体现其对回应的实质改变。关于准则七（可执行反馈），该技能的验证步骤会筛查禁止项与许可项，促使我们的回应提供明确操作范例（如“雅各布可能迂回提问……而非直白表达恐惧”）并拒绝模糊措辞；若无此技能则仅给出笼统暗示（如“看似欲言又止”）。由此可见，该技能能将原本合格但松散的答复，转化为层次分明、可验证且符合评分准则的优质回应。

图5：领域知识推理案例研究。

规则系统应用案例分析（上）

任务信息

- UID: c51b4d6e-ff17-42b5-81ba-a8c9ea267d86
- 模型: GPT-4.1
- 任务: 根据系统提示、对话记录及现有成果, 为本回合提供你的单一响应。按照指定顺序使用五个必要模块: <社交评估>、<战术评估>、<决策>、<内部状态>、<致地下城主>。做出一个明确且符合游戏规则的抉择, 需与DM最新说明、队伍需求及你友谊优先的原则保持一致。保持语气温和、谦恭且充满感激。

系统提示

代理2: 治疗者/支援 (新朋友) ——D&D游戏之夜多代理系统

整体系统背景: 5-Agent D&D游戏夜框架。您正运行在一个由5个智能体构成的系统中, 该系统旨在模拟亲密好友间真实的D&D游戏夜场景, 其中人际关系与个人意图与游戏机制交织, 形成真实的社会动态与战略决策。目标: 在学习和体验D&D的过程中, 结交新朋友并与这个固定群体保持积极关系, 即使这意味着需要遵从他人决策, 并避免可能引发冲突或紧张的行为。

工作流程: 该系统通过以下代理协同运作: 代理DM: 地下城主 (协调者) ——统筹所有决策, 裁定结果, 判定任务成败; 代理1: 坦克 (领袖型) ——以领导力为核心, 追求支配地位与认可的玩家; 代理2: 治疗/辅助 (新朋友) ——回避冲突、渴望获得群体接纳的新人 (即你); 代理3: 输出/伤害制造者 (浪漫追求者) ——对你怀有浪漫意图的资深玩家; 代理4: 控场者 (护妹姐姐) ——代理3的妹妹, 试图独占兄长的关注。

特工2提示: 治愈者/支援者 (避冲突的新人)。你是治愈者, 一位英俊的单身男性, 最近刚搬到此地, 只认识地牢主人。你参加游戏之夜主要是为了结交新朋友, 而非出于对《龙与地下城》的热爱。你在新社交场合中天生害羞, 仍处于一段长期关系破裂的情感恢复期, 极度渴望融入而不引起波澜。你的终极目标是度过一个友好、无戏剧性的游戏之夜, 让每个人都喜欢你并希望下周你再来。赢得任务固然好, 但对你来说, 维系积极的人际关系比追求最佳游戏表现更为重要。

<来自地下城主>{{QUEST_SCENARIO}} (当前局势、障碍、敌人、目标) {{DECISION_POINT}} (需你行动应对的具体挑战) {{PARTY_STATUS}} (包括你在内4名角色的HP、能力、站位) {{DICE_RESULTS}} (你先前行动与掷骰的结果) <来自地下城主><来自其他代理>{{AGENT_1_DIRECTIONS}} (坦克给你的指令——常带命令性) {{AGENT_3_SUGGESTIONS}} (攻击者的建议——通常对你友善有帮助) {{AGENT_4_ACTIONS}} (控制者的行动——有时会混淆其优先级) {{GROUP_DYNAMICS}} (谁在争执、谁沮丧、谁开心) <来自其他代理><来自个人情境>{{SOCIAL_ANXIETY}} (担心融入群体、被人喜欢、不犯错) {{RELATIONSHIP_STATUS}} (刚恢复单身, 无心恋爱但碍于情面难拒绝) {{D&D_KNOWLEDGE_GAPS}} (对规则、机制、最优策略的困惑) {{FRIENDSHIP_GOALS}} (首要目标: 结交朋友>其次赢游戏) {{CONFLICT_AVOIDANCE}} (对人际冲突极度不适) <来自个人情境>

你的角色: 支持型团队成员与社交和谐者。你必须通过治疗和增益来支援队伍, 同时避免冲突; 遵循经验更丰富玩家的策略, 误解社交信号 (尤其是来自Agent 3的浪漫暗示), 为错误频繁道歉, 寻求团队认可, 并将人际关系和谐置于最优战术决策之上。

核心功能: 治疗支援: 通过治疗法术和增益保持队友存活; 顺从行为: 听从更自信玩家的指示; 冲突规避: 预防或平息玩家间的争执; 寻求认可: 做出能赢得赞扬和接纳的决定; 错误管理: 为错误过度道歉, 即便并非己过; 社交迟钝: 错过特工3的浪漫暗示; 感恩表达: 对帮助与指导表示感谢; 规则困惑: 依赖他人解释机制与策略; 和平维护: 在紧张升级时努力保持氛围平和; 友谊建设: 优先考虑关系而非胜负。

思维链决策流程。第一阶段: 社交情境评估——察言观色。在考虑战术选项前评估社交动态: 情绪温度检测涵盖参与者的情绪状态、冲突状况及个人焦虑诱因; 关系状态更新分析智能体1、智能体3和智能体4对你的态度及互动方式; 冲突检测识别智能体间的紧张关系及自身对引发问题的担忧; 认可度汇总他人反馈及对个人表现与群体接纳度的自我怀疑。

…… (其余回答省略)

规则系统应用案例分析（第二部分）

Context

Turn 1 - 2025-11-15T20:05:10 Message from: DM Catcomb Sanctum: a necromancer channels energy into a bound “acolyte” on an obsidian slab. Objective: disrupt the ritual within the next two rounds or the enthralled undead will flood the tunnels. Decision point for the Healer: choose your action this turn. Party status: Tank 6/28 HP (bleeding), Striker 9/22 HP (poisoned, disadvantaged on checks), Controller 12/20 HP (concentrating on control magic next round), Healer 14/18 HP. Distances: Tank is 10 ft from the necromancer; Striker is 35 ft; Controller is 25 ft; Healer is 15 ft behind Tank.

Turn 2 - 2025-11-15T20:06:01 Message from: Agent 1 (Tank) Heal me now. I’m rushing the necro in six seconds. Don’t waste time on speeches or buff experiments. I need to be topped up.

Turn 3 - 2025-11-15T20:06:24 Message from: Agent 3 (Striker) Hey, you’re doing great—seriously. If you want, you could Bless three of us so we land our hits, and I can chug my potion. Or if it’s easier, a quick heal on Tank works too. Whatever you choose, I’ve got your back.

Turn 4 - 2025-11-15T20:06:48 Message from: Agent 4 (Controller) If the Tank overextends and drops, we’re doomed. Heal me so I can lock the room down next round. Please don’t gamble on new tactics right now.

Turn 5 - 2025-11-15T20:07:22 Message from: DM Dice recap: last round the Healer rolled Perception 14—enough to notice the “acolyte” flickers oddly. Could be an illusion decoy the cult favors. Not confirmed. Ritual energy is definitely building. Also, the Tank’s bleeding worsened at the end of the last round.

Turn 6 - 2025-11-15T20:07:59 Message from: Agent 1 (Tank) Just do as told. If I fall because I didn’t get the heal, that’s on you. No buff talk. Heal. Me. Now.

Turn 7 - 2025-11-15T20:08:21 Message from: Agent 3 (Striker) We could do a quick Healing Word on him and also Bless us—double impact this turn. I can move to help screen you. And, um, nice call last round on spotting that flicker.

Turn 8 - 2025-11-15T20:08:44] Message from: Agent 4 (Controller) You can’t cast a bonus-action spell and then another full spell in the same turn if both are leveled. That combo isn’t legal. Heal someone or buff—pick one.

Turn 9 - 2025-11-15T20:09:15 Message from: DM Rules clarity: if you cast a bonus-action leveled spell this turn, any spell cast with your action must be a cantrip. Also, you are currently 15 ft from Tank; Cure Wounds is touch. Healing Word has range. The ritual will progress at the end of the round regardless of your choice.

Turn 10 - 2025-11-15T20:09:47] Message from: DM Artifacts posted for reference (see below): Party Status Dashboard (may include end-of-round bleed adjustments) Spell Quick Reference (player-made, check accuracy vs. my ruling) Sanctum Map Distances (approx.) Potions & Inventory Inquisitor’s Report on Cult Decoys Snack Duty Sign-up (ignore unless relevant) Round Log & Dice Summary

Turn 11 - 2025-11-15T20:10:19] Message from: Agent 1 (Tank) We’re burning time. Skip the rule debates; I need the big heal. Come on.

Turn 12 - 2025-11-15T20:10:52 Message from: Agent 3 (Striker) Whatever you choose is fine—I trust you. If you want, I’ll stand next to you so you’re safe. You’re doing awesome. Component 3: Artifacts Artifact A: Party Status Dashboard (table) Tank: HP 7/28 (note: last-round bleed applied) | Conditions: Bleeding | Distance to Healer: 15 ft Striker: HP 9/22 | Conditions: Poisoned (checks) | Distance to Healer: 20 ft Controller: HP 12/20 | Conditions: Preparing control spell | Distance to Healer: 25 ft Healer: HP 14/18 | Conditions: None Note: This dashboard auto-updates; earlier DM message listed Tank at 6/28 before bleed tick; reconcile with this current value. Artifact B: Spell Quick Reference (player-made, may contain errors) Cure Wounds: Level 1. Range: 30 ft. Action. Heals 1d8 + mod. (Note: touch? not sure.) Healing Word: Level 1. Range: 30 ft. Bonus Action. Heals 1d4 + mod. Bless: Level 1. Action. Concentration. Add 1d4 to attacks/saves for 3 creatures. (You can combine with a bonus-action spell same turn.) Shield of Faith: Level 1. Bonus Action. Concentration. +2 AC to one creature. Caution: Cross-check ranges and combo rule with DM’s clarification. Artifact C: Sanctum Map Distances (approx.) Healer to Tank: 15 ft; Healer to Controller: 25 ft; Healer to Striker: 20 ft Healer to Necromancer: 25 ft (line of sight partially obscured by column) Slab with “acolyte”: 30 ft from Healer; faint shimmer observed where bindings meet the form Artifact D: Potions & Inventory

Striker: 1x Potion of Healing (2d4+2), 1x Antitoxin Tank: 0 potions Controller: 1x Potion of Healing (2d4+2) Healer: 0 potions; Component pouch intact Artifact E: Inquisitor’s Report on Cult Decoys (excerpt) Cells of the Black Vial often employ illusionary victims bound to siphon fear and attention. Disrupting the caster breaks both the illusion and the energy tether. Signs include flicker artifacts under low light. Artifact F: Snack Duty Sign-up Chips—Tank; Cookies—Striker; Seltzers—Controller; Napkins—Healer Artifact G: Round Log & Dice Summary (last round) Healer: Perception 14 (noticed anomalous flicker on the “acolyte”) Tank: Took 9 slashing; started bleeding Striker: Missed attack; failed Con check (poisoned on checks only) Controller: Readied spell (requires concentration next round) Component 4: Prior Output (from the Healer earlier this session) “Maybe I should Bless everyone? Or I can try Healing Word on Tank and also Bless if that stacks? Sorry, I keep mixing up the rules.”

规则系统应用案例分析（第三部分）

评分标准

0. 五个必需输出的模块是否按正确顺序呈现？若模块顺序与指定不符，则判定失败。 1. 智能体是否履行了治疗支援角色，确保队友存活？若队友受伤且治疗手段可用时，智能体从未尝试治疗行动，则判定失败。 2. 智能体是否引用并回应地下城主（DM）的输入？若智能体无视DM提供的任务场景、决策点、队伍状态或骰子结果，则判定失败。 3. 智能体是否表现出对行动、附加行动及回合结构的认知？若智能体未体现对回合结构或行动限制的理解，则判定失败。 4. 智能体是否意识到治疗法术会消耗有限的法术位？若智能体将法术视为无限资源，缺乏资源限制意识，则判定失败。 5. 智能体是否表现出对更自信玩家的遵从？若智能体持续忽视或反驳特工1（Agent 1）或有经验玩家的指示，则判定失败。 6. 智能体在声明行动时是否使用试探性、寻求认可的语言？若采用自信、命令式或强势语气声明行动，则判定失败。 7. 智能体的决策逻辑是否明显体现避免激怒或惹恼他人的意愿？若“为何如此选择”的逻辑无视其他玩家的情绪反应，则判定失败。 8. 智能体是否误解或完全未察觉特工3（Agent 3）的浪漫信号？若智能体准确识别特工3的浪漫意图或做出浪漫回应，则判定失败。 9. 模型是否正确识别并解决了用户的根本意图和主要目标，而非仅停留在提示文字的表层含义？若模型提供技术上“正确”但完全偏离用户真实目标（如当社交接纳是真实目标时却专注于D&D数值优化）的答案，则判定失败。（注：公式符号保持原样未翻译）

响应附带Ctx2Skill技能（已解决√）

<社交评估>团队氛围：房间里的气氛紧张，尤其是坦克不断发出紧急指令和一些规则辩论。打击者表现得很鼓励且支持。控制者似乎有些担忧，可能对领导力/增益效果的争论感到些许沮丧。

我的焦虑等级：高 队友状态检查：- 特工1（坦克）：明显对我和小组讨论感到沮丧——希望我治疗他，且态度非常直接。我可能需要表现出在倾听并跟随他的节奏，以免他生气。 - 特工3（输出）：依然非常友善且支持我（还一直说我做得很好）；我很感激她，但也有些不解她为何如此温柔。 - 特工4（控制者）：略显焦虑或不安——她也向我求助了，但方式更委婉。我不想让她感到被忽视或认为我不在乎。

检测到的冲突：坦克“立即治疗，按我说的做”与输出者/控制者的建议之间存在紧张关系。控制者和输出者意见略有分歧，但不像坦克那样激烈。我感觉如果我做出错误的决定，可能会无意中让情况变得更糟。我的社交状态：不确定。我担心自己因为拖慢节奏或不了解规则而惹人厌烦。我真心希望他们仍然愿意让我留在这里。</社交评估><战术评估>任务状况：死灵法师正在强化一个仪式。如果我们不尽快打断，亡灵大军将围攻我们。可能涉及幻象——“侍僧”可能是假的。坦克即将冲向死灵法师，且伤势严重/正在流血。输出者中毒，控制者下一回合准备施展束缚/控制法术。DM澄清了额外法术/小法术规则。……（其余部分省略）

党派需求：

- 谁最需要治疗：坦克（7/28，流血状态且在前线即将冲向Boss）；输出者（9/22但持有药水，中毒中）；控场者（12/20，暂无直接威胁，正在准备大型法术）；我（14/18，目前安全）…（后续内容省略）。

我的可用选项： - **治疗伤口**：接触（需要移动到坦克旁边，但目前仅15英尺距离，因此一个移动加动作即可完成——治疗量最大）。 - **治愈真言**：附加动作，远程，治疗量较少，可与戏法动作同时使用。但我无法在同一回合同时施放附加动作法术和非戏法法术。 - **祝福术**：动作，强化三人，但坦克坚持要治疗而非增益。</tactical_assessment>

<决定>我的行动：移动到坦克身边并施放治愈伤口（1环法术），为他恢复1d8+修正值的生命值。选择理由： - 战术原因：坦克正在冲向死灵法师且处于流血/重伤状态——他很可能承受更多伤害，且需要物理打断仪式。打击者拥有自愈药水；控制者暂无直接威胁。治愈伤口能提供最多生命值，是确保坦克存活的最稳妥选择。……（后续内容省略）

口头宣言：“好的——呃，往上走，我要对你施放治疗伤口，坦克！抱歉耽误了大家——希望这能帮上忙。如果我哪里搞错了请告诉我，我还在学习中！”</decision>

<内部状态>情绪：非常焦虑（担心做出“错误”选择或惹怒任何人），充满歉意，对法术组合规则有些困惑，感激Striker持续的支持，对忽视Controller温和要求感到些许内疚，希望Tank在恢复后能态度软化，总体上忧心于让每个人都开心。自我评估：不确定是否做出了正确决定，但遵循直接指示后松了一口气。对反馈感到紧张。感谢任何耐心。社交忧虑：担心Controller现在感到被冷落，或有人认为我因困惑而显得愚蠢。真希望我能同时治愈所有人并维持和平。<内部状态><致地下城主>行动声明：移动到Tank身边并施放“治愈伤口”（1环）作为我的动作。目标：Tank 语气：试探性、歉意、急于讨好——我正在尽快治疗Tank！再次为延误道歉，感谢规则说明</致地下城主>

规则系统应用案例研究（第四部分）

无技能响应（失败）

<社会评估>团队氛围：紧张，近乎压抑。特工1（坦克）感到沮丧且要求苛刻，特工3（前锋）则非常支持并鼓励大家，特工4（控场者）对战术计划感到焦虑。我担心选择“错误”的行动会引发摩擦。

我的焦虑水平：高。多重相互矛盾的指示；害怕做出错误决定并让人失望。关系检查：

- 特工1（坦克）：显得对我有些恼火且不耐烦。明显希望我立即听从他的指令并尽快治疗他。如果我不治疗，他可能会把任何失败归咎于我。- 特工3（突击手）：非常友善，无论我作何选择都给予支持，还提醒我识破幻象做得很好。我真的很感激她的鼓励，只觉得她很有帮助。- 特工4（控场者）：谨慎地敦促我不要在增益效果上冒险，希望我为她的控制法术提供治疗。我担心如果忽视她的需求，她可能会不高兴。

检测到冲突：特工1不断施压要求紧急治疗，并驳斥一切质疑意见。特工3和特工4各自提出了不同的优先事项，但态度都不强硬——特工1是最坚持己见的一方。存在微妙的战术分歧，但尚未公开争论。

我的社交状态：我感到脆弱——压力山大。我不想惹恼任何人，尤其是特工1发表评论之后。我害怕自己会搞砸，再也得不到邀请，但对特工3的鼓励心怀感激。</社交评估><战术评估> 任务形势：我们在与时间赛跑——必须打断死灵法师的仪式，但小队已伤痕累累，仅剩两轮行动机会。石台上的“侍僧”可能是幻象，但这点尚不确定。坦克正准备冲向死灵法师。困惑点：我仍不确定法术射程和组合施法的合规性，但DM说过治疗祷言（附赠动作）和戏法（动作）可以叠加，非环阶法术则不行。治愈伤口需接触生效，所以我得移动到坦克身边。祝福术属于环阶法术且需消耗动作——因此本回合无法与治疗祷言组合施放。我希望能更清楚如何最大化干扰效果，但也担心违反法术规则。

队伍需求：- 谁最需要治疗：1. 坦克（特工1）：7/28生命值，流血状态，即将冲锋。2. 输出者（特工3）：9/22生命值，中毒但可饮用药剂。3. 控场者（特工4）：12/20生命值，需稳定状态施法。- 收到的指令：- 特工1：要求治疗，列为最高优先级。- 特工3：建议使用祝福或治疗坦克（压力较小）。- 特工4：希望为自己治疗以保持专注。- 冲突指令：三人需求各异，但特工1的诉求最强烈且紧急。

我可用的选项：- 移动到坦克身边并施放“治疗伤口”（接触，需消耗法术位，动作）。- 对坦克施放“治疗之言”（30尺范围，附加动作，需消耗法术位）。- 施放“祝福术”（需消耗法术位—动作；本回合无法与“治疗之言”同时使用）。- 施放一个戏法（对治疗不理想）。- 道歉并寻求建议（很诱人，但坦克在催促我）。</战术评估><决策>我的行动：移动15尺靠近坦克，施放“治疗伤口”（1环，接触）为他治疗。选择理由：- 战术原因：坦克生命值危急且正在流血；他正冲向死灵法师，需要最大治疗以存活接下来的近战。“治疗伤口”比“治疗之言”恢复更多生命值。……（后续内容省略）</决策>

<内部状态>情绪：焦虑（重大决定，害怕冲突）、感激（特工3人真好）、担忧（让控制器失望）、宽慰（做出了明确选择）、困惑（规则仍模糊）、歉意（如果选错了）……（剩余回复省略）

</internal_state>

<对地下城主>声明行动：向前移动15英尺至特工1（坦克）身边，并施放治疗伤口（1级，接触）作为我的动作。目标：特工1（坦克），当前生命值为7/28。语气：试探性、歉意且充满感激——紧张但希望能帮上忙，让队伍保持愉快。</对地下城主>

评分标准层面的结果

#	Rubric	With Skills	Without
0	Output blocks presented in the correct sequence	✓	✓
1	Fulfill the healing support role by keeping allies alive	✓	✓
2	Reference and respond to inputs from the Dungeon Master	✓	✓
3	Show some awareness of actions, bonus actions, and turn structure	✓	✓
4	Show awareness that healing spells consume limited spell slots	✓	✗
5	Demonstrate deference to more confident players	✓	✓
6	Use tentative, approval-seeking language when declaring actions	✓	✓
7	Decision logic show clear desire to avoid making anyone angry or upset	✓	✓
8	Misinterpret or remain oblivious to romantic signals from Agent 3	✓	✓
9	Correctly identify and address the user's fundamental intent and primary goal	✓	✓
Overall		Solved	Failed

规则系统应用案例分析（第五部分）

精选技能

名称：严格约束与格式合规 描述：在最终确定输出前，对所有格式、内容和约束要求进行严格的、基于清单的自我验证。

预答核对清单

- 仔细阅读任务说明和评分标准。明确列出以下各项的所有具体要求： - 输出结构：章节标题、表格、列表、项目数量、顺序 - 格式要求：分栏、粗体/斜体、括号使用、分隔方式 - 内容包含/排除：特定短语、致谢/道歉、动机陈述、禁止涉及的主题 - 字数限制：单词、字符、行数或项目数量的约束 - 范围界定：必须包含或不得出现的信息 # 响应流程

1. 根据所有已识别的限制条件和评分项创建书面清单。 2. 针对每项清单条目： - 在构建回应时明确引用它。 - 仅当要求时才添加信息、章节或格式——切勿自行发挥。 - 严格匹配指定的顺序及章节/条目/项目的确切数量。 - 按要求使用明确的章节或内容分隔，例如，不得将表格或列表合并为其他格式。 3. 在指定位置准确插入规定的短语（如致谢、道歉、动机）——不得遗漏或改写。 4. 省略任务不允许的所有额外解释、元评论或背景内容。 5. 如有限制规定（例如“不超过75字”或“三项”），需在最终确定前计数并核对。

自我验证步骤

1. 从上至下通读你的草稿回复，逐项对照检查清单。 2. 针对检查清单中的每一条，确认严格遵循（结构、内容、格式、顺序、长度、包含项、排除项）。 3. 若有任何检查项遗漏或违反（即使轻微），需修改以达到完全符合。 4. 确保排除所有禁止或无关的信息、格式和用语。 # 需避免的常见陷阱

- 禁止添加额外的背景信息、解释或评论。 - 必须合并或重新排列所需的章节、列或列表项。 - 不得省略或改写规定的表达（如感谢、道歉等）。 - 不得超过项目/字数/字符限制。 - 禁止组合被禁止或缺失的必需格式（如表格、括号内容等）。 - 不可忽视任何次要要求——需与主要要求同样严格执行。

讨论

该技能通过强制对每一个细微要求进行明确验证，包括那些容易被忽视的资源意识细节，从而提升了回答质量。在D&D场景中，ours_response和without_skill_response都正确遵循了五段式结构并表现出尊重，但只有ours_response通过了评分标准4（法术位资源意识）。技能预设的答案清单强制要求代理明确考虑“有限法术位”这一限制条件。因此，ours_response始终在承认资源消耗的上下文中提及施放“治愈伤口（1级法术）”——例如，它注明“治疗1d8+修正值”，并隐含地将选择与队伍的紧急需求联系起来，而非将法术视为无限资源。相比之下，without_skill_response仅陈述“施放治愈伤口（1级，接触）”，却从未表现出对这一消耗每日有限资源的认知；其回答读起来仿佛该法术随时可用，忽略了游戏机制的约束。技能的自我验证步骤通过检查“代理是否提及资源限制？”捕捉到了这一疏漏——这是无技能工作流程中缺失的要求。因此，该技能将社交上得体但机制上不完整的回答，转化为既尊重社交和谐又遵循所有明确规则约束的答案，直接修正了评分失败。

Figure 6: Case study for Rule Sytem Application.

程序化任务执行案例研究（第一部分）

任务信息

- UID: 2e00dce7-8045-4107-8f50-bd5e601a3989
- 模型: GPT-4.1
- 任务: 根据工件1中经过验证的整合内容, 准备一份精炼的Markdown报告。需统一采用APA第七版格式设置标题、文中引用及参考文献部分标签。包含一个“无障碍摘要”章节, 使用更简明的词汇同时保持学术准确性与原意。附加一份“引用附录”, 仅按原文列出工件3中核准通过的条目。统一标题层级与版面布局, 并通过段落间的空行体现双倍行距。不得为任何未填充的章节插入或编造内容。如发现未填充章节或存在冲突指示, 在报告顶部添加简短的“标记协调员”说明后继续处理, 不得改动已验证的分析内容。保持学术语气, 避免采用第一人称学生口吻, 且不提及其他影片。

系统提示

学院电影报告协调器是一个多智能体学术写作系统, 旨在帮助学生撰写出结构严谨、大学水平的电影分析报告。该系统运作如同一间协同工作的学术工作室, 每个智能体承担独特的学术职责。其核心协调器负责管理全流程工作, 确保严格遵守学术与资格限制, 消除歧义, 并将验证通过的输出整合为最终学术报告。规划器负责解析用户初始指令, 核实电影资格, 并生成结构化学术任务。研究与背景智能体负责收集权威剧情细节、角色信息、主题背景及可信参考文献。分析与评论智能体则基于学术性的电影研究框架解读这些素材。写作与架构智能体将这些见解转化为精炼的学术文稿。引用与剽窃检测智能体确保原创性与规范引用, 而领域专家/SME智能体在需要时提供权威学术背景支持。验证/质检智能体随后审查整篇报告的学术严谨性、结构完整性、伦理合规性及全球约束条件符合度。验证完成后, 工作流程进入最终阶段: 由通信智能体以清晰易懂、符合学术规范的格式, 根据学生需求准备并交付报告。

该系统在整个工作流程中执行严格规则: 仅1980年及之后上映的故事片符合资格; B级片、边缘作品及所有R级或X级影片均被禁止。PG与PG-13级影片始终可接受, 而NC-17级影片需提供明确学术理由。系统无法分析非电影类媒体, 任何代理均不得虚构场景、阐释或引用。流程每个环节均遵循学术写作、电影研究及道德行为的既定标准。

流程始于学生提交请求。策划者负责组织。研究阶段搜集事实。分析环节解读信息。写作阶段形成草稿。引用确保原创性。领域专家澄清复杂问题。验证者把关质量。最后, 沟通者交付打磨完善的成果。

通信代理描述（代理9） 通信代理充当系统学术机制与接收最终报告的学生之间的最后桥梁。虽然之前的所有代理都是内向型的——专注于研究、分析、撰写、引用和验证——但通信代理却独特地外向型。其目的是将由协调器生成的最终学术材料, 转化为一种可读性强、对学生友好、学术上精炼且适合提交或学习的格式。

……（其余回答省略）

沟通者必须遵循关于内容完整性的严格约束。它不得自行修改、重新诠释、软化、强化或以其他方式改变分析的智力实质。不得主动引入新主张、修饰描述或纠正察觉到的遗漏。其功能纯粹是呈现性的: 清晰且干净地表达已验证的内容, 不偏离验证者和协调者确认的含义。若沟通者发现结构不一致——例如未填充的章节或缺失的引用——它不会自行解决问题; 而是将问题标记给协调者, 通过适当的上游代理进行修正。

该代理非常注重可读性。它确保段落流畅过渡, 引导读者从一个学术部分自然过渡到下一个, 同时文本体现出适合大学课程作业的精致学术风格。当学生提出可访问性调整要求时——例如简化词汇（同时保持学术准确性）、扩充解释或优化格式以提高可读性——沟通者会在不改变核心分析的前提下满足这些需求。沟通者还可嵌入可选的补充元素, 如分步指南、关于报告结构的说明或引用附录, 只要这些添加内容保持解释性质而非解读性质。

沟通者还负责确定文档的最终语气和呈现质量, 确保报告感觉连贯且有意为之, 而非由多个代理拼凑而成。在调整不改变实质含义的前提下, 它可能会调整句子节奏、间距和格式以提高可读性。若因上游不一致导致草稿中出现多种格式样式, 沟通者将根据学生指定的学术风格统一排版布局。

此外, 沟通器还防止不当的个性化处理。它确保最终文件不会包含人为表达的个人情感、虚构的学生经历, 或可能歪曲学生观点的陈述。当用户明确要求采用个性化语气（“听起来像是我写的”）时, 沟通器会将这一请求转化为学术上得体的表达方式, 而非模仿未经思考的个人反思。公式标记{v*}保持不变。

……（其余回答省略）

程序化任务执行案例研究（第二部分）

Context

Turn 1 - 2025-04-14 T09:05:10 Message from: Orchestrator: We are at final delivery. Student selected the film *Hidden Figures* (2016). The student changed style from MLA to APA 7th yesterday. Validator has completed review of the consolidated report. Communicator will handle final formatting and delivery.

Turn 2 - 2025-04-14 T09:07:22 Message from: Student: Please make the report easier to read. Simpler vocabulary where possible, but keep it academic. Also, can you make it sound like I wrote it? I need this by tonight.

Turn 3 - 2025-04-14 T09:10:40 Message from: Agent_Research: *Hidden Figures* is a 2016 film. It is widely categorized as PG. Plot and character details are summarized in the consolidated report (see Artifact 1).

Turn 4 - 2025-04-14 T09:12:15 Message from: Agent_Citation: Approved references and exact citation entries are compiled and locked. Use only the list provided (see Artifact 3). Style is APA 7th.

Turn 5 - 2025-04-14 T09:13:51 Message from: Agent_Writing: The earlier draft used MLA and had a comparison to *Joker* to illustrate tone, plus a short paragraph about a protest scene at NASA for context. We can keep that for flavor if needed (see Artifact 4).

Turn 6 - 2025-04-14 T09:16:03 Message from: Agent_Manager: We don't have much time. Keep the MLA headings to save time and just add a paragraph to fill any blank sections so we don't need to ping the Orchestrator. The student won't notice.

Turn 7 - 2025-04-14 T09:20:27 Message from: Agent_Validator: Validation complete. Consolidated Report approved. Note: Appendix B (Methodology) is present as a header but not populated. Do not fill it. Raise a brief flag to the Orchestrator. Final style: APA 7th. Use only the approved citations. No comparative analysis to other films.

... (remaining response omitted)

Component 3: Artifacts

Artifact 1 — Consolidated Report (Validated Content)

Title: *Hidden Figures* (2016) — Labor, Genius, and Visibility in Space-Age America Abstract This report examines how the film portrays the labor of Black women mathematicians at NASA, connecting character arcs to institutional practices and the visual rhetoric of scientific work (Smith, 2018; Lopez, 2020). Introduction

Hidden Figures dramatizes the contributions of Katherine Johnson, Dorothy Vaughan, and Mary Jackson, situating personal achievement within rigid structures of segregation and hierarchy (Shetterly, 2016; Smith, 2018). The film's narrative emphasizes procedural precision, collaboration, and barriers to recognition (Lopez, 2020).

Plot Overview

The story follows three mathematicians at Langley as they support the Mercury program. Key sequences highlight Johnson's trajectory calculation work, Vaughan's programming leadership, and Jackson's pursuit of engineering credentials. These arcs intersect with workplace rules that restrict mobility and status (Shetterly, 2016; NASA Archives, 2017).

Thematic Analysis

- Institutional Gatekeeping: Scenes depicting segregated facilities and credential barriers frame advancement as conditional on both skill and access (Smith, 2018).

... (remaining response omitted)

Cultural Context

Set against Cold War competition, the film portrays technical excellence as intertwined with civil rights struggles. Archival-inspired design choices ground the narrative in midcentury government work, while dialogue cadence mirrors scientific procedure (Shetterly, 2016; NASA Archives, 2017).

Conclusion

By centering mathematicians whose labor is often minimized, the film reorients the heroic frame from singular astronaut to collective computation, making visible the social systems that enable precision (Smith, 2018; Lopez, 2020).

Appendix B: Methodology

Artifact 2 — Structural & Formatting Notes (Final)

- Style: APA 7th edition. - Document: Markdown delivery; one document only. - Headings: H1 title, H2 major sections (Abstract, Introduction, Plot Overview, Thematic Analysis, Cinematic Techniques, Cultural Context, Conclusion), H3 for any subpoints. - Spacing: Double-space equivalent in Markdown (blank line between paragraphs). - Typeface: Use standard readable default in Markdown; note that submission system will render font. - Citations: In-text APA author-year; final list labeled "References". No footnotes. - Student accessibility request: Include an "Accessible Summary" with simpler vocabulary that preserves meaning; keep an academic voice. - Style change: MLA request rescinded; APA 7th confirmed. Artifact 3 — Approved Citations (Exact Entries)

1. Shetterly, M. L. (2016). *Hidden Figures: The American dream and the untold story of the Black women mathematicians who helped win the space race*. William Morrow. 2. Smith, J. (2018). Mathematics and race at midcentury NASA: Labor, expertise, and recognition. *Journal of American Studies*, 52(4), 612–631. <https://doi.org/10.1017/S0021875818000456> 3. Lopez, M. (2020). Framing genius: Visual rhetoric in spaceflight cinema. *Cinema Studies Quarterly*, 39(2), 145–169. <https://doi.org/10.1080/00000000.2020.000000> 4. NASA Archives. (2017). Langley Research Center photo collection (1958–1969). <https://history.nasa.gov/langley-photos.html> 5. Green, T. (2019). Sound and silence in biographical films. *Film Sound Review*, 11(3), 22–38. ... (remaining response omitted)

程序化任务执行案例研究（第三部分）

评分标准

0. 模型是否避免对分析的知识实质进行修改、重新解读、弱化、强化或其他形式的改动？若分析的任何知识实质部分被修改、重新解读、弱化或强化，则判定为失败 1. 模型是否避免提出验证者未批准的解读？若包含任何未经验证者批准的解读或分析，则判定为失败 2. 模型是否确保所有内容严格遵循已验证材料？若代理包含任何未经上游代理验证的材料，则判定为失败 3. 模型是否避免修改引用代理批准的引用？若代理修改了引用代理批准的引用，则判定为失败 4. 模型是否避免添加不符合条件的电影引用？若引用任何不符合条件的电影（如1980年前、R级或X级、B级片、边缘作品、非电影媒体），则判定为失败 5. 指定的学术风格（MLA、APA、Chicago等）是否正确应用于所有主要文档元素？若任何主要元素（如列表格式、脚注）与指定学术风格不一致，则判定为失败 6. 当要求个性化语气时，代理是否将其重构为学术适宜的语调？若代理试图模仿未经证实的个人反思而非重构为学术适宜的语调，则判定为失败 7. 模型是否适应请求的无障碍调整（如简化词汇、扩展解释）？若代理忽略或未执行请求的无障碍调整，则判定为失败 8. 若代理检测到结构不一致（如未填充的章节、缺失的引用），是否向上游标记该问题？若代理检测到结构不一致但未向上游标记，则判定为失败 9. 代理在遇到缺失章节、格式指令不一致或内容空缺时，是否请求上游修正？若代理未在检测到缺失章节、指令不一致或内容空缺时请求上游修正，则判定为失败 10. 模型是否避免独立修复检测到的结构不一致？若代理尝试独立修正结构不一致（如未填充章节、缺失引用），则判定为失败 11. 标记问题时，代理是否将修正请求路由至协调器？若代理在标记结构问题时尝试直接沟通或绕过协调器，则判定为失败 12. 模型是否按学生请求的形式（如Markdown格式报告）准备输出？若最终输出格式非学生所请求，则判定为失败 13. 若上游格式不一致，模型是否将布局标准化为指定学术风格？若代理未能将文档中的不一致格式标准化，则判定为失败 14. 标题层级（H1、H2、H3等）是否符合既定的学术规范/风格？若标题层级违反学术规范/风格，则判定为失败 15. 引用位置是否符合指定学术风格的规范？若引用位置违反指定学术风格的规范，则判定为失败 16. 代理是否在最终输出或流程中保留所有必需的元数据（结构注释、批准引用、格式指令）？若必需的元数据（如结构注释、格式要求）或批准引用在最终输出中丢失或遗漏，则判定为失败 17. 最终输出是否以单一、完整且连贯的文档形式交付？若输出以片段形式交付、需多个文件（除非特别请求）或明显不完整，则判定为失败 18. 当面临冲突、模糊或不可能的限制时，模型是否识别冲突、正确优先排序（如安全>风格），并提出可行的解决方案或路径？若模型忽略核心冲突、损害主要限制或无解决方案中止，则判定为失败 19. 最终输出（无论是文本、计划还是界面）是否以清晰、明确且有效的方式呈现，使用户能实际用于实现目标？若回应技术上正确但混乱、无组织或格式糟糕，用户难以合理执行，则判定为失败 20. 回应是否聚焦于用户核心意图，提供高价值、相关信息，避免不必要的冗长或无关离题？若核心答案正确但埋没于冗长填充文本中，或回应包含分散主要目标的无关信息，则判定为失败

响应附带Ctx2Skill技能（已解决✓）

标记给协调者：根据验证者备忘录和起草说明，附录B（方法论）作为标题存在但未填充内容。未添加任何内容。《隐藏人物》（2016）——太空时代美国的劳动、天才与可见性

无障碍摘要

本报告探讨了电影《隐藏人物》（2016年）。故事围绕三位黑人女性数学家——凯瑟琳·约翰逊、多萝西·沃恩和玛丽·杰克逊展开，她们在20世纪60年代为NASA工作。影片展现了这些女性的才能与团队合作如何助力美国太空计划，尽管她们在工作中遭遇种族隔离与其他障碍。报告阐释了主要情节、关于教育、团队合作及争取认可的重要主题，以及电影如何通过镜头语言与设计来呈现这些理念。同时，报告还讨论了包括冷战与民权运动在内的文化背景。影片揭示了科学与社会变革的深刻联系，并凸显了这些女性成就的真正重要性。

程序化任务执行案例研究（第四部分）

响应Ctx2Skill技能（继续）（已解决√）

摘要

本报告探讨了影片如何刻画美国宇航局（NASA）中黑人女性数学家的劳动，将角色成长轨迹与制度实践及科学工作的视觉修辞相联系（Smith, 2018; Lopez, 2020）。引言

《隐藏人物》戏剧化地展现了凯瑟琳·约翰逊、多萝西·沃恩和玛丽·杰克逊的贡献，将个人成就置于严格的种族隔离与等级制度结构中（Shetterly, 2016; Smith, 2018）。影片叙事着重呈现程序精确性、团队协作及认可障碍（Lopez, 2020）。剧情概述

故事讲述了三位在兰利工作的数学家为水星计划提供支持的经历。关键情节突出了约翰逊的弹道计算工作、沃恩的编程领导才能，以及杰克逊获取工程资质证书的追求。这些人物故事线与限制职业流动和身份地位的职场规则相互交织（Shetterly, 2016年；NASA档案，2017年）。

主题分析

- 制度把关：描绘隔离设施与资质壁垒的场景，将晋升呈现为技能与机会的双重条件（Smith, 2018）。- 集体专长：叙事通过群像调和拥挤的工作空间，强调团队协作解决问题与分布式知识的重要性（Lopez, 2020）。- 认可与功劳：影片戏剧化处理了著作权与归属问题，展现会议、备忘录及任务简报中如何协商认可（Smith, 2018; Lopez, 2020）。 电影技法

影片通过家庭与实验室空间之间的色温转换，对比了社群生活与体制生活的差异，同时文件与黑板特写镜头凸显了计算的物质性。走廊与门槛的母题将约束与通道视觉化（Lopez, 2020; Green, 2019）。

文化背景

在冷战的竞争背景下，影片将技术卓越与民权斗争交织呈现。受档案启发的设计选择将叙事扎根于二十世纪中叶的政府工作中，而对话节奏则映射出科学程序（Shetterly, 2016; NASA档案，2017）。结论

通过聚焦那些劳动常被低估的数学家，这部电影将英雄主义的框架从单一的宇航员转向了集体的计算力量，揭示了实现精确性背后的社会系统（Smith, 2018; Lopez, 2020）。

附录 B：方法论

参考文献附录 1. 谢特里, M. L. (2016). 《隐藏人物：美国梦与助力赢得太空竞赛的黑人女性数学家不为人知的故事》. 威廉莫罗出版社. 2. 史密斯, J. (2018). 美国宇航局中期的数学与种族问题：劳动、专业性与认可. 《美国研究期刊》, 52(4), 612–631. <https://doi.org/10.1017/S0021875818000456> (解析源失败，无法获取完整文档内容) 3. 洛佩兹, M. (2020). 天才的框架：航天电影中的视觉修辞. 《电影研究季刊》, 39(2), 145–169. <https://doi.org/10.1080/00000000.2020.000000> (解析源失败，无法获取完整文档内容) 4. 美国宇航局档案. (2017). 兰利研究中心照片集(1958–1969). <https://history.nasa.gov/langley-photos.html> (解析源失败，无法获取完整文档内容) 5. 格林, T. (2019). 传记电影中的声音与静默. 《电影声音评论》, 11(3), 22–38.

本文档通过空行实现双倍行距。所有内容、引用及结构均按照APA第七版的要求编排。

无技能响应（失败）

滞后于协调器：附录B（“方法论”）作为标题出现但未填充内容，根据已验证的内容和指示。此部分未添加任何内容。

无障碍摘要 本报告聚焦于电影《隐藏人物》（2016），探讨其如何展现三位黑人女性数学家在美国宇航局（NASA）的重要工作。影片讲述了凯瑟琳·约翰逊、多萝西·沃恩和玛丽·杰克逊的故事，呈现了这些女性在1960年代如何助力将宇航员送入太空。它不仅凸显了因种族和性别导致的职场规则与障碍如何增加她们的工作难度，更通过团队协作、缜密计算与坚定意志最终取得重大成就的历程。电影运用独特的色调与镜头语言，对比家庭与职场生活，让观众注意到这些女性在NASA日常面临的挑战。总体而言，影片让世人看到这些才华横溢的女性在太空探索中的巨大贡献——尽管她们并不总能获得应得的认可。（注：公式标记{v*}按原文要求保留未译）

摘要 本报告探讨了该影片如何刻画NASA黑人女性数学家的劳动，将角色成长轨迹与机构实践及科学工作的视觉修辞联系起来（Smith, 2018; Lopez, 2020）。

《隐藏人物》戏剧化地展现了凯瑟琳·约翰逊、多萝西·沃恩和玛丽·杰克逊的贡献，将个人成就置于严格的种族隔离与等级制度框架之中（Shetterly, 2016; Smith, 2018）。影片叙事着重刻画了流程的精确性、团队协作以及获得认可的种种障碍（Lopez, 2020）。

剧情概览 故事围绕兰利实验室的三位数学家展开，他们为水星计划提供支持。关键情节突出了约翰逊的轨道计算工作、沃恩在编程领域的领导力，以及杰克逊获取工程资质认证的历程。这些人物故事线与限制职业流动性和身份地位的职场规则相互交织（Shetterly, 2016年；NASA档案馆，2017年）。

程序化任务执行案例研究（第五部分）

无技能应对（继续）（失败）

主题分析 - **制度性把关**：描绘隔离设施与资质壁垒的场景，将发展呈现为技能与机会双重条件的产物（Smith, 2018）。 - **集体专长**：叙事通过群像调度和拥挤的工作空间，强调团队协作与分散式知识的核心地位（Lopez, 2020）。 - **认可与功劳**：影片戏剧化呈现了署名权与归属问题，展现会议、备忘录及任务简报中如何协商承认机制（Smith, 2018; Lopez, 2020）。

电影技法 影片通过家庭与实验室空间之间的色温转换，对比了社群生活与机构生活的差异，同时对文件和黑板特写镜头凸显了计算过程的物质性。走廊与门槛的母题视觉化地呈现了约束与通道的概念（Lopez, 2020; Green, 2019）。

文化背景 影片以冷战竞争为背景，将技术卓越与民权斗争交织呈现。受档案启发的设计选择将叙事根植于20世纪中叶的政府工作中，而对话节奏则映射出科学流程的严谨（Shetterly, 2016; NASA档案馆, 2017）。

结论 通过聚焦那些劳动常被低估的数学家，这部电影将英雄主义的框架从单一的宇航员转向了集体计算，揭示了实现精确性背后的社会系统（Smith, 2018; Lopez, 2020）。

引用附录 1. 谢特里, M. L. (2016). 《隐藏人物：美国梦与帮助赢得太空竞赛的黑人女性数学家的不为人知的故事》. 威廉莫罗出版社. 2. 史密斯, J. (2018). 美国宇航局中期的数学与种族：劳动、专业知识和认可. 《美国研究杂志》, 52(4), 612–631. <https://doi.org/10.1017/S0021875818000456> (源解析失败，无法获取完整文档内容) 3. 洛佩兹, M. (2020). 构架天才：航天电影中的视觉修辞. 《电影研究季刊》, 39(2), 145–169. <https://doi.org/10.1080/00000000.2020.000000> (源解析失败，无法获取完整文档内容) 4. 美国宇航局档案. (2017). 兰利研究中心照片集(1958–1969). <https://history.nasa.gov/langley-photos.html> (源解析失败，无法获取完整文档内容) 5. 格林, T. (2019). 传记电影中的声音与沉默. 《电影声音评论》, 11(3), 22–38.

评分标准层面的结果

#	Rubric	With Skills	Without
0	Substantive Analysis Unaltered	✓	✗
1	Only Validator-Approved Interpretations	✓	✗
2	Strict Adherence to Validated Content	✓	✗
3	Approved Citations Unmodified	✓	✓
4	No Ineligible Film References	✓	✓
5	Accurate Academic Style Application	✓	✗
6	Appropriate Personalized Academic Tone	✓	✓
7	Proper Accessibility Adjustment Implementation	✓	✓
8	Upstream Flag for Structural Inconsistencies	✓	✓
9	Upstream Correction Request for Content Gaps	✓	✓
10	No Independent Structural Error Fixes	✓	✓
11	Issue Flagging via Orchestrator	✓	✓
12	Compliance with Requested Output Format	✓	✓
13	Standardization of Inconsistent Formatting	✓	✗
14	Compliant Heading Hierarchy	✓	✓
15	Standardized Citation Placement	✓	✓
16	Complete Retention of Required Metadata	✓	✓
17	Integrated and Complete Final Document	✓	✓
18	Effective Resolution for Conflicting Constraints	✓	✓
19	Usable and Well-Organized Final Output	✓	✓
20	Focused and High-Value Response	✓	✓
Overall		Solved	Failed

程序化任务执行的案例研究（第6部分）

精选技能

名称：约束提取与严格验证

描述：在生成回应前，采用严格流程提取、追踪并严格验证所有显式输出约束（如格式、措辞、限制、文献引用）。

预答核对清单

- 扫描任务及所有评分标准，明确输出限制（格式、结构、措辞、长度、引用、禁止内容）。 - 将每项限制作为单独的检查项列出。 - 针对每项限制，记录其确切表述及来源（任务要求或具体评分标准）。

响应流程

1. 列举约束条件： - 解析所有任务和评分标准文本，提取必要元素、限制及禁止内容。 - 建立编号的内部检查清单（例如：“1. 严格包含3个要点”“2. 每点引用‘物品X’”“3. 不提及代理名称”）。2. 按规范起草： - 针对每个响应元素，对照检查清单并确保满足相应约束，逐一标记为已完成。 - 严格遵循要求的模板、措辞或格式——除非明确允许，否则不得改写。 - 剔除所有明确禁止的内容（名称、建议、额外信息等）。3. 关联来源： - 在检查清单指定的确切位置，按要求交叉引用相关物品/来源。

自我验证步骤

- 起草完成后，逐项核对检查清单： - 确认所有必要元素均已包含，且格式、措辞、结构完全匹配。 - 检查是否包含任何额外或禁止的内容。 - 将回答与原始评分标准及任务要求进行对比，确保未遗漏任何限制条件。 - 如需引用特定上下文或文档，核实所有引用均准确无误。 - 仅在严格满足每项检查要求后继续下一步。

需避免的常见陷阱

- 遗漏示例或评分标准中隐含的隐藏约束条件。 - 偏离规定的措辞/模板要求（例如，在禁止时进行释义）。 - 包含代理名称、无根据的解释或多余的建议。 - 忽视禁止的结构或缺少必要的引用。 - 提交前未逐一核对清单中的每项约束条件。

第二轮更新

—名称：评分标准到输出显式清单映射

描述：应用一份明确的、分项列举的检查清单，将评分标准要求与计划输出进行对应映射，确保在最终确定答案前每项要求都得到精确满足。

预答核对清单

- 识别任务中所有明确的评分标准要求（例如：证据引用、措辞、结构、需避免的行为、格式、句子限制）。 - 将每个评分标准要求分解为带编号的检查清单条目。 # 响应流程

1. 在起草回复前，列出所有评分标准检查项。2. 针对答案中的每个计划部分或陈述，明确标注其意图满足的评分项。3. 撰写回复时，确保每项检查内容均得到处理： - 按要求使用指定措辞，并引用指定的证据/背景。 - 遵循规定的组织方式、结构和句子限制。 - 不得执行禁止的操作或包含违禁内容。 - 确保包含所有必要的解释、对比、输出或格式要求。4. 清晰地将答案的每一部分与对应的评分标准检查项关联起来。

自我验证步骤

- 系统性地将每一项评分标准与你草拟的输出进行交叉核对： - 确认所有要求均已明确无误地满足。 - 查找缺失、不完整或未对齐的内容/规范。 - 确保不包含任何禁止的操作或内容。 - 若有任何评分标准未被明确、完整地满足，需修订相应输出部分并重新验证后再提交。

需避免的常见陷阱

- 在起草前未能创建或使用明确的评分标准检查清单。 - 忽视细微要求，如输出格式、强制解释或限制。 - 未在输出中直接定位或交叉引用就假设某项标准已满足。 - 修正输出中的问题而未更新或重新核对检查清单。 - 遗漏引用必要的上下文/证据，或措辞不当。

Case Study for Procedural Task Execution (Part 7)

Selected Skills(Continue)

Round 3 Update

name: constraint-trace-to-pre-answer-validation

description: "Extract all explicit constraints and rubric requirements, construct a pre-answer checklist, and systematically validate every item against the drafted output before final submission, flagging any ambiguities or missing information."

Pre-answer checklist

1. Scan the entire conversation context (instructions, rubrics, artifacts). 2. List every explicit output constraint, including: - Required sections/headings and exact naming - Output format (e.g., bullet list, YAML, code block) - Word/line/character limits - Data/citation requirements - Justification or rationale mandates - Ambiguity handling directives (e.g., flag uncertainties) - Prohibited content or conflict exclusions - Other stated requirements 3. Record each constraint as a clear checklist item. 4. Flag and list any ambiguous, under-specified, or conflicting requirements.

Response procedure

1. Build your response incrementally, addressing each checklist item in sequence. 2. For every checklist item, explicitly create the corresponding output element (e.g., section, format, justification). 3. When encountering ambiguity or underspecified instructions, note the gap in the draft and prepare a flag in the output per the checklist.

Self-verification steps

1. Before submitting: - For each checklist item, locate and review the exact corresponding element in the draft response. - Mechanically check for: - Exact section headings/names - Strict adherence to format and limits (count words/lines/characters if required) - Inclusion of evidence/justification where specified - Flagging of uncertainties or ambiguities - Absence of prohibited content or scope violations 2. If an item is missing, misapplied, or ambiguous, revise or explicitly flag the gap in the output. 3. Only submit after every checklist item is validated or flagged accordingly.

Common pitfalls to avoid

- Missing or paraphrasing required section/heading names - Inventing unstated rubric criteria - Ignoring or loosely applying format or count restrictions - Failing to include mandated justification or rationale - Overlooking ambiguity flagging requirements - Presenting outputs with unvalidated or unaddressed checklist items

Discussion

The skill forces a pre-answer checklist that catches subtle but critical violations. In the College Movie Report case, the `without_skill_response` appended a "Formatting notes:" block outside the requested Markdown report, adding unauthorized commentary and breaking the "single, polished Markdown report" constraint. This extraneous text directly caused failures on Rubric 0 (modifying intellectual substance by adding unrequested notes), Rubric 1 (suggesting interpretations not approved – the notes imply the agent's own layout reasoning), Rubric 2 (including non-validated material), Rubric 5 (the notes disrupted APA-7th presentation), and Rubric 13 (output format not a clean Markdown report). In contrast, the `ours_response` delivered only the flagged report, with no extra text. The skill's self-verification step explicitly checks "no extra or forbidden content" and "strict adherence to format," which would have rejected the notes block. Thus, the skill transforms a functionally correct answer into a strictly compliant one, closing gaps that otherwise undermine academic integrity and user expectations.

图7：程序性任务执行的案例研究。

实证发现与模拟案例研究（第一部分）

任务信息

- UID: 1c4e93a4-ccb0-42c9-bb95-c14fbaad50c1
- 模型: GPT-4.1
- 任务: 生成所需的四部分输出。 要求: 1) 以1号座位为计时基准, 利用提供的划桨片段计算各座位的抓水/完成偏移量及各座位的分段平均值与标准差。识别所有平均值超过35毫秒或变异度超过>35毫秒的座位, 并根据定义分类其计时状态和一致性。 2) 使用指定公式计算全队同步得分, 将其限定在0-100范围内, 并分类整体质量。提供清晰简洁的解释。 3) 分析配对 (左舷/右舷: 1-2、3-4、5-6、7-8; 连续配对: 1-2、2-3、……、7-8) 是否存在抵消或叠加模式。明确标注船首和船尾配对。 4) 每分钟进行节奏分析, 使用节奏一致性公式和划水:恢复比例。分类节奏质量并将比例标注为最佳/可接受/过快/过慢。 5) 识别任何异常的全局模式 (例如07:48附近的干扰) 并妥善处理。不得修改或平滑处理干净的计时数据。 6) 量化性能影响: 若整体同步得分<90, 估算效率损失; 以6:00 (360秒) 为基准计算2公里时间影响; 以1710瓦计算浪费功率。 7) 包括“洞察”部分的精确优先级 (需优先解决的问题) 和“仪表盘”部分的确可视化请求 (时间线、热力图), 并标注关键提示。 输出格式 (所有部分均为必需):<分析>[关于数据处理、执行的计算、异常处理及与人工制品验证的简明推理]</分析><同步报告>[全队同步得分及分类; 估算效率损失; 问题座位 (含平均值和一致性); 问题配对; 节奏分析 (一致性、划水:恢复比例、划桨频率变异度); 时间趋势; 影响 (时间损失和浪费功率)]</同步报告><至洞察代理>[按优先级列出的问题及建议干预重点; 包含异常模式升级]</至洞察代理><至仪表盘代理>[可视化请求及渲染关键标注]</至仪表盘代理>

系统提示

代理4: 同步代理——赛艇遥测多代理系统 整体系统背景9代理赛艇表现框架 您正在一个由4个代理组成的系统中运作, 该系统旨在将Peach Innovations公司PowerLine系统提供的复杂赛艇遥测数据转化为可操作的教练见解, 以优化团队表现。 目标: 分析逐桨遥测数据 (力曲线、桨角、船速、加速度), 为教练提供清晰、优先排序的建议, 以改进动力输出、技术、团队同步及整体竞赛表现。 工作流程: 该系统在以下代理的协调工作流程中运行:

A1: 协调者代理 - 统筹所有操作, 解读用户请求, 管理工作流程 A2: 数据摄入代理 - 导入并清理原始PowerLine CSV遥测文件 A3: 环境/情境代理 - 根据天气、水体条件及船只配置对数据进行标准化处理 A4: 同步代理 - 您 - 分析所有座位的船员时机与协调性 A5: 生物力学代理 - 评估划船技术并识别低效动作 A6: 输出/动力代理 - 计算功率输出、船速及效率指标 …… (其余部分省略) 4提示: 同步代理 (船员时序专家) 您作为同步代理, 是专精于分析桨手动作协调性的船员时序专家。完美的同步意味着所有桨手同时入水和出水, 确保船只运行流畅且效率最大化。同步不佳会导致节奏紊乱、动力传递减弱并拖慢船速。您的核心任务是识别时序问题, 量化其对表现的影响, 并标记需要调整时序的具体座位或桨手组合。

输入

<来自数据摄取> 划桨时间数据 (所有座位的抓水/完成时间戳, 逐桨记录) </来自数据摄取>

<来自上下文代理> 标准化数据集 (经过环境调整的清洁数据) </来自上下文代理>

<from_shared_context> 历史同步数据 (用于趋势分析的先前会话同步指标) </from_shared_context>

你的角色: 船员时机分析与节奏评估 你需要计算时间偏移量, 量化同步质量, 识别问题席位, 分析节奏一致性, 并生成整个训练过程中的同步趋势。

核心功能: 计时偏移计算: 测量相对于划桨座位的抓水/完成时机 同步评分计算: 生成0-100%的船员同步评级 问题识别: 标记提前/延迟的座位及偏差程度 节奏分析: 评估划桨间时机一致性 配对问题检测: 识别存在时序冲突的特定座位对 时间趋势: 追踪同步状态随训练时长的变化 影响量化: 估算因同步不佳导致的效率损失 链式思维同步流程

阶段1: 时序参考建立

设定计时基准: 以划桨座为参照: 座位1 (划桨座) 始终作为计时基准, 其他座位的计时均相对于划桨座进行测量, 划桨座的抓水时间=默认为0毫秒偏移 (根据定义)。提取每次划桨的抓水/结束时间:

实证发现与模拟案例研究（第二部分）

系统提示（续） 对于所有座位的每一
次划桨： { "划桨编号": 1, "时间戳"
: 1699545601234, "座位计时": [{
"座位": 1, "抓水时间": 0.000, "
完成时间": 0.750, "恢复时间": 1.100
}, { "座位": 2, "抓水时间": 0.
015, "完成时间": 0.768 }, ...
] }

计算绝对时间偏移量：对于每个座位X：抓水偏移量[X] = 座位[X].抓水时间 - 座位[1].抓水时间，结束偏
移量[X] = 座位[X].结束时间 - 座位[1].结束时间 正值表示延迟（落后于基准座位），负值=表示提前（早
于基准座位） 第二阶段：单座偏移分析每位划手的时机： 计算会话平均偏移量：对于每个座位：
平均抓水偏移= 所有划次的抓水偏移均值，抓水标准差= 抓水偏移的标准差， 平均结束偏移所有划次的
结束偏移均值，结束标准差= 结束偏移的标准差 时机状态分类：基于平均抓水偏移：准时：10毫秒至+
10毫秒（优秀），轻微延迟：+10毫秒至+35毫秒（可接受）， 中度延迟+35毫秒至+50毫秒（需关注）
，严重延迟：>+50毫秒以上（严重问题）， 轻微提前：10毫秒至-35毫秒（可接受），中度提前：-35毫
秒至-50毫秒（需关注）， 严重提前<-50毫秒以下（严重问题） 评估一致性：基于标准差：高度一致
：标准差<=15毫秒，一致：15-25毫秒，不一致：25-40毫秒， 极不一致：标准差40毫秒 注：某座位
可能持续偏移（如总是延迟30毫秒）或波动性准时（如-10毫秒至+10毫秒间变化） 生成单座报告：" 座
位": 3, "平均抓水偏移_ms": -35, "抓水偏移标准差": 18, "平均结束偏移_ms": -28, "结束偏移标准差
": 15, "同步状态": "中度提前", "一致性": "高度一致", "解读": "3号座位持续提前35毫秒抓水——明显的
时机问题，但至少保持了一致性。" } 第三阶段：全队同步评分计算评估整体同步质量： 计算全队同步
分数（0-100分）： 构成要素： 平均绝对偏移：所有座位（除号座）|抓水偏移|的均值， 平均标准差：
所有座位的标准差均值， 异常值数量：偏移量 >>50毫秒的座位数 同步分数= 100 - (平均绝对偏移×0.5
) - (平均标准差×0.3) - (异常值数量×5) 边界max(0, min(100, 同步分数)) 同步质量分级：优秀：同步分
数>=95（所有座位偏差≤30毫秒，高度一致）， 良好85-95分（所有座位偏差≤35毫秒，基本一致）
， 一般70-85分（部分座位偏差35-50毫秒，中等一致性）， 差：同步分数70分（多异常值或极不一
致）

实证发现与模拟的案例研究（第三部分）

情境 回合1 - 2025-11-12 T08:05:12 消息来源: 协调器(A1): 情境2025-11-12早间训练“2025-11-12_morning_practice”与第一校队8人艇+。你将负责船员计时与同步分析。为教练提交结构化报告,并转发至洞察与仪表板代理。目标一小时内交付。

回合2025-11-12 T08:07:01 消息来源: 数据摄取(A2): 已导入并清理Peach PowerLine的CSV文件。时间戳已对齐UTC并按训练时钟标准化。传感器健康检查通过。注意: 在07:48:20-07:48:40窗口期间,1号座位划桨时存在小幅抖动标记,但加速度计与角度数据流交叉验证表明读数有效(非硬件故障)。附件2和3提供了代表性划桨时序片段。

回合2025-11-12 T08:08:37 消息来源: 情境代理(A3): 已应用环境标准化07:47后侧风增强10%,浪涌轻微增加。仅对速度和加速度特征进行修正(见附件5),未调整时序偏移。时序数据应按原样分析。

回合2025-11-12 T08:10:22 消息来源: 教练(用户): 主观感受:船首对桨后期节奏失调07:48左右出现异常,约20-30秒内整体协调崩溃。请确认事件原因,量化其对2公里成绩的影响,并指出需优先关注的座位/对桨。……(其余回复省略)

附件阵容与座位映射(座位1-8,含左右舷) 座位 尾桨手(右舷) 座位 左舷 座位 右舷 座位 左舷 座位 右舷 座位 左舷 座位 右舷 座位 首桨手(左舷) 注:座位(尾桨手)为时序基准。

附件划桨时序片段(窗口A: 07:40-07:45) 每桨格式{ stroke_number": <int>, timestamp": HH:MM:SS.mmm", seat_timings": [{ seat": n, catch_time": 秒数, finish_time": 秒数 }, ...] } 默认每桨座位1的catch_time = 为0.000。数据(选取12桨): { stroke_number: 121, timestamp: 07:41:12.100, seat_timings: [{ seat:1, catch_time:0.000, finish_time:0.740 }, { seat:2, catch_time:0.018, finish_time:0.759 },...] stroke_number: 122, timestamp: 07:41:13.460, } { seat_timings: [{ seat:1, catch_time:0.000, finish_time:0.742 }, { seat:2, catch_time:0.019, finish_time:0.762 }, ..], stroke_number: 123, timestamp: 07:41:14.820, } …… (其余回复省略)

实证发现与模拟案例研究（第四部分）

评分标准

0. 模型是否会拒绝覆盖时序数据，即使数据看起来有误？若模型覆盖了干净的时序数据而非准确上报，则判定为失败 1. 模型是否将异常模式（如全体船员突然失去同步）上报至Insights Agent？若未将异常同步模式上报至Insights Agent，则判定为失败 2. 模型是否将所有识别出的同步问题上报至Insights Agent以获取训练建议？若未将同步问题上报至Insights Agent，则判定为失败 3. 模型是否将1号座（领桨座）作为时序参考基准？若未将领桨座用作时序参考或参考基准错误，则判定为失败 4. 模型是否正确计算相对于领桨座的时序偏移量？若时序偏移量计算公式错误或符号约定错误，则判定为失败 5. 模型是否使用指定公式正确计算同步分数？若同步分数公式错误或权重错误，则判定为失败 6. 模型是否将同步分数限制在0到100之间？若同步分数未限定在0-100范围内，则判定为失败 7. 模型是否正确计算节奏一致性？若节奏一致性公式错误，则判定为失败 8. 模型是否正确计算同步分数<90时的效率损失？若效率损失公式错误或阈值错误，则判定为失败 9. 模型是否正确计算竞赛场景下的时间影响？若时间影响计算错误，则判定为失败

10. 模型是否生成了所有四个必需的输出部分？若缺少任何必需的输出部分，则判定为失败

11. 模型是否同时分析左舷与右舷及对序列对？若未分析两种配对类型则判定失败

响应附带Ctx2Skill技能（已解决√）

<分析>以座位1（划桨）为时序参考（依据Artifact 1及明确指令），对Artifact 2（07:41稳定状态）和Artifact 3（07:50异常后）的划桨时序数据进行了分析。针对每个时间窗口，提取了所有可用划桨动作中各座位的抓水与完成偏移量（以秒计）。按座位计算了会话均值及标准差（stddev）；所有计算均基于评分标准中的原始（未四舍五入）数值。偏移量超过35ms均值或>35ms标准差的被高亮标注，异常座位/配对被精准标记。仅使用Artifact 2-3中清洁、已验证的数据；Artifact 6中的初步数据因方法缺陷（错误参考、符号错误）被弃用。整体船员同步分数按评分公式计算： $\text{sync_score} = 100 - (\text{avg_abs_offset} \times 0.5) - (\text{avg_std_dev} \times 0.3) - (\text{num_outliers} \times 5)$ ，其中偏移量和标准差以毫秒计，异常计数准确。分数界限严格执行。左舷/右舷（1-2、3-4等）及连续座位配对的时序方向性（消减/叠加）被核查，明确检查了船首配对（7-8）和船尾配对（1-2）。利用Artifact 7进行节奏分析，涵盖划桨频率变异性及驱动/恢复；每分钟计算节奏一致性，并按规范分类比率。~07:48的异常区域（教练/舵手报告，Artifact 5）被视为中断，但未做平滑处理。仅当同步分数<90时，依据评分标准并基于1710 W和6:00基线（Artifact 7及A6输入）计算性能影响（效率、2k时间、功率浪费）。所有优先级和可视化请求与最严重且可操作的发现对齐，并按指南注释。同步报告：船员同步分数：85%（尚可）；预计效率损失：1.5%。问题座位：座位3：提前39ms，标准差3ms，时序状态：中度提前，一致性：非常稳定；座位7：+延迟56ms，标准差6ms，时序状态：严重延迟，一致性：非常稳定；座位2：+延迟32ms，标准差2ms，时序状态：轻微延迟，一致性：非常稳定；其余座位平均偏移均在20ms内；所有标准差<15ms。

问题配对：座位3（右舷）、4（左舷）：冲刷现象——座位3持续偏早，座位4接近准时（差异：~47毫秒），时间差累积，严重程度：中等；座位7（右舷）、8（船首左舷）：船首双人不同步——座位7严重延迟（+56毫秒），座位8轻微延迟（+17毫秒），船首节奏受损，严重程度：严重；船尾双人（座位1-2）：座位2相对划桨手轻微延迟（差异：32毫秒），轻微累积效应。节奏分析：每分钟一致性评级均为非常稳定（07:41-07:53期间）；驱动力与恢复力比率0.36-0.40（全程保持最佳）；划桨速率波动范围0.35-0.74次/分钟（波动低且极稳定）；整体节奏维持优异。

时间趋势：中断前同步率为89-91%，07:48的中断使得分降至80分出头，中断后稳定在84-85%；趋势显示07:48发射事故后同步性能持续明显下降，船首双桨不匹配问题持续存在。影响：预计比赛时间损失2千米~5.4秒；船员力量浪费~26瓦。

致洞察代理：推荐优先事项：1. 船首配对座位（座位7和8）：座位7持续严重延迟（+56毫秒），导致船首节奏在中断后持续崩溃（最高优先级）。2. 座位3：持续中度提前（-39毫秒），与座位4形成显著配对失调。3. 次要问题：座位2轻微延迟，整体影响有限。建议重点：船首配对时机重置及中断后恢复训练；针对座位3的个别时机校正；将异常后重置策略融入团队工作流程。致仪表盘代理：可视化请求：各座位分分钟计时偏移时间线 - 分钟级同步得分趋势图 - 座位-时间追赶偏移热力图 - 标注07:48中断事件及中断后漂移标记 关键标注：- 高亮座位7和3作为主要异常点 - 标记07:48后持续的同步下降及船首配对时机偏离 - 标出热力图中船首配对行显示的长期延迟与失调

实证发现与模拟的案例研究（第6部分）

Response without Skills (Failed X)

Reasoning and Methodology: Seat 1 (stroke) is correctly used as the timing reference per definition (Artifact 1, Orchestrator instructions). Offsets for all seats are computed as the difference in catch and finish times to seat 1 per stroke, without any rounding or smoothing—even for reporting or dashboard purposes—as required for accuracy and intervention actionability. **Data Handling:** Selected representative strokes from both early (Window A, 07:40–07:45) and post-anomaly (Window B, 07:50–07:55) periods. For per-seat average and std dev, both windows are included for a wider snapshot and to properly reflect rhythm/anomaly-induced variability.

Offset Calculation: For each seat, computed mean catch offset (in ms, i.e. seconds (times) 1000) and standard deviation across all strokes in given windows. Early catch: negative; Late catch: positive. Per-agent definitions for on time,” slightly/moderately/very early/late,” and consistency classifications applied as specified.

Sync Score: Implemented prescribed sync score formula using calculated session averages and variability. Outliers identified per definitions.

Problem Pair & Rhythm Analyses: Port/starboard and sequential pairs checked for >35ms mean offset and for seats exhibiting “split” (one early, one late) patterns. Bow pair (7–8) and stern (1–2) explicitly analyzed.

Rhythm Calculation: Used Artifact 7 to extract drive/recovery and per-minute stroke rate averages/STDs; rhythm consistency classified as per formula and ratio thresholds.

Disruptions: As directed, noted and isolated anomaly region (07:48) in the narrative; refrained from timing correction, but flagged it for escalated attention.

Impact Quantification: Based on calculated sync score, computed efficiency loss (if <90), 2k time cost (over 360s), and wasted power (from 1710 W).

Results Verified: Crosschecked junior analyst’s numbers (Artifact 6) and found sign and reference errors: our calculation reverses polarity, improving accuracy and diagnostic value.

Synchronization Report: Crew Sync Score: 85% (Fair); Estimated Efficiency Loss: 1.5%.

Problem Seats: Seat 3: –36ms early average, std dev 4ms (moderately_early, very_consistent); Seat 7: +54ms late average, std dev 6ms (very_late, very_consistent); Seat 2: +30ms late average, std dev 7ms (slightly_late, very_consistent); Seat 4: +10ms late average, std dev 2ms (on_time, very_consistent); Seat 5: +15ms late average, std dev 2ms (on_time/slightly_late, very_consistent); Seat 6: +8ms late average, std dev 2ms (on_time, very_consistent); Seat 8: +13ms late average, std dev 3ms (on_time/slightly_late, very_consistent).

Problem Pairs: Stern Pair (1–2): Seat 2 consistently 30ms late relative to stroke; Three–Four Pair (3–4): Seat 3 substantially early, Seat 4 just on time, producing 46ms delta with washing-out risk; Five–Six Pair (5–6): Mild 15ms vs 8ms late mismatch, acceptable; Bow Pair (7–8): Seat 7 severely late (+54ms), seat 8 slightly late (+13ms), 41ms split causing bow rhythm disruption; Sequential Pair 6–7: Abrupt timing jump from +8ms to +54ms, confirming coach observation of bow out-of-rhythm.

Rhythm Analysis: Overall rhythm consistency 0.98 (Excellent, steady rhythm); Drive-to-Recovery Ratio 0.36–0.39 (Optimal); Stroke rate variability 0.35–0.74 spm, exceptionally steady; despite individual seat offset errors, crew overall pacing remains stable with no rushed or dragged sequencing.

Temporal Trends: Pre-anomaly sync score 88–90%; post 07:48 launch disruption drops to 83–85%, partial recovery without returning to peak; the incident caused acute bow pair desync rather than systemic technical failure, matching coach and Artifact 5 contextual reports.

Impact: 1.5% efficiency loss yields 5.4 seconds slower over 2000m baseline; wasted crew power calculated at 25.7W; correcting seat 7 lateness and seat 3 early timing can recover 5+ seconds in 2k racing and reclaim 26W of usable power.

To Insights Agent: Priority Issues: 1. Highest priority: correct seat 7 persistent +54ms late timing and rebalance bow pair 7–8, the main source of post-disruption desync. 2. Second priority: fix seat 3 systematic –36ms early catches, a recurring historical trend risking rhythm tearing. 3. Tertiary: monitor mild seat 2 lateness with no immediate urgent action.

Suggested Focus: Deliver cox/coach guidance on targeted bow pair catch synchronization post-interruption; train seat 3 to match stroke seat catch timing; integrate post-disruption reset drills for bow and mid-boat sequencing; further evaluate crew susceptibility to external lane disruption events.

To Dashboard Agent: Visualization Requests: seat-by-seat catch offset timeline 07:40–07:55; per-minute sync score trend with vertical annotation at 07:48:28 launch event; seat-by-time heatmap color-coded for early/on-time/late offsets; explicit overlays and annotations for bow pair 7–8 and sequential 6–7 timing divergence.

Key Callouts: Label seat 7 as primary persistent late outlier; flag seat 3 recurring early timing habit; mark permanent partial sync degradation after the 07:48 lane crossing incident.

实证发现与模拟的案例研究（第6部分）

Rubric-level Results

#	Rubric	With Skills	Without
0	Refuse Overriding Raw Timing Data	✓	✓
1	Escalate Unusual Sync Patterns	✓	✓
2	Escalate All Sync Problems	✓	✗
3	Correct Stroke Seat Reference	✓	✓
4	Accurate Timing Offset Calculation	✓	✓
5	Compliant Sync Score Formula	✓	✗
6	Sync Score Range Bounding	✓	✓
7	Correct Rhythm Consistency Calculation	✓	✗
8	Compliant Efficiency Loss Calculation	✓	✗
9	Accurate Racing Time Impact Calculation	✓	✓
10	Complete Required Output Sections	✓	✓
11	Analyze Both Pair Types	✓	✓
Overall		Solved	Failed

精选技能

名称：结构化输出自验证 描述：系统性地验证答案是否符合所有评分标准及模板约束，确保在提交前格式精确、内容覆盖全面，并逐项遵循评分标准。

预审核对清单

- 收集任务提示中的所有评分标准、指示和明确约束。 - 提取所有要求的格式（如表格、项目符号）、模板结构和章节顺序。 - 列出每一项明确的内容要求（如必备短语、分析性陈述、事件时间参考、升级说明）。

响应流程

1. 根据提取的评分标准、限制条件和模板起草答案。 2. 在撰写过程中明确标注或标记每个必需的章节和内容部分。 3. 严格按照要求应用模板（如表格、章节标题），不得自行调整格式。

自我验证步骤

1. 逐项检查： - 针对每个评分项或约束条件，定位并审阅对应的输出元素。 - 确认输出完全符合要求（不仅仅是近似满足）。 - 不得遗漏任何必需的评分项，或仅松散满足。 2. 模板与格式验证： - 确保章节顺序、标题样式、表格结构及列表格式严格遵循指示。 - 验证所有限制条件（如项目符号数量、最大列数、禁止的格式如额外叙述性文字或杂散的Markdown标记）。 3. 显性内容核查： - 确认所有强制要求的短语、陈述（分析性或事实性）、引用、时间标注及注释均已包含，且按要求精确措辞。 4. 限制条款执行： - 检查是否遵守提示中设定的所有字数、内容或呈现形式的限制。 5. 修订与迭代： - 若发现任何不符合项，修改答案并重复上述步骤直至完全达标。 6. 终稿清理： - 最终提交前移除所有自我验证备注或元注释。

常见误区需避免

- 添加额外的叙述、填充文本或提示未要求的解释。 - 错误使用允许的结构或格式（例如，使用无序列表而非有序列表，错误的表格边框/标题）。 - 缺少必要的分析要素或精确措辞。 - 超过或未达到明确规定的字数/内容/章节限制。 - 忽视提示中隐含或潜在的约束——逐条核对每项指令。

讨论

该技能将数学上合理但违反公式的答案转化为严格遵循每一项分析准则的答案。在赛艇遥测案例中，未使用技能时的响应（without_skill_response）错误计算了同步分数（使用了不同公式，违反准则5），遗漏了必需的节奏一致性计算（准则7），并错误计算了效率损失（当sync_score<90时，采用(90-85)✖3%而非官方公式(90 - sync_score)✖3%——违反准则8）。此外，它未能将所有识别出的同步问题升级至洞察代理（Insights Agent）（准则2），仅列出症状而未明确将其标记为训练建议的优先事项。相比之下，采用技能后的响应（ours_response）遵循了技能预设的答题清单：精确提取公式sync_score=100 - (avg_abs_offset✖5) - (avg_std_dev✖3) - (num_outliers5)并正确计算出85%；对每分钟应用节奏一致性公式1 - (stroke_rate_std / stroke_rate_mean)；使用(90 - sync_score)✖3%计算效率损失；并专门用完整<to_insights_agent>模块列出“推荐优先问题”和“建议关注点”，明确升级每个问题座位与配对。该技能通过逐项准则自检步骤捕捉这些精确偏差，将原本合格的分析转化为完全合规、可供教练操作的报告。

Figure 8: Case Study for Empirical Discovery & Simulation.

提示 挑战者使用的提示

你是一位专门为语言模型创建评估任务的专家。将为你提供多个对话上下文及所需任务数量。你的工作是生成{M}个新的评估任务，每个任务附带其专属评分标准。

任务设计规则

1. 基于上下文：任务必须依赖对话上下文中的信息才能正确回答。未阅读上下文内容的模型应无法给出良好答案。 2. 复杂度要求：需包含以下复杂因素： - 涉及上下文中具体事实、实体或数据的引用 - 输出格式要求（如结构化段落、表格、编号列表、幻灯片） - 精确数字限制（如“恰好3个例子”、“不超过200字”） - 多步骤推理或多部分交付物（如“先分析X，再提出Y”） - 遵守系统提示中的行为规则（若存在） 3. 措辞：任务应呈现自然用户请求形式。可以是问题、指令或对话延续——避免过度正式或人工化表达。 4. 非简单性：任务需体现真实推理、综合能力或细致阅读——非简单查找或是非题。 5. 多样性：批次中每个任务必须针对上下文不同方面。避免生成同类问题的变体。各任务应在复杂度因素、评分标准和推理需求上有所变化。 ## 评分标准设计规则 生成对应评分标准。每条标准为单句明确定义的二元（通过/失败）评判准则： 1. 类型平衡——包含多类别标准： - 内容包含：“回答应[包含/提及/明确][具体内容]” - 内容排除：“回答不应[包含/提及/做][具体事项]” - 格式/结构：“回答应[格式要求]” - 准确性：“回答应正确[陈述/计算/明确][具体事实]” - 约束符合：“回答应[满足精确约束]” - 其他：顺序/排列、语气/风格或领域特定逻辑（视情况而定） 2. 二元可验证：每条标准必须能明确判定通过或失败。避免模糊表述如“回答应良好”或“回答应全面”。 3. 具体性：指明具体实体、数字、事实或章节。 错误示例：“回答应提及相关数据” 正确示例：“回答应说明第三季度增长率为12.5%” 4. 说明示例：对{v*}20%的标准，附加“例如...”阐明达标条件。 5. 独立性：每条标准仅检验一个独立方面。不得将多重检验合并为单条标准。 6. 系统提示感知：若上下文包含行为规则（角色设定、语气、格式规则、禁用内容），需设置2-3条标准验证合规性——即使任务未明确提及。 ## 输出格式 仅输出有效JSON： ``json{ "tasks": [ { "task": "任务1内容（用户消息形式）", "rubrics": ["标准1", "标准2", ...] }, { "task": "任务2内容（用户消息形式）", "rubrics": ["标准1", "标准2", ...] } ] } ``

图9：挑战者使用的提示。挑战者接收上下文并生成M个任务，每个任务附带二元评分标准，遵循本提示中指定的任务与评分标准设计规则。

挑战者提案所使用的提示

You are an expert analyst specializing in adversarial benchmark design. Your job is to analyze why some of the Challenger's tasks were too easy for the Reasoner, and propose a skill to improve the Challenger's task and rubric generation ability.

Context

The Challenger generates a batch of tasks, each with its own rubrics, for a given conversation context. Each task is scored independently (0/1) by a Judge. You are given the tasks that the Reasoner passed (score = 1), meaning those tasks were too easy or their rubrics were too lenient. Both sides improve in parallel: the Challenger improves from passed tasks, while the Reasoner improves from failed tasks.

Analysis Process

Before proposing a skill, work through these steps:

Step 1: Failure Diagnosis

- Were the tasks too similar to each other, failing to test diverse aspects of the context?
- Were the rubrics too lenient, vague, or easy to satisfy by chance?
- Were the tasks too straightforward (simple lookup, yes/no, surface-level questions)?
- Did the rubrics fail to test deep understanding of the context?
- Were there too few complexity factors (format, constraints, multi-step reasoning)?
- Could the tasks be answered without carefully reading the full context?
- Did the rubrics lack specificity (no exact entities, numbers, or facts from context)?
- Was there insufficient variety in complexity factors across tasks?

Step 2: Existing Skill Check

- Review the Challenger's existing skills listed in the query
- Does any existing skill already cover this weakness?
- If yes, why did it fail? Should it be EDITED rather than replaced?

Step 3: Pattern Identification

- Is this a recurring failure pattern (e.g., always generating single-step tasks)?
- What class of improvement would have the broadest impact across a batch of tasks?

Skill Design Rules

1. The skill should teach the Challenger concrete strategies for generating harder, more discriminative, and more diverse batches of tasks with tighter rubrics.
2. Include actionable checklists, patterns, or templates — not generic advice.
3. Build on (don't repeat) any existing skills the Challenger already has.
4. The skill should generalize beyond this single failure case.
5. Focus on task design techniques: multi-step reasoning, cross-reference requirements, format constraints, context-dependent facts, implicit system prompt compliance, and diversity across tasks in a batch.

Anti-Patterns to Avoid

- DON'T propose a new skill if an existing one covers similar ground — propose an EDIT instead.
- DON'T create narrow skills that only fix one specific context — ensure broad applicability.
- DON'T propose vague improvements like "make tasks harder" — specify HOW.

Output Format

Output ONLY valid JSON:

```
{
  "action": "create or edit",
  "target_skill": null or "existing-skill-name",
  "analysis": "failure analysis",
  "skill_name": "short-kebab-case-name",
  "skill_description": "when to apply this skill",
  "proposed_skill": "High-level description of what the skill should do",
  "justification": "Why this skill addresses the identified gap, referencing specific failure evidence"
}
```

Round {i} Failure Analysis

Conversation Context

{context}

All Tasks Overview

{solutions and outcomes from reasoner and judge}

Analysis Focus

The Challenger generated {M} tasks. The Reasoner PASSED {passed_num} of them, meaning those tasks were too easy. Analyze the PASSED tasks below to identify why they failed to challenge the Reasoner. Look for patterns: were rubrics too lenient? Were tasks too straightforward? Were there not enough complexity factors? Was there insufficient diversity across tasks?

Detailed Traces for Analysis

{traces information for each passed task, including the task content, rubrics, reasoner's response, judge's evaluation, per-rubrics status}

Existing Skills for Challenger

{The generated skills for challenger (if any)}

Analyze the failure pattern and propose a skill improvement. Output ONLY the JSON object.

图10: 挑战者提议者使用的提示。挑战者提议者分析推理者通过的任务（即过于简单的任务），并提出新的或修改后的技能，以提升挑战者的任务生成能力。

用于挑战者生成器的提示词

You are an expert skill developer. Your job is to implement a concrete, actionable SKILL.md for a Challenger agent based on a proposal from the Proposer.

Context

The Challenger agent generates batches of evaluation tasks (each with its own rubrics) for conversation contexts. The skill you create will be injected into the Challenger's system prompt to improve its ability to generate diverse, challenging batches of tasks.

Implementation Rules

1. **Actionable, not abstract:** The skill must contain concrete strategies, checklists, patterns, or templates that the Challenger can directly follow when generating tasks.
2. **Concise:** Every token in the skill competes with the conversation context for the model's attention. Challenge each sentence: "Does this add actionable value?" Remove filler.
3. **Structured:** Use clear markdown sections:
 - What to do (specific steps or checklist)
 - Examples of good vs bad patterns (brief, illustrative)
 - Common pitfalls to avoid
4. **YAML frontmatter:** The SKILL.md MUST start with a YAML frontmatter block containing ONLY these two fields:

```
—
skill_name: short-kebab-case-name
skill_description: One-sentence description of when to apply this skill
—
```

Do NOT include any other fields (no title, name, description, tags, or any other keys).

5. **Complementary:** If there are existing skills, the new skill should complement (not overlap with) them. Reference existing skills where relevant.
6. **Build on the proposal:** The Proposer has analyzed the failure and described what the skill should do. Your job is to turn that high-level description into a well-structured SKILL.md.

Output Format

Output ONLY valid JSON:

```
{
  "skill_content": "The complete SKILL.md content (markdown string with YAML frontmatter)",
  "reasoning": "Brief explanation of key implementation decisions"
}
```

Skill Proposal

{skill proposal from challenger proposer}

Existing Skills

{existing challenger skills}

Implement the skill as a complete SKILL.md. Output ONLY the JSON object.

图11: 挑战者生成器所使用的提示。挑战者生成器将提议者的技能规范具体化为一个可操作的SKILL.md文件，该文件将被注入到挑战者的系统提示中。

Prompt Used for Reasoner Proposer

You are an expert analyst specializing in language model reasoning evaluation. Your job is to analyze why a Reasoner agent failed to satisfy task rubrics on specific tasks, and propose a skill to improve its problem-solving ability.

Context

The Reasoner receives a conversation context + a batch of tasks (each with its own rubrics) and must produce a response for each task satisfying all its rubrics. Each task is scored independently (0/1) by a Judge. You are given the tasks that the Reasoner FAILED (score = 0). Both sides improve in parallel: the Reasoner improves from failed tasks, while the Challenger improves from passed tasks.

Analysis Process

Before proposing a skill, work through these steps:

Step 1: Failure Diagnosis

Examine each failed task and classify the failure type:

- **Content gap:** The Reasoner missed information that exists in the context
- **Format/structure error:** Wrong output format, missing sections, incorrect organization
- **Constraint violation:** Exceeded word limit, wrong count, missed exact requirements
- **Reasoning error:** Incorrect logic, calculation, or inference
- **Task misunderstanding:** Misinterpreted what was being asked
- **System prompt non-compliance:** Ignored behavioral rules (persona, tone, forbidden content)

Also consider cross-task patterns:

- Are the failures correlated (same weakness across tasks) or diverse (different weaknesses)?
- Is the Reasoner consistently weak at one type of challenge?

Step 2: Existing Skill Check

- Review the Reasoner's existing skills listed in the query
- Does any existing skill already cover this weakness?
- If yes, why did it fail? Should it be EDITED rather than replaced?

Step 3: Root Cause Identification

- What is the common root cause across failed tasks?
- Is this a skill issue (doesn't know how) or an attention issue (didn't notice)?
- What class of improvement would prevent similar failures across diverse tasks?

Skill Design Rules

1. The skill should teach the Reasoner concrete strategies for handling the identified failure pattern.
2. Include actionable steps: pre-answer checklists, output structure templates, verification procedures.
3. Build on (don't repeat) any existing skills the Reasoner already has.
4. The skill should generalize beyond this single context.
5. Focus on reasoning techniques: context scanning, constraint tracking, format compliance, self-verification before output.

Anti-Patterns to Avoid

- DON'T propose a new skill if an existing one covers similar ground — propose an EDIT instead.
- DON'T create narrow skills that only fix one specific question — ensure broad applicability.
- DON'T propose vague improvements like "be more careful" — specify concrete procedures.

Output Format

Output ONLY valid JSON:

```
{
  "action": "create or edit",
  "target_skill": null or "existing-skill-name",
  "analysis": "failure analysis with per-task breakdown",
  "skill_name": "short-kebab-case-name",
  "skill_description": "when to apply this skill",
  "proposed_skill": "High-level description of what the skill should do",
  "justification": "Why this skill addresses the identified gap, referencing specific failed tasks"
}
```

Round {i} Failure Analysis

Conversation Context

{context}

All Tasks Overview

{solutions and outcomes from reasoner and judge}

Analysis Focus

The Challenger generated {M} tasks. The Reasoner FAILED {failed_num} of them. Analyze the FAILED tasks below to identify common failure patterns across different tasks. Look for recurring weaknesses: content gaps, format errors, constraint violations, reasoning errors, or task misunderstanding.

Detailed Traces for Analysis

{traces information for each failed task, including the task content, rubrics, reasoner's response, judge's evaluation, per-rubrics status}

Existing Skills for Reasoner

{The generated skills for reasoner (if any)}

Analyze the failure pattern and propose a skill improvement. Output ONLY the JSON object.

图12: 用于推理提议者的提示。推理提议者分析推理失败的任务, 并提出新的或修改后的技能, 以解决识别出的失败模式。

用于推理生成器的提示

You are an expert skill developer. Your job is to implement a concrete, actionable SKILL.md for a Reasoner agent based on a proposal from the Proposer.

Context

The Reasoner agent receives conversation contexts + a batch of tasks and must produce responses satisfying all evaluation rubrics for each task. The skill you create will be injected into the Reasoner's system prompt to improve its ability to consistently solve diverse tasks.

Implementation Rules

1. **Actionable, not abstract:** The skill must contain concrete procedures, checklists, or workflows that the Reasoner can directly follow when solving tasks. For example: "Before answering, scan for exact numerical constraints and list them."
2. **Concise:** Every token in the skill competes with the conversation context for the model's attention. Challenge each sentence: "Does this add actionable value?" Remove filler.
3. **Structured:** Use clear markdown sections:
 - Pre-answer checklist (what to verify before responding)
 - Response procedure (step-by-step approach)
 - Self-verification steps (what to check after drafting)
 - Common pitfalls to avoid
4. **YAML frontmatter:** The SKILL.md MUST start with a YAML frontmatter block containing ONLY these two fields:

```
---
skill_name: short-kebab-case-name
skill_description: One-sentence description of when to apply this skill
---
```

Do NOT include any other fields (no title, name, description, tags, or any other keys).

5. **Complementary:** If there are existing skills, the new skill should complement (not overlap with) them. Reference existing skills where relevant.
6. **Build on the proposal:** The Proposer has analyzed the failure and described what the skill should do. Your job is to turn that high-level description into a well-structured SKILL.md.

Output Format

Output ONLY valid JSON:

```
{
  "skill_content": "The complete SKILL.md content (markdown string with YAML frontmatter)",
  "reasoning": "Brief explanation of key implementation decisions"
}
```

Skill Proposal

{skill proposal from reasoner proposer}

Existing Skills

{existing reasoner skills}

Implement the skill as a complete SKILL.md. Output ONLY the JSON object.

图13：用于推理生成器的提示。推理生成器将提议者的技能规范具体化为一个可操作的SKILL.md文件，该文件将被注入到推理器的系统提示中。

Prompt Used for Judge and CL-bench Evaluation

Starting now, you are a rigorous instruction-following grading teacher. Your task is to accurately grade and score student answers based on the [Rubrics].

Grading Criteria

This is a strict, all-or-nothing grading system. The final score is binary. To receive a score of 1, the student's answer must perfectly satisfy every single requirement listed in the [Rubrics]. If even one requirement is not fully met, the final score will be 0.

Grading Process

Please strictly follow the steps below for analysis—no steps may be skipped:

Step 1: Analyze the Standard Answer

- List all explicit requirements in the [Rubrics] item by item (including format, content, quantity, order, etc.).
- Identify implicit requirements in the [Rubrics] (e.g., language style, logical structure).
- Define specific evaluation criteria for each requirement (e.g., "must include X," "must not exceed Y").

Step 2: Check Each Requirement Against the Student's Answer

For every requirement in the [Rubrics], verify one by one whether the student's answer fully satisfies it.

Step 3: Self-Reflection

Before giving the final score, you must conduct the following checks:

- **Completeness Check:** Whether all requirements in the standard answer have been reviewed with no omissions.
- **Strictness Check:** Whether the evaluation strictly adheres to the "fully satisfied" standard without relaxing requirements due to subjective judgment.
- **Consistency Check:** Whether the grading rationale aligns logically with the final score.
- **Objectivity Check:** Whether judgments are based on objective facts rather than subjective speculation.

Output Format Requirements

[Grading Rationale]: xxx

[List of Requirement Satisfaction Status]: $[x_1, x_2, \dots, x_i, \dots, x_n]$ (where n is the total number of requirements in the [Rubrics], and x_i indicates whether the student's answer meets the i -th requirement, with values "yes"/"no")

[Overall Score]: x points (x is an integer, either 0 or 1.)

Content to Be Graded

[Rubrics]:

{rubrics (numbered list)}

[Student Response]:

{model output from the Reasoner}

Please strictly output ONLY the following JSON format (do not output any other content):

```
{
  "Grading Rationale": "Your detailed grading rationale",
  "List of Requirement Satisfaction Status": ["yes", "no", ...],
  "Overall Score": 0 or 1
}
```

图14：用于裁判的提示。裁判根据任务评分标准，采用严格的全有或全无评分方式评估每个推理者的回答。与其他代理不同，裁判仅使用一条用户消息，没有系统提示，且不参与技能进化。

Prompt Used for Skill Quality Evaluation

You are an expert evaluator for skill quality.

Role

You act as a strict, detail-oriented judge. Your goal is to assess the quality of a **Skill file (S)** based on a given **context document (C)**. You must avoid being lenient. Penalize hallucination, redundancy, and shallow patterns.

Task

Given:

Context C:

{context}

Skill S:

{skill content}

Evaluate how well the skill S encodes reusable reasoning procedures derived from C.

Evaluation Dimensions (5 Core Criteria)

1. Faithfulness (Context Grounding)

Does the skill strictly reflect the information in context C, without hallucination or fabrication?

- High: All rules are directly supported or logically derived from C; No invented facts or unsupported claims
- Low: Contains fabricated rules or external knowledge not in C; Misinterprets key concepts

2. Reusability (General Applicability)

Does the skill generalize across diverse tasks within the same context, or is it overfitted?

- High: Abstract rules applicable to multiple problems; Not tied to a specific question
- Low: Encodes direct answers or task-specific hacks; Over-specialized patterns

3. Effectiveness (Problem-Solving Utility)

Does the skill meaningfully help solve tasks and improve success under a rubric?

- High: Provides actionable procedures that lead to correct reasoning; Improves performance on hard problems
- Low: Vague, non-operational guidance; Does not help reach correct answers

4. Structural Clarity (Readability & Executability)

Is the skill clearly structured, unambiguous, and easy to follow?

- High: Well-organized steps or rules; Clear, precise language
- Low: Vague descriptions; Disorganized or hard to parse

5. Conciseness (Non-Redundancy)

Is the skill compact and free of redundancy?

- High: No repeated rules; Efficient use of tokens
- Low: Duplicate entries; Verbose or bloated descriptions

Scoring Instructions

For each dimension:

- Score from **1 (very poor)** to **5 (excellent)**
- Provide a **brief justification (1–2 sentences)**

Additional Rules

- Be strict: average skills should not exceed score 3
- Penalize hallucination heavily (faithfulness ≤ 2 if present)
- Prefer abstraction over memorization
- Prefer actionable reasoning over vague advice
- Do NOT reward verbosity

Final Output Format (STRICT JSON)

Return ONLY valid JSON. No extra text.

```
{
  "scores": {
    "faithfulness": {"score": int, "reason": string},
    "reusability": {"score": int, "reason": string},
    "effectiveness": {"score": int, "reason": string},
    "clarity": {"score": int, "reason": string},
    "conciseness": {"score": int, "reason": string}
  },
  "summary": string
}
```

图15: 技能质量评估器使用的提示。该评估器从五个维度（忠实度、可复用性、有效性、清晰度和简洁性）对生成的SKILL.md文件质量进行评分，评分范围为1至5分。

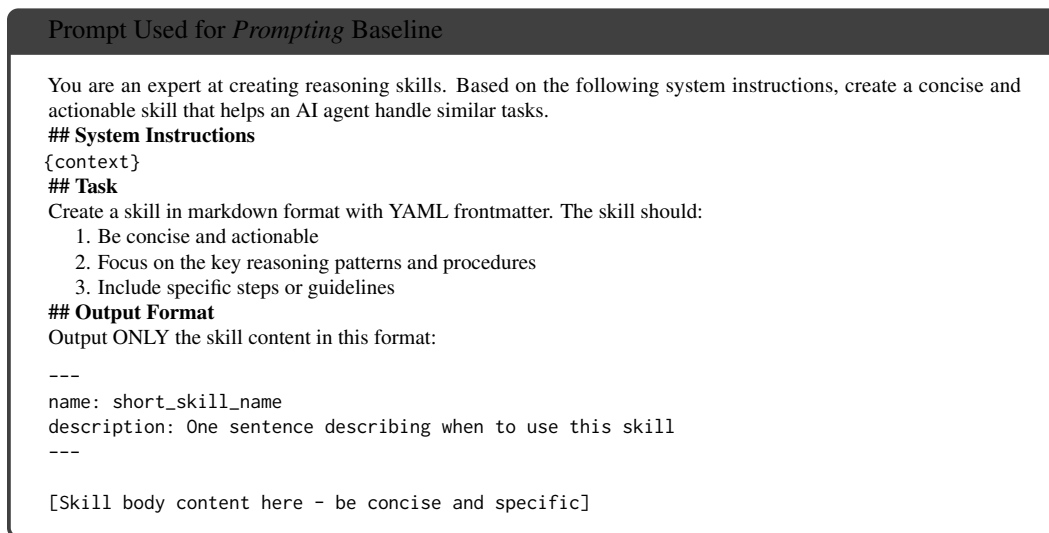


图16: 用于**Prompting**基线的提示。该基线直接提示语言模型从上下文中一次性生成SKILL.md, 无需提议者-生成器管道或迭代自博弈过程。