

深思而非仅久思：通过深度思考标记 衡量大语言模型的推理努力

陈伟林^{1,2*}、彭立谦²、谭天²、赵超²、陈建航²、林子骞²、高亚历²、孟昱¹，弗吉尼亚大学，²谷歌，*以学生研究员身份在谷歌完成工作。

1

大型语言模型（LLMs）通过长链思维（CoT）扩展测试时计算，展现了令人瞩目的推理能力。然而，最新研究发现原始标记计数作为推理质量的指标并不可靠：生成长度的增加并不总是与准确性相关，反而可能暗示“过度思考”，导致性能下降。在本研究中，我们通过识别`deep-thinking tokens`——即模型深层在收敛前发生显著修正的内部预测标记，量化了推理时的努力程度。在四个具有挑战性的数学与科学基准测试（AIME 24/25、HMMT 25和GPQA-diamond）及一系列专注于推理的多样化模型（GPT-OSS、DeepSeek-R1和Qwen3）上，我们证明`deep-thinking ratio`（生成序列中深度思考标记的比例）与准确性呈现稳健且持续的正相关关系，显著优于基于长度和置信度的基线方法。基于这一发现，我们提出了Think@ n 策略——一种测试时扩展方法，优先选择具有高深度思考比例的样本。实验表明，Think@ n 在匹配或超越标准自治性表现的同时，通过基于短前缀提前拒绝低潜力生成，大幅降低了推理成本。




图1 | 准确度与思维努力代理指标相关性对比。图中展示了在AIME 2024/2025、HMMT 2025和GPQA-Diamond数据集上，GPT-OSS-120B-medium模型性能与两项推理时思维努力度量指标的关系。(Left) 输出token数量呈现中等负相关（平均 $r = -0.544$ ），表明输出长度是不可靠的性能指标。(Right) 相比之下，我们提出的深度思考比率与准确度呈现强正相关（平均 $r = 0.828$ ）。

1. 引言

大型语言模型（LLMs）通过生成显式的思维轨迹，显著提升了推理能力，其中思维链（CoT）范式（Wei等人，2022）尤为突出。先前研究表明，增加生成的推理标记数量通常能提升任务表现（Anthropic, 2025a,b; Guo等人，2025; Jaech等人，2024; OpenAI, 2025; Team等人，2025; Yang等人，2025; Zhong等人，2024），这推动了鼓励生成更长、更精细思维轨迹的方法发展（Balachandran等人，2025; Muennighoff等人，2025; Yeo等人，2025）。

然而，越来越多的证据表明，在推理过程中，令牌计数并非模型性能的可靠指标，因为更长的推理过程并不总是意味着更高的准确性（Aggarwal等人，2025; Su等人，2025; Sui等人，2025; Wu等人，2025）。实证研究揭示了思维链长度与性能之间的倒U型关系（Wu等人，2025），以及逆向缩放行为——即更长的推理痕迹会系统性降低性能（Gema等人，2025）。过度的推理可能反映了过度思考，模型在其中放大了有缺陷的启发式方法或固着于无关细节（Feng等人，2025）。因此，依赖长度作为推理质量的衡量标准不仅鼓励了冗长而非清晰，还浪费了计算资源在无信息量的令牌上。尽管最近的研究尝试评估思维链的语义结构（例如，通过将推理痕迹表示为图），这些方法往往依赖于昂贵的辅助解析或外部注释（Feng等人，2025）。要解决这些局限，需要更原则性和高效的方法来衡量思考努力，以区分有效推理和无信息量的生成。

在本工作中，我们引入*deep-thinking ratio* (DTR)作为推理时思维努力程度的直接衡量指标。不同于依赖输出长度等表层特征，我们聚焦于单个词元在模型内部的生成过程。我们提出：当词元预测在浅层网络就趋于稳定时，后续深度方向的修正所消耗的计算努力相对较低，类似于*less thinking*；反之，若词元预测需要在深层网络持续调整才能收敛，则反映了*greater thinking*（Chuang等人，2023）提出的现象。我们将这一理念操作化为：将中间层隐藏状态投射至词表空间，逐层比较其预测分布与最终层分布的差异。那些直到深层网络分布才收敛的词元被标记为*deep-thinking tokens*。通过统计生成序列中深度思考词元的比例，我们获得DTR指标——该指标无需任务特定启发规则或外部结构标注，即可提供一种机理明确、计算简洁的思维努力度量方法。

在四项具有挑战性的数学与科学推理基准测试——AIME 2024、AIME 2025、HMMT 2025以及GPQA（Art of Problem Solving, 2024a,b, 2025a,b; HMMT, 2025; Rein等人，2024）——以及一系列以推理为核心的语言模型（包括GPT-OSS、DeepSeek-R1和Qwen3系列（Guo等人，2025; OpenAI等人，2025; Yang等人，2025））中，我们证明通过测量深度思考标记{v*}能够与任务准确率呈现强相关性。所获得的相关性显著高于基于长度或置信度的基线方法。此外，我们还展示了深度思考标记{v*}可用于并行推理扩展，其中优先选择并聚合具有更高DTR的响应，其性能可媲美甚至优于标准的基于共识的方法，同时仅需一半的计算成本。我们的贡献总结如下：

- 我们引入*deep-thinking ratio* (DTR)——一种衡量序列中*deep-thinking tokens*比例的方法，这些预测在收敛前需经过更深层次的持续修正——以此作为表征推理时思维努力的新视角。
- 我们通过实证研究表明，在多个推理基准测试和模型家族中，生成序列的DTR与任务准确性呈现出强烈的正相关性，其表现显著优于基于长度和基于置信度的基线方法。




图2| 思维热力图：我们绘制了GPT-OSS-120B-high生成的一个答案序列最后一层（第36层）与中间层之间分布的詹森-香农散度（JSD）值。功能性和模板化词汇（如“和”、“是”、“boxed”、“<|return|>”）通常在较浅层即趋于收敛；而操作符后接的补全内容（如“+”、“=”）及答案标记/符号（如“13”、“(D)”）则需到更深层才稳定。值得注意的是，答案标记“13”在首次出现后，会逐渐在更深的层中显现。

- 我们介绍了Think@{v*}，一种测试时扩展策略，它优先选择并聚合具有更高DTR的样本。通过基于短前缀估计的DTR提前终止无望的生成，Think@{v*}以大约一半的推理成本达到或超越了标准自一致性方法的效果。

2. 测量深度思考比率

2.1. 预备知识

我们考虑一个自回归语言模型 f_θ ，它由 L 个Transformer层、隐藏维度 d 和词汇表 V 组成。给定前缀序列 $y_{<t}$ ，在生成步骤 t 的前向传播过程中会产生一系列残差流状态 $\{h_{t,l}\}_{l=1}^L$ ，其中 $h_{t,l} \in \mathbb{R}^d$ 表示第 l 层之后的隐藏状态。最终层的输出 $h_{t,L}$ 通过语言建模头（即解嵌入矩阵） $W_U \in \mathbb{R}^{|V| \times d}$ 投影，生成词汇表上的逻辑值。

关于早期退出机制的先期研究（Belrose等人，2023；Din等人，2024；Elbayad等人，2019；Schuster等人，2022；Teerapittayanon等人，2016）已表明，在无需专门辅助训练的情况下，直接将语言建模头应用于中间层隐藏状态能有效生成有意义的预测分布（Kao等人，2020；Nostalgebraist，2020）。基于这一系列研究，我们使用相同的解嵌入矩阵 W_U 将中间层隐藏状态投影至词汇空间。对于每个中间层 $l \in \{1, \dots, L-1\}$ ，我们计算对数几率向量 $z_{t,l}$ 和概率分布 $p_{t,l}$ 如下：

$$p_{t,l} = \text{softmax}(z_{t,l}), \quad z_{t,l} = W_U h_{t,l} \quad (1)$$

模型的最终层分布由 $p_{t,L}$ 表示。




图3 | 我们识别深度思考token方法的示意图。假设一个具有10层的模型，通过设置深度分数 $\rho=0.8$ ，该token在生成步骤 t 时被成功分类为深度思考token，因为其与最终层分布的JSD值首次低于阈值 g ，直至进入迟滞阶段

。

Algorithm 1: Computing Deep-Thinking Ratio (DTR)

Input : Autoregressive LM f_θ with L layers and unembedding matrix W_U ; Input prompt x ; Threshold g ; Depth fraction ρ

Output : DTR(S) of the generated sequence S

```

 $C \leftarrow 0$ ; // deep thinking token count
 $S \leftarrow \emptyset$ ; // generated sequence
 $y_t \leftarrow [\text{BOS}]$ ; // initialize with start token
while  $y_t \neq [\text{EOS}]$  do
    Sample  $y_t \sim p_{t,L}(f_\theta(\cdot | x, S))$ ;
     $S \leftarrow (S, y_t)$ ;
    for  $l \leftarrow 1$  to  $L$  do
         $p_{t,l} \leftarrow \text{softmax}(W_U h_{t,l})$ ;
         $D_{t,l} \leftarrow \text{JSD}(p_{t,L}, p_{t,l})$ ;
    end
     $c_t \leftarrow \min\{l : \min_{j \leq l} D_{t,j} \leq g\}$ ;
    if  $c_t \geq \lceil (1 - \rho)L \rceil$  then
         $C \leftarrow C + 1$ ;
    end
end
return  $C/|S|$ ;

```

2.2. 深度思考令牌

我们假设，对某个标记的推理时思考努力表现为预测分布（即 $\{v^*\}$ ）在语言模型各层间的持续演变。分布较早稳定的标记对应较少的额外思考，而稳定较晚的标记则需要更持久的内部思考。换言之，简单标记通过浅层计算即可早期稳定，而需要更多思考的困难标记则会在更深层次通过更多计算呈现分布变化。为说明这一点，图2展示了一个回答GQPA（Rein等人，2024）问题的动机示例。

为了量化这一行为，我们测量了一个token的预测分布在 $settling$ 之前持续变化的时长，具体操作是将中间分布与最终层分布足够接近时的层数作为衡量标准。具体而言，对于每个生成步骤 t 和层 l ，我们计算中间层分布 $p_{t,l}$ 与最终层分布 $p_{t,L}$ 之间的Jensen-Shannon散度(JSD)：

$$\begin{aligned}
 D_{t,l} &:= \text{JSD}(p_{t,L} \| p_{t,l}) \\
 &= H\left(\frac{p_{t,L} + p_{t,l}}{2}\right) - \frac{1}{2}H(p_{t,L}) - \frac{1}{2}H(p_{t,l}),
 \end{aligned} \tag{2}$$

其中 $H(\cdot)$ 表示香农熵。根据构造， $D_{t,L} = 0$ 。一条轨迹 $l \mapsto D_{t,l}$ 若仅在后续层趋近于零，则表明存在持续的分布修正（需更多思考），而早期收敛则意味着模型以较少的后续更新确定了最终预测（需较少思考）。我们采用JSD是由于其对称性和有界性，遵循(Chuang et al., 2023)的做法。其他距离度量的探讨详见附录A节。

为了强制执行严格的稳定概念，我们计算：

$$\bar{D}_{t,l} = \min_{j \leq l} D_{t,j}. \quad (3)$$

我们将沉降深度 c_t 定义为 $\bar{D}_{t,l}$ 首次低于固定阈值 g 的层：

$$c_t = \min \{l \in \{1, \dots, L\} : \bar{D}_{t,l} \leq g\}. \quad (4)$$

随后，我们通过深度分数 $\rho \in (0, 1)$ 定义一个深度思考机制，其中

$$\mathcal{L}_{\text{deep-thinking}} = \{l : l \geq \lceil \rho \times L \rceil\}. \quad (5)$$

一个标记被归类为深度思考标记（即需要更多层计算和更多思考努力才能足够接近最终层分布），如果 $c_t \in \mathcal{L}_{\text{deep-thinking}}$ 。图示如图3所示。

最后，对于一个长度为 T 的生成序列 s ，我们定义了深度思考比率 $\text{DTR}(s)$ ，用于 s 序列作为在后期体制中稳定的标记比例：

$$\text{DTR}(s) = \frac{1}{T} \sum_{t=1}^T \mathbb{1}[c_t \in \mathcal{L}_{\text{deep-thinking}}]. \quad (6)$$

较高的DTR表明，更大比例的标记在稳定前需经历扩展计算以进行分布修正。我们指出，所提出的方法并不意味着提前确定的标记次优；相反，它提供了推理时思维努力的深度特征，与表层标记长度测量形成互补。我们在算法1中展示了DTR的整体算法流程，并在附录E部分提供了定性分析实例。

3. 深度思考比率更可靠地反映任务准确度

我们实证评估了基于分布距离的测量方法是否比表面层次、基于长度的代理指标（如标记计数）更能忠实且稳健地表征推理时的思维努力。

模型。我们评估了来自三个模型家族的八种推理大语言模型变体：GPT-OSS-20B（具备低、中、高三种推理级别）和GPT-OSS-120B（具备低、中、高三种推理级别）（OpenAI等人，2025年）、DeepSeek-R1-70B（郭等人，2025年） $\{\mathbf{v}^*\}$ 以及Qwen3-30B-思维版（杨等人，2025年）。这些模型以其在数学和复杂推理方面强大的长链思维（CoT）能力著称，并覆盖多种参数规模以实现全面覆盖。

任务。我们聚焦于推理密集型的基准测试，在这些测试中，扩展思维链式（CoT）计算在推理阶段扮演着核心角色。我们采用了近期大语言模型（LLM）推理能力评估中广泛使用的四项基准（Balunovi 等人，2025；OpenAI，2025；xAI，2025），包括三个竞赛级数学题集：AIME 2024（解题的艺术，2024a,b）、AIME 2025（解题的艺术，2025a,b）和HMMT 2025（HMMT，2025），以及GPQA的钻石级试题集（Rein等人，2024），该试题集由具有挑战性的研究生级别科学问题组成。

¹For brevity, we refer DeepSeek-R1-70B to Llama-3.3-70B-Instruct distilled with DeepSeek-R1 generated samples (<https://huggingface.co/deepseek-ai/DeepSeek-R1-Distill-Llama-70B>).

解码设置。遵循(Gema等人, 2025)的方法, 我们使用固定、中性的指令提示模型进行逐步推理, 不指定推理预算或明确鼓励更长时间的思考。这种设置允许每个模型在单个实例基础上自然分配推理时间计算, 避免了由外部强加的标记预算或预算条件提示引入的混淆变量。根据自然过度思考分析的标准实践(Gema等人, 2025), 我们对每个问题采样多个回答(实验中每个问题25个回答)。在这些样本中, 模型自然展现出推理长度和内部计算模式的差异。所有测试模型均采用开发者推荐的采样参数: GPT-OSS系列使用温度=1.0和top $p=1.0$; DeepSeek-R1-70B和Qwen-3-30B-Thinking使用温度=0.6和top $p=0.95$ 。

对于每个采样的响应, 我们记录中间层的隐藏状态, 获取其投影概率分布, 并按照第2节所述计算DTR。我们统一设定判定阈值 $g=0.5$ 和深度比例 $\rho=0.85$ 来定义深度思考机制。同时, 我们还分析了不同参数值的影响, 相关结果在第3.2节中给出。报告统计量均基于30个随机种子在解码过程中的平均值。

3.1. 结果

为了量化推理时的思考投入与任务表现之间的关系, 我们通过计算皮尔逊相关系数来衡量思考投入分数与答案准确性之间的关联。具体而言, 我们采用(Gema等人, 2025年)提出的分箱分析方法, 将采样序列根据其DTR(公式(6))划分为分位数箱(即5个箱), 并计算每个箱内的平均准确率。

我们将深度思考的标记测量与以下基线进行比较, 包括长度-
b基于代理和置信度的方法, 这些方法也常被用来评估生成——
t离子质量。

标记计数。模型输出推理轨迹中生成的标记总数。该指标被广泛视为测试时计算的直接代理, 并且是许多推理时间缩放实证研究的基础(Anthropic, 2025a,b; Guo et al., 2025; Jaech et al., 2024; OpenAI, 2025; Team et al., 2025; Yang et al., 2025; Zhong et al., 2024)。

逆向标记计数。作为补充基线, 我们额外考虑了逆向标记计数, 其定义为每个响应生成的总标记数的负值。引入这一转换是为了解释大型语言模型(LLM)在过度思考时, 推理长度与准确性之间常见的反向关系(Gema等人, 2025; Wu等人, 2025)。

L原始概率。沿用第2节的符号表示, 设生成的序列为 $\{v^*\}$ 。在
g生成步骤 t , 模型在词汇表 $\mathcal{V}$ 上的输出预测分布(位于最终层 L)
璦 $\{v^*\}$ 表示。我们计算采样标记的平均对数概率:

$$\text{LogProb}(S) = \frac{1}{T} \sum_{t=1}^T \log p_{t,L}(y_t) \quad (7)$$

H较高的值表示模型对其自身生成的样本赋予更高的似然度, 通常
璦解释为更高的置信度。

表1 | 展示了八个模型变体在四个推理基准测试中，任务准确性与不同推理时度量（包括基于长度和基于置信度的基线）之间的皮尔逊相关性。相关性数值采用颜色编码：强正相关（0.5 ~ 1）用深绿色表示，弱正相关（0 ~ 0.5）用浅绿色表示，弱负相关（-0.5 ~ 0）用浅橙色表示，强负相关（-1 ~ -0.5）用深橙色表示。

	Token Length	Reverse Token Length	Log Probability	Negative Perplexity	Negative Entropy	Self-Certainty	DTR (Ours)
<i>AIME 2025</i>							
OSS-120B-low	0.504	-0.504	0.872	0.453	0.863	0.803	0.930
OSS-120B-medium	-0.365	0.365	0.817	0.246	0.822	0.815	0.862
OSS-120B-high	-0.961	0.961	0.705	0.552	0.711	0.728	0.796
OSS-20B-low	-0.689	0.689	0.579	0.849	0.665	0.275	0.373
OSS-20B-medium	-0.757	0.757	0.616	-0.677	0.637	0.097	0.161
OSS-20B-high	-0.385	0.385	0.455	-0.795	0.550	0.489	0.610
DeepSeek-R1-70B	-0.973	0.973	0.961	0.955	0.946	0.899	0.974
Qwen3-30B-Thinking	-0.663	0.663	-0.008	-0.035	0.154	0.828	0.855
<i>AIME 2024</i>							
OSS-120B-low	-0.166	0.166	0.897	0.682	0.869	0.741	0.840
OSS-120B-medium	-0.680	0.680	0.795	-0.293	0.908	0.924	0.533
OSS-120B-high	-0.755	0.755	0.700	-0.275	0.593	0.654	0.905
OSS-20B-low	-0.655	0.655	0.548	-0.342	0.667	0.584	0.730
OSS-20B-medium	-0.827	0.827	0.195	-0.150	0.440	0.252	-0.192
OSS-20B-high	-0.989	0.989	0.809	0.262	0.921	0.855	0.824
DeepSeek-R1-70B	-0.987	0.987	-0.037	0.223	0.067	0.287	0.430
Qwen3-30B-Thinking	-0.869	0.869	-0.857	-0.720	-0.680	-0.246	-0.657
<i>GPQA-Diamond</i>							
OSS-120B-low	0.682	-0.682	0.984	0.172	0.995	0.996	0.976
OSS-120B-medium	-0.340	0.340	0.973	0.316	0.985	0.981	0.823
OSS-120B-high	-0.970	0.970	0.854	0.501	0.813	0.885	0.845
OSS-20B-low	-0.602	0.602	0.984	0.235	0.991	0.917	0.935
OSS-20B-medium	-0.847	0.847	0.914	0.468	0.911	0.889	0.718
OSS-20B-high	-0.794	0.794	0.879	0.461	0.902	0.915	0.992
DeepSeek-R1-70B	-0.930	0.930	0.068	-0.133	-0.165	-0.532	0.885
Qwen3-30B-Thinking	-0.634	0.634	0.589	0.865	0.711	0.943	0.828
<i>HMMT 2025</i>							
OSS-120B-low	0.871	-0.871	0.761	0.629	0.695	0.884	0.305
OSS-120B-medium	-0.793	0.793	0.706	0.045	0.618	0.631	0.926
OSS-120B-high	-0.967	0.967	0.750	0.503	0.728	0.754	0.972
OSS-20B-low	-0.634	0.634	-0.695	0.549	-0.359	-0.489	0.689
OSS-20B-medium	-0.668	0.668	0.447	0.336	0.424	0.331	0.247
OSS-20B-high	-0.352	0.352	0.537	0.994	0.831	0.628	0.932
DeepSeek-R1-70B	-0.866	0.866	0.879	0.889	0.858	0.905	0.902
Qwen3-30B-Thinking	-0.950	0.950	-0.803	-0.762	-0.801	0.745	0.911
Average	-0.594	0.594	0.527	0.219	0.571	0.605	0.683

负困惑度。困惑度定义为指数化的负平均对数概率：

$$\text{PPL}(S) = \exp\left(-\frac{1}{T} \sum_{t=1}^T \log p_{t,L}(y_t)\right) \quad (8)$$

我们报告了负困惑度 $-\text{PPL}(S)$ ，因此数值越大代表置信度越高。

N负熵。为了整合来自对 $\{v^*\}$ 的完整预测分布的信息，而不仅仅是t汉仅对采样到的标记，我们计算平均熵：

$$\text{Ent}(S) = \frac{1}{T} \sum_{t=1}^T H(p_{t,L}), \quad H(p_{t,L}) = - \sum_{v \in \mathcal{V}} p_{t,L}(v) \log p_{t,L}(v) \quad (9)$$

我们报告负熵 $-\text{Ent}(S)$ ，数值越大表示分布越尖锐，因而模型置信度越高。

自我确定性。我们还引入了自我确定性（Kang等人，2025），这是一种基于以下理念的分布置信度量：更高的置信度对应于更远离均匀分布 u 的预测分布，该分布代表最大不确定性。形式上，自我确定性被定义为 $u(v) = 1/|\mathcal{V}|$ 与 $p_{t,L}$ 之间的平均Kullback-Leibler（KL）散度：

$$\begin{aligned} \text{Self-Certainty}(S) &= \frac{1}{T} \sum_{t=1}^T \text{KL}(u \parallel p_{t,L}) \\ &= -\frac{1}{T|\mathcal{V}|} \sum_{t=1}^T \sum_{v \in \mathcal{V}} \log(|\mathcal{V}| p_{t,L}(v)) \end{aligned} \quad (10)$$

对于所有基线方法，相关性的计算均采用相同协议，即对序列进行排序 $\{v^*\}$ 并按标记计数（或其负值）或置信度分数进行分箱。

表1报告了八种模型变体和四个基准测试中任务准确性与不同测量指标之间的相关性。如观察所见，采用标记计数衡量的序列呈现出显著的橙色数值（ $r < 0$ ），均值 $r = -0.59$ 。这表明生成长度与较低性能更相关，与近期关于逆向缩放和过度思考的研究结果一致。延长的推理轨迹可能是冗余、误判或错误放大性思考的表现。这些结果凸显了将表层长度特征作为有效问题解决代理指标的不可靠性。反转标记计数后，得到了相同量级的正相关性。但这种改进纯属事后调整，仅反映了在短响应更准确的体系中存在的经验规律。因此，反向标记计数仅能作为统计调整手段，而非捕捉计算或思考投入的原则性概念。

与词符计数指标相比，基于置信度的测量（对数概率、负困惑度、负熵及自我确定性）与平均 $r = 0.219 \sim 0.605$ 呈现中等程度正相关，这一点从绿色数值占主导地位可以看出。这表明模型置信度捕捉了关于正确性的部分信息。然而，这些测量在不同模型和基准测试中的表现相对异质：某些配置实现了强正相关，而另一些则弱化甚至转为负相关。这种不一致性暗示，置信度信号可能混杂了过度自信等其他因素，因此不能可靠地反映推理时的计算投入或问题解决效能。

相比之下，我们提出的DTR测量方法展现出与任务绩效最强且最稳定的关联，平均相关性高达 $r = 0.683$ ，超越了基于置信度方法中表现最佳的反向标记计数和自确信基线。总体而言，DTR在所有模型和基准测试中均保持正值，呈现出最少的橙色标记值（在测试的32种模型-基准设置中仅占2例）。综合分析表明，相较于单纯依赖标记数量或基于置信度的替代方案，通过输出序列计算DTR能更忠实、更稳健地刻画成功推理的结果。

3.2. 沉降阈值与深度分数的影响

西我们进行分析以了解我们的两个关键超参数——稳定阈值 $\{v^*\}$ 和晚沉降深度分数 ρ 影响所测量的思维努力及其与任务的相关性。图4展示了在不同思考努力（即平均



(a) Effect of different settling threshold g .(b) Effect of different depth fraction ρ .

图4 | 超参数对思维努力测量与准确度曲线的影响。我们通过调整不同的稳定阈值 g 和深度分数 ρ 来分析超参数的影响。(a) 变化 g 对相关性影响更大；宽松的阈值 ($g = 0.25$) 产生更平缓的趋势，而 $g = 0.5$ 则提供最稳健的正向信号。(b) 变化 ρ 会改变思维努力得分的范围，但总体上保持一致的积极斜率。总体而言，更严格的标准（更高的 g ，更低的 ρ ）会缩小DTR的范围，其中 $(g, \rho) = (0.5, 0.85)$ 在稳定性和相关性之间提供了理想的平衡。

最终结算代币比率)，由 $g \in \{0.25, 0.5, 0.75\}$ 和 $\rho \in \{0.8, 0.85, 0.9, 0.95\}$ 推导得出。我们设定 ρ 当扫描 g 时，固定为0.85；当扫描 ρ 时， g 固定为0.5。我们在GPQA-D上报告结果。u使用GPT-OSS-20B，推理级别高。

我们得出以下观察结果：(1) 所测序列级思维努力的程度直接受这些参数严格性的影响。具体而言，图4a和图4b均表明，施加更严格的标准——更高的稳定阈值 g 或更低的深度比例 ρ ——会导致平均晚期稳定令牌比率的下降。这一现象在机制上是一致的：较高的 g 要求中间状态在分布上远离最终输出，直至在晚期阶段达到更深层才被视为稳定；而较低的 ρ 则将晚期阶段的定义限制在更窄的深层区间。这两种条件自然过滤掉了更多候选者，导致被归类为晚期稳定的令牌减少，进而使得整体思维努力得分的范围降低。

(2) 沉降阈值 g 对思考努力与准确性之间相关性的影响，比深度分数 ρ 更为显著。如图4b所示，改变 ρ 会因严格程度的不同而调整延迟沉降比例的范围，但在所有设置中均保持了一致的正斜率，这表明该指标对于后期层的具体定义相对稳健。相比之下，图4a显示 g 的选择对测量结果影响更大：采用较宽松的阈值 $g = 0.25$ 会导致趋势更为平缓且相关性降低，这意味着该阈值可能过于宽松，包含了计算努力较少的标记，从而削弱了测量区分高质量轨迹的能力。反之，阈值 $g = 0.5$ 和 $g = 0.75$ 则表现出更稳健的正相关性，准确反映了精度变化。

(3) 总体而言，我们可以看到，当标准过于严格时 ($g = 0.75$ 和 $\rho \in \{0.9, 0.95\}$)，尽管趋势仍保持正相关，但由于可能过滤掉信息量高的计算标记，显得略微不稳定。在测试的配置中， $(g, \rho) = (0.5, 0.85)$ 实现了理想的平衡，产生了具有高相关值的可靠趋势。

表2 | 不同聚合方法下四项推理基准的任务准确率与平均推理成本（千标记数）对比。报告的成本降低（ $\Delta\%$ ）以Cons@ n 为基准。Think@ n 在降低约50%推理成本的同时实现了最佳综合性能。采用 $\dagger$ 的方法通过设置50个前缀标记长度来实现早停机制。

Method	AIME 25		AIME 24		HMMT 25		GPQA-D	
	Acc	Cost ($\Delta\%$)	Acc	Cost ($\Delta\%$)	Acc	Cost ($\Delta\%$)	Acc	Cost ($\Delta\%$)
<i>OSS-120B-medium</i>								
Cons@ n	92.7	307.6 (-)	92.7	235.1 (-)	80.0	355.6 (-)	73.8	93.5 (-)
Mean@ n	80.0	307.6 (-)	81.6	235.1 (-)	62.6	355.6 (-)	69.9	93.5 (-)
Long@ n	86.7	307.6 (-)	86.7	235.1 (-)	73.3	355.6 (-)	73.2	93.5 (-)
Short@ n	87.3	255.7 (-17%)	88.0	200.9 (-15%)	77.3	290.4 (-18%)	73.3	84.4 (-10%)
Self-Certainty@ $n^\dagger$	87.3	150.6 (-51%)	91.3	119.3 (-49%)	78.0	177.0 (-50%)	76.0	47.9 (-49%)
Think@ $n^\dagger$	94.7	155.4 (-49%)	93.3	121.3 (-48%)	80.0	181.9 (-49%)	74.7	48.8 (-48%)
<i>Qwen3-4B-Thinking</i>								
Cons@ n	86.7	1073.1 (-)	93.3	950.1 (-)	63.3	1275.7 (-)	67.8	410.6 (-)
Mean@ n	81.2	1073.1 (-)	86.3	950.1 (-)	55.7	1275.7 (-)	66.9	410.6 (-)
Long@ n	85.3	1073.1 (-)	86.7	950.1 (-)	52.7	1275.7 (-)	66.7	410.6 (-)
Short@ n	90.0	983.6 (-8%)	90.0	871.0 (-8%)	63.3	1165.7 (-9%)	68.2	382.9 (-7%)
Self-Certainty@ $n^\dagger$	86.7	548.9 (-49%)	90.0	480.9 (-49%)	63.3	641.4 (-50%)	68.2	206.6 (-50%)
Think@ $n^\dagger$	90.0	537.5 (-50%)	93.3	482.2 (-49%)	66.7	641.4 (-50%)	69.7	206.8 (-50%)

4. 深度思考令牌实现高效测试时扩展

重复采样是一种流行的策略，用于扩展测试时的计算资源，与生成长链思维（CoT）并行（Brown等人，2024；Gupta和Srikumar，2025；Saad-Falcon等人，2024，2025；Stroebl等人，2024）。它通过聚合每个问题下多个独立生成的样本来提高准确性，代价是增加了推理预算。在本节中，我们将探讨是否可以利用我们提出的DTR度量 $\{v^*\}$ ，优先选择和聚合更高质量的样本，以实现更好的性能。

实验设置。我们遵循近期测试时间缩放研究中普遍采用的最佳 n 选1（BoN）评估协议（Fu等人，2025）。针对每个问题，我们使用相同的解码设置采样 n 个响应，并比较以下聚合方法：Cons@ n ：标准自一致性（Wang等人，2023），对所有 n 个采样响应进行多数投票；Mean@ n ：所有 n 个样本的平均准确率，反映无偏好聚合的基线；Long@ n 与Short@ n ：对按token数量排序（Agarwal等人，2025；Hassid等人，2025）的 n 个样本中最长/最短 η 百分比的样本进行多数投票；Self-Certainty@ n ：对按自确信分数（第3节中表现最佳的基线）排序的 n 个样本中得分最高 η 百分比的样本进行多数投票；Think@ n ：对按DTR($\cdot$)排序的 n 个样本中得分最高 η 百分比的样本进行多数投票。所有方法均基于相同的 n 个样本池运行。我们设定 $n = 48$ ， $\eta = 50\%$ 。更多分析详见C节。结果取10次试验的平均值。

结果。我们在表2中报告了结果。为了比较效率，我们明确考虑了Short@ n 、Self-Certainty@ n 和Think@ n 的早期停止机制，这些方法仅聚合部分样本。具体而言，我们报告了每个问题的平均推理成本，以生成的总令牌数为衡量指标，采用以下协议进行测量。

对于Cons@ n 和Mean@ n ，推理成本定义为所有标记数量的总和
 n 采样响应 = (即 $\sum_{i=1}^n |S_i|$) 对应于无早期停止的完全解码。对于
Short@ n ，我们按样本长度排序并选择最短的 $\eta \times n$ 个样本。推理成本为




图5 | 不同聚合方法下任务准确性与推理成本（tokens）之间的权衡比较。准确率为四个数据集（AIME 24/25、HMMT 25、GPQA-D）的平均值。我们的Think@ n 方法实现了最佳的帕累托最优性能，以约一半的推理成本达到或超越Cons@ n 的准确性，而Self-Certainty@ n 的效率明显较低。

表3 | 前缀长度(ℓ_{prefix})对AIME 2025中Think@ n 性能与推理成本的影响。使用50个tokens的短前缀估算DTR优于更长前缀方案，其效果与完整序列（全部）相当，同时显著节省成本。作为参考，我们还列出了Pass@1和Cons@ n 指标。下标表示10次试验的标准差。

	Accuracy	Cost (k tokens)
Pass@1	80.0 _{4.2}	6.4
Cons@ n	90.0 _{2.5}	307.6
Think@ n		
Prefix length		
50	94.7 _{1.6}	155.4
100	92.0 _{1.6}	154.1
500	92.7 _{1.3}	153.2
1000	92.7 _{1.3}	177.4
2000	92.0 _{1.3}	198.8
all	94.0 _{0.3}	307.6

计算方式为所选样本的令牌数总和，加上一个等于 $\ell_{\text{longest_short}} \times \eta \times n$ 的提前停止开销，其中 ℓ_{short} 表示所选最短子集中最长样本的长度。这一项用于说明部分生成的样本在子集生成完成时即终止（即受 $\ell_{\text{longest_short}}$ 限制）。Long@ n 的推理成本与Cons@ n 和Mean@ n 相同，因为它需要完整解码以选择最长样本。对于Think@ n ，样本通过DTR排序，该值由固定前缀计算得出。设 ℓ_{prefix} 表示用于估计DTR(S 的前缀令牌数: ℓ_{prefix})。推理成本定义为排名前 $\eta \times n$ 样本的总令牌数，加上一个固定前缀开销 $\ell_{\text{prefix}} \times \eta \times n$ ，这反映了在提前终止前生成所有候选样本的成本。Self-Certainty@ n 的成本计算方式与Think@ n 相同，唯一区别在于样本通过Self-Certainty($S[:\ell_{\text{prefix}}]$)而非DTR($S[:\ell_{\text{prefix}}]$)进行排序。

表3报告了对AIME 25进行的一项初步消融实验，该实验变动了 ℓ_{prefix} 。我们发现，仅使用 $\ell_{\text{prefix}} = 50$ 个标记就能比更长的前缀获得更高的准确率，并与使用完整序列所取得的性能相当，同时显著降低了推理成本。因此，在表2的所有实验中，我们将 $\ell_{\text{prefix}} = 50$ 固定为50。

如图所示，Cons@ n 由于需要对每个候选进行完全解码，产生了最高的推理成本，同时提供了强有力的准确度基准。Mean@ n 的成本与Cons@ n 相同，但在所有方法中表现最差。在早期停止机制下，Short@ n 相对于Cons@ n 实现了适度的成本节约，但在准确度上始终不及后者。与Short@ n 相比，Long@ n 表现出进一步下降的性能，且未带来任何成本节约的好处。这表明基于长度的启发式方法仍是推理质量的粗略代理，往往无法可靠地识别高质量样本，导致次优的聚合结果。Self-Certainty@ n 通过利用短前缀实现早期停止，大幅降低了推理成本，但在四个评估基准中的三个上，其表现仍不及Cons@ n 和Think@ n 。相比之下，Think@ n 在仅需约一半推理成本的情况下，始终匹配或超越Cons@ n 的准确度。帕累托最优性能在图5所示的平均结果中最为明显，其中Think@ n 实现了最佳的准确度-成本综合权衡。总之，这些结果表明DTR提供了更具信息量和可靠性的选择信号，能够高效并行扩展推理计算。

5. 相关工作

5.1. CoT长度与性能的关系

测试时扩展的范式主要基于一个论断运作：分配更多计算资源——通常表现为更长的思维链序列——能提升推理性能（Guo等人，2025；Muennighoff等人，2025；Wei等人，2022）。然而近期实证研究揭示了这一“越长越好”启发式法则普遍性的微妙之处（Feng等人，2025；Wu等人，2025）。Gema等人（2025）发现了逆向扩展机制，即增加推理长度会系统性降低跨多种任务的准确性，尤其在模型容易分心的情况下。类似地，Wu等人（2025）将思维链长度与准确性的关系描述为“倒U型”曲线，表明存在一个最佳长度，超过该长度后，由于错误累积等因素，性能会下降。

多篇研究提出了利用相应观察结果的方法，通过推崇简洁性来实现。Hassid等人（2025年）证明，在采样候选方案中最短的推理链往往最准确，提出了基于推理时长的投票机制以实现高效生成。Agarwal等人（2025年）的类似研究也提出了一种无需训练的并行解码策略，该策略选择首个完成的追踪路径，在保持准确性的同时减少标记使用。在训练方面，Shrivastava等人（2025年）提出了组过滤策略优化（GFPO），通过拒绝采样过滤较长响应来明确抑制强化学习中的长度膨胀，证明模型可以在不牺牲性能的情况下减少思考。我们的工作与这些观点一致，确认原始标记计数是衡量有效推理努力的不可靠指标，但我们的不同之处在于提出了机制性的内部信号，而非仅仅依赖表面层次的简洁启发式方法。

5.2. 利用LLM中的内部信息

已有大量研究探索了语言模型（LMs）内部如何在各层间表示和处理信息，以及如何利用其内部状态。这一方向的核心发现是：语言模型的中间表征在抵达最终层前往往已蕴含显著信号。Nostalgebraist（2020）最早通过使用模型的解嵌入矩阵将中间隐藏状态直接投射至词汇空间——这也是本研究采用的技术——为此观点提供了证据。结果表明，自回归变换器会形成关于下一个标记的粗略猜测，并通过各层迭代优化。后续分析（Belrose等人，2023年）进一步引入了可学习的、特定于层的仿射变换，以更好地对齐中间 $\{v^*\}$

r 表示与最终预测空间的关联，使得在 $\{v^*\}$ 中能够进行更具可解释性的标记预测
s较浅层。

除了模型探测，Chuang等人（2023）利用了一项实证发现：语言模型中的事实知识在特定层中往往更为显著。通过对比高层与低层的逻辑值，他们提出了一种解码方法，能够放大事实信号并提升事实性。Vilas等人（2025）的最新研究引入了潜在轨迹信号，这些信号通过隐藏状态在生成推理轨迹中的时间演变来预测正确性。该工作虽然考察了表征的序列维度，但我们的研究聚焦于单个令牌在各层间预测结果的深度演变。

互补可解释性研究也重新审视了大语言模型（LLM）在推理过程中如何利用深度。Gupta等人（2025）表明，早期层倾向于高频、通用的标记猜测，随后这些猜测会被细化为上下文适宜的预测。Csordás等人（2025）提出，后期层主要进行细粒度的分布优化，而非引入根本性的新转换，这对现代LLM中深度利用的效率提出了质疑。这些发现强化了一种观点，即内部预测可能在最终层之前就已稳定，这与我们的动机相吻合。总体而言，我们的目标不是修改或构建内部状态以开发旨在提升模型能力的新方法。相反，我们利用自然、未经修改的内部表征作为衡量模型计算努力的代理，这隐式反映了LLM中的思考努力。

6. 结论

我们引入了深度思考比率（DTR）作为衡量大语言模型推理时努力程度的新指标。通过追踪预测标记在深度上的稳定性，DTR提供了比表层代理（如标记长度或置信度）更有效的推理信号。基于此洞见，我们提出了Think@ n ——一种利用DTR进行早期选择与聚合的测试时扩展策略，其性能媲美甚至超越标准自一致性方法，同时大幅降低推理成本。综合结果表明，衡量模型内部如何思考（而非思考时长）是一个极具前景的方向。未来工作可借助这一思路探索高效推理的特征——将关注点从生成长思维链转向诱导更深层、计算密集度更高的推理过程，从而可能催生更可靠、高效的推理模型。

致谢

西我们感谢Google AIR的王从超及其同事提供的宝贵支持。同时，我们也感谢Y来自弗吉尼亚理工大学的u-Min Tseng以及弗吉尼亚大学Meng-Lab的成员们，感谢他们富有启发性的讨论。

参考文献

A. Agarwal, A. Sengupta 和 T. Chakraborty. 首次完成搜索：大型语言模型中的高效测试时间缩放。*arXiv preprint arXiv:2505.18149*, 2025年。

PAggarwal, S. Kim, J. Lanchantin, S. Welleck, J. Weston, I. Kulikov与S. Saha. 《OptimalThinking-Bench: 评估大语言模型中的过度思考与思考不足》。*arXiv*, 2025年。

Anthropic. Claude 3.7 十四行系统卡。<https://assets.anthropic.com/m/785e231869ea8b3b/original/claude-3-7-sonnet-system-card.pdf>, 2025a。

Anthropic. 系统卡片: Claude opus 4 & claude sonnet 4. <https://www-cdn.anthropic.com/6d8a8055020700718b0c49369f60816ba2a7c285.pdf>, 2025b.

解题的艺术。2024年美国数学邀请赛I。

https://artofproblemsolving.com/wiki/index.php/2024_AIME_I, 2024a。

解题艺术。2024年美国数学邀请赛II。

https://artofproblemsolving.com/wiki/index.php/2024_AIME_II, 2024b。

解题的艺术。2025年AIME I。 https://artofproblemsolving.com/wiki/index.php/2025_AIME_I, 2025a。 解题的艺术。2025年AIME II。

https://artofproblemsolving.com/wiki/index.php/2025_AIME_II, 2025b。 V. Balachandran、J. Chen、L. Chen、S. Garg、N. Joshi、Y. Lara、J. Langford、B. Nushi、V. Vineet、Y. Wu和S. Yousefi。 复杂任务的推理时间扩展: 现状与未来展望。 *arXiv*, 2025。 doi: 10.48550/arxiv.2504.00294。 M. Balunovi、J. Dekoninck、I. Petrov、N. Jovanovi 和 M. Vechev。 Matharena: 评估LLMs在无污染数学竞赛中的表现。 *arXiv preprint arXiv:2505.23281*, 2025。 N. Belrose、Z. Furman、L. Smith、D. Halawi、I. Ostrovsky、L. McKinney、S. Biderman和J. Steinhardt。 用调谐透镜从Transformer中引出潜在预测。 *arXiv preprint arXiv:2303.08112*, 2023。

B. Brown、J. Juravsky、R. Ehrlich、R. Clark、Q. V. Le、C. Ré 和 A. Mirhoseini。 《大型语言猴子: 通过重复采样扩展推理计算》。 *arXiv*, 2024年。 doi: 10.48550/arxiv.2407.21787。

Y.-S. Chuang、Y. Xie、H. Luo、Y. Kim、J. Glass和P. He。 DoLa: 通过对比层解码提升大语言模型的事实性。 *arXiv*, 2023。

R. Csordás、C. D. Manning 和 C. Potts。 语言模型是否有效利用了其深度? *arXiv*, 2025年。 doi: 10.48550/arxiv.2505.13898。 A. Y. Din、T. Karidi、L. Choshen 和 M. Geva。 跳跃式结论: 用线性变换缩短Transformer。 载于 *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, 第9615–9625页, 2024年。 M. Elbayad、J. Gu、E. Grave 和 M. Auli。 深度自适应Transformer。 *arXiv preprint arXiv:1910.10073*, 2019年。

Y. Feng、J. Kempe、C. Zhang、P. Jain, 与 A. Hartshorn。 有效推理的特征是什么? 重新审视思维链的长度、回顾与结构。 *arXiv*, 2025。

Y. Fu、X. Wang、Y. Tian, 和 J. Zhao。 深度思考与自信。 *arXiv preprint arXiv:2508.15260*, 2025年。 A. P. Gema、A. Hägele、R. Chen、A. Arditi、J. Goldman-Wetzler、K. Fraser-Taliente、H. Sleight、L. Petrini、J. Michael、B. Alex、P. Minervini、Y. Chen、J. Benton, 和 E. Perez。 测试时计算中的逆缩放。 *arXiv*, 2025年。 doi: 10.48550/arxiv.2507.14417。 D. Guo、D. Yang、H. Zhang、J. Song、R. Zhang、R. Xu、Q. Zhu、S. Ma、P. Wang、X. Bi, 等。 Deepseek-r1: 通过强化学习激励大语言模型的推理能力。 *arXiv preprint arXiv:2501.12948*, 2025年。

A. Gupta 和 V. Srikumar。通过重复采样进行测试时缩放改进多语言文本生成。arXiv, 2025年。doi: 10.48550/arxiv.2505.21941。

A. Gupta, J. Yeung, G. Anumanchipalli 与 A. Ivanova。大型语言模型如何利用其深度? {v*}, 2025年。
M. Hassid, G. Synnaeve, Y. Adi 及 R. Schwartz。勿过度思考: 倾向更短思维链以提升LLM推理能力{v*}, 2025年。

HMMT。Hmmt 2025。https://www.hmmt.org/, 2025年。

AJaech、A. Kalai、A. Lerer、A. Richardson、A. El-Kishky、A. Low、A. Helyar、A. Madry、A. Beutel、A. Carney等人。OpenAI O1系统卡。{v*}, 2024年。

Z康、X. 赵和D. 宋。基于自确定性的大语言模型可扩展最佳n选方法。arXiv, 2025年。doi: 10.48550/arxiv.2502.18581。

高文涛、吴泰宏、纪培恒、谢政杰和李汉阳。BERT的输出层能识别所有隐藏层? 一些引人入胜的现象及提升BERT的简单方法。arXiv preprint arXiv:2001.09309, 2020年。

N. Muennighoff、Z. Yang、W. Shi、X. L. Li、L. Fei-Fei、H. Hajishirzi、L. Zettlemoyer、P. Liang、E. Candès和T. B. Hashimoto。s1: 简单测试时间缩放。载于
Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing, 页码20286–20332, 2025年。

Nostalgebraist。解读gpt: logit透镜。https://www.lesswrong.com/posts/AcKRB8wDpdaN6v6ru/interpreting-gpt-the-logit-lens, 2020年。

OpenAI。OpenAI o3-mini 系统卡。https://openai.com/index/o3-mini-system-card/, 2025年。

OpenAI。推出gpt-5。https://openai.com/index/introducing-gpt-5/, 2025。

OpenAI、S. Agarwal、L. Ahmad、J. Ai、S. Altman、A. Applebaum、E. Arbus、R. K. Arora、Y. Bai、B. Baker、H. Bao、B. Barak、A. Bennett、T. Bertao、N. Brett、E. Brevdo、G. Brockman、S. Bubeck、C. Chang、K. Chen、M. Chen、E. Cheung、A. Clark、D. Cook、M. Dukhan、C. Dvorak、K. Fives、V. Fomenko、T. Garipov、K. Georgiev、M. Glaese、T. Gogineni、A. Goucher、L. Gross、K. G. Guzman、J. Hallman、J. Hehir、J. Heidecke、A. Helyar、H. Hu、R. Huet、J. Huh、S. Jain、Z. Johnson、C. Koch、I. Kofman、D. Kundel、J. Kwon、V. Kyrilov、E. Y. Le、G. Leclerc、J. P. Lennon、S. Lessans、M. Lezcano-Casado、Y. Li、Z. Li、J. Lin、J. Liss、Lily、Liu、J. Liu、K. Lu、C. Lu、Z. Martinovic、L. McCallum、J. McGrath、S. McKinney、A. McLaughlin、S. Mei、S. Mostovoy、T. Mu、G. Myles、A. Neitz、A. Nichol、J. Pachocki、A. Paino、D. Palmie、A. Pantuliano、G. Parascandolo、J. Park、L. Pathak、C. Paz、L. Peran、D. Pimenov、M. Pokrass、E. Proehl、H. Qiu、G. Raila、F. Raso、H. Ren、K. Richardson、D. Robinson、B. Rotsted、H. Salman、S. Sanjeev、M. Schwarzer、D. Sculley、H. Sikchi、K. Simon、K. Singhal、Y. Song、D. Stuckey、Z. Sun、P. Tillet、S. Toizer、F. Tsingou、N. Vyas、E. Wallace、X. Wang、M. Wang、O. Watkins、K. Weil、A. Wendling、K. Whinnery、C. Whitney、H. Wong、L. Yang、Y. Yang、M. Yasunaga、K. Ying、W. Zaremba、W. Zhan、C. Zhang、B. Zhang、E. Zhang与S. Zhao。gpt-oss-120b与gpt-oss-20b模型卡。{v*}, 2025。doi: 10.48550/arxiv.2508.10925。

D. Rein, B. L. Hou, A. C. Stickland, J. Petty, R. Y. Pang, J. Dirani, J. Michael, 和 S. R. Bowman。Gpqa: 一个研究生级别的防谷歌问答基准测试。收录于*First Conference on Language Modeling*, 2024年。

J. Saad-Falcon、A. G. Lafuente、S. Natarajan、N. Maru、H. Todorov、E. Guha、E. K. Buchanan、M. Chen、N. Guha、C. Ré 和 A. Mirhoseini。Archon: 一种面向推理时技术的架构搜索框架。{v*}, 2024。doi: 10.48550/arxiv.2409.15254。

J. Saad-Falcon, E. K. Buchanan, M. F. Chen, T.-H. Huang, B. McLaughlin, T. Bhathal, S. Zhu, B. Athiwaratkun, F. Sala, S. Linderman, A. Mirhoseini, 与 C. Ré。通过弱验证器缩小生成-验证差距。 *arXiv*, 2025。doi: 10.48550/arxiv.2506.18203。 T. Schuster, A. Fisch, J. Gupta, M. Dehghani, D. Bahri, V. Tran, Y. Tay, 与 D. Metzler。自信自适应语言建模。 *Advances in Neural Information Processing Systems*, 35:17456–17472, 2022。 V. Shrivastava, A. Awadallah, V. Balachandran, S. Garg, H. Behl, 与 D. Papailiopoulos。多采样以少思考：面向简洁推理的群体过滤策略优化。 *arXiv preprint arXiv:2508.09726*, 2025。

B. Stroebel, S. Kapoor 和 A. Narayanan。《推理缩放法则：不完美验证器下LLM重采样的局限》。 *arXiv*, 2024年。doi: 10.48550/arxiv.2411.17501。

J. Su, J. Healey, P. Nakov 和 C. Cardie。介于欠思考与过思考之间：关于LLMs推理长度与正确性的实证研究。 *arXiv*, 2025年。doi: 10.48550/arxiv.2505.00127。

Y. Sui, Y.-N. Chuang, G. Wang, J. Zhang, T. Zhang, J. Yuan, H. Liu, A. Wen, S. Zhong, H. Chen, 和 X. Hu。停止过度思考：大型语言模型高效推理综述。 *arXiv*, 2025。doi: 10.48550/arxiv.2503.16419。

K. Team, A. Du, B. Gao, B. Xing, C. Jiang, C. Chen, C. Li, C. Xiao, C. Du, C. Liao, 等。Kimi k1.5：利用大语言模型扩展强化学习。 *arXiv preprint arXiv:2501.12599*, 2025。

S. Teerapittayanon, B. McDanel 和 H.-T. Kung。《Branchynet：通过早期退出深度神经网络实现快速推理》。发表于 *2016 23rd international conference on pattern recognition (ICPR)*, 页码2464–2469。IEEE, 2016年。

M. G. 维拉斯、S. 优素菲、B. 努希、E. 霍维茨与V. 巴拉钱德兰。《追踪痕迹：潜在时间信号助力高效精准推理》。 *arXiv*, 2025年。

X. Wang, J. Wei, D. Schuurmans, Q. V. Le, E. H. Chi, S. Narang, A. Chowdhery, and D. Zhou。自洽性提升语言模型中的思维链推理。载于 *The Eleventh International Conference on Learning Representations*, 2023。网址<https://openreview.net/forum?id=1PL1NIMMrw>。

J. Wei, X. Wang, D. Schuurmans, M. Bosma, B. Ichter, F. Xia, E. Chi, Q. Le 和 D. Zhou。思维链提示激发大型语言模型中的推理能力。 *arXiv*, 2022年。doi: 10.48550/arxiv.2201.11903。

Y. Wu, Y. Wang, T. Du, S. Jegelka, 和 Y. Wang。多即是少：理解大语言模型中的思维链长度。 *arXiv*, 2025。

xAI。Grok 4。 <https://x.ai/news/grok-4>, 2025年。

A. 杨、A. 李、B. 杨、B. 张、B. 惠、B. 郑、B. 余、C. 高、C. 黄、C. 吕等。Qwen3技术报告。 *arXiv preprint arXiv:2505.09388*, 2025年。

E. Yeo, Y. Tong, M. Niu, G. Neubig, 与 X. Yue。《揭秘大语言模型中的长链推理机制》。 *arXiv*, 2025年。doi: 10.48550/arxiv.2502.03373。

T. Zhong, Z. Liu, Y. Pan, Y. Zhang, Y. Zhou, S. Liang, Z. Wu, Y. Lyu, P. Shu, X. Yu等。评估OpenAI O1：通用人工智能的机遇与挑战。 *arXiv preprint arXiv:2409.18486*, 2024年。

A. DTR不同距离度量的比较

我们的方法（第2节）采用Jensen-Shannon散度（JSD）来量化中间层与最终层预测之间的差异，并计算DTR。距离的其他定义也是可行的。在此我们探索了两种额外指标：Kullback-Leibler散度（KLD）和余弦相似度。结果展示于图6中。

Kullback-Leibler散度。将JSD替换为方程(2)中的KLD后，我们计算散度g最终层分布 $p_{t,L}$ 与中间层分布 $p_{t,l}$ 之间的差异为

$$D_{t,l}^{\text{KL}} = \text{KL}(p_{t,L} \parallel p_{t,l}) \quad (11)$$

余弦相似度。我们将第2.2节中定义的分布比较替换为使用余弦相似度的表示空间度量。不同于通过共享解嵌入矩阵 w_U （将中间层隐藏状态投影到词汇空间（公式(1)）），我们直接计算中间层隐藏状态 $h_{t,l}$ 与最终层隐藏状态 $h_{t,L}$ 之间的余弦相似度。该距离定义为

$$D_{t,l}^{\text{cos}} = 1 - \frac{\langle h_{t,l}, h_{t,L} \rangle}{\|h_{t,l}\| \|h_{t,L}\|} \quad (12)$$

对于KLD和余弦相似度，我们随后应用与第2.2节相同的配置来识别深度思考标记并计算基于KLD的DTR和基于余弦的DTR。

结果。我们报告了基于KLD和基于余弦的DTR与我们的主要基于JSD的DTR方法在AIME 25和HMMT 25数据集上使用OSS-120B-*medium*的相关性结果。在两个数据集中，基于JSD的DTR始终与准确率保持最强的正相关性（AIME 25上 $r = 0.869$ ；HMMT 25上 $r = 0.895$ ），这证明了我们在第2节中定义DTR时采用该方法的合理性。相比之下，基于余弦的DTR显示出明显较弱且不稳定的相关性（AIME 25上 $r = 0.633$ ，而HMMT 25上仅为 $r = 0.172$ ）。基于KLD的DTR同样表现出不一致的行为，在AIME 25上呈现负相关（ $r = -0.698$ ），而在HMMT 25上则为适度的正相关（ $r = 0.409$ ）。这种不一致性可能源于KLD的非对称性和数值不稳定性：早期层的预测往往是高熵且相对平坦的，会将概率质量分配给许多后续被驱近零值的标记。因此，KLD可能人为地变小，导致该度量极为敏感。

B. 不同GPT-OSS推理级别下的DTR

图7展示了GPT-OSS-120B模型在不同推理级别配置（即低、中、高）下DTR的变化情况。我们在AIME 25和GPQA-D数据集上观察到一个有趣且一致的趋势：尽管底层模型权重完全相同且仅系统提示存在差异，但较低推理级别的配置表现出更高的DTR值，而较高推理级别的配置则系统性地产生更小的DTR，同时实现更好的任务准确率。

一个可能的解释是，更高的推理层级可能会将计算从深度重新分配到序列长度上，实质上扁平化了每个词元的逐层计算。具备更高推理层级的模型对每个单独词元所需的深度修正更少，但会生成更长的推理链，伴随更多前向传递，从而带来更大的总有效计算量和提升的




图6 | 不同距离度量（余弦相似度、KL散度和JS散度）在AIME 25 (*top row*) 和HMMT 25 (*bottom row*) 上准确率与深思率 (DTR) 相关性的比较。

任务表现。由于DTR定义为深度思考标记所占比例（即平均于生成标记总数），较长的序列会增加DTR计算中的分母，从而产生较小的值。这也意味着DTR在不同模型或模型模式间可能无法直接比较。

C. Think@ n 的额外分析

H在此，我们进一步分析了Think@ $\{v^*\}$ 在不同采样数量 $\{v^*\}$ 下的表现。
r响应 n 和 (ii) 保留的前 η 百分比用于投票。

样本数量 n 的影响。图8a对比了Think@ n 与Cons@ n （即自一致性）随 n 增加（ $n \in \{16, 32, 48\}$ ）的表现。Think@ n 随着 n 增大而单调提升，其相对于Cons@ n 的优势愈发明显。采样更多响应会使正确答案簇规模扩大且出现概率增加。Think@ n 能够通过优先选择更优样本，利用这一扩大的候选池，从而获得比Cons@ n 更显著的性能提升。

E前 η 百分比的影响。图8a评估了Think@ n 在不同前 η 百分比（ $\eta \in \{25\%, 50\%, 75\%\}$ ）下的表现。性能在 $\eta=50\%$ 时达到峰值，而在比例较小（ $\eta=25\%$ ）时则有所下降




图7 {v*} 不同推理级别配置下OSS-120B的深度思考比率（DTR）米模型。




图8 | 不同样本数量 n 与top- η 百分比下Think@ n 的分析。(a) 随着 n 的增加，Think@ n 持续受益于更大的候选池，并在较高 n 时展现出与Cons@ n 逐渐拉大的性能差距。(b) 性能在 $\eta=50\%$ 时达到峰值，而过于激进的过滤或过度宽松的选择都可能导致准确率下降。

以及更大的比例 ($\eta=75\%$)。这表明了一种权衡：选择过少的样本会降低投票的稳健性，可能因缺乏足够多的强力候选者来稳定多数投票；而选择过多则可能引入质量较低的样本，从而稀释Think@ n 的益处。总体而言，结果支持我们将 $\eta=50\%$ 作为一个稳定的操作点。

D. 提示

西我们提供了在数学任务（AIME 2024、AIME 2025、HMMT）实验中采用的提示。2表4中的025）和表5中的GPQA。

表4 | 数学任务推理提示（AIME 2024、AIME 2025、HMMT 2025）。

AIME 2024、AIME 2025、HMMT 2025的提示
请逐步推理，并将最终答案放入\boxed{}中。

表5 | GPQA的推理提示。

GPQA的提示
你将获得一个包含不同选项的多选题，如(A)、(B)、(C)、(D)。在给出最终答案前，请逐步思考。始终以“最终答案是\boxed{(X)}。”结束你的回答，其中X为正确选项。若无一选项匹配，则选择最接近的选项作为最终答案。

E. 定性示例

我们展示一个来自AIME 2025数据集的示例问题及其标准答案（表6），以及OSS-120-medium的两个输出：一个错误（表7）和一个正确（表8）。值得注意的是，错误的输出明显更为冗长（27,724个标记）且DTR值较低（13.9），而正确的输出则简洁得多（3,725个标记）且DTR值更高（19.0）。

表6 | 来自AIME 2025的一个示例问题及其真实答案。

2025年AIME的示例问题。
以点A为中心、半径为6的圆 ω_1 与半径为15的圆 ω_2 在点B处内切。点C和D位于 ω_2 上，使得BC成为 ω_2 和BC $\perp$ $\overline{AD}$ 的直径。如图所示，矩形EFGH内接于 ω_1 ，其中EF $\perp$ $\overline{BC}$ 、C比GH更接近EF，且D比FG更接近EH。三角形 $\triangle DGF$ 和 $\triangle CHG$ 面积相等。矩形EFGH的面积为 $\frac{m}{n}$ ，其中m和n为互质的正整数。求 $m + n$ 。
真实答案。
293

表7 | OSS-120B-medium 对示例问题的错误输出。

DTR = 13.9% 和词元数 = 27,724 的输出不正确。

我们需要解读几何图形。设定：圆 ω_1 半径为6，圆心在A点，与半径为15的大圆 ω_2 在点B处内切。因此，B是 ω_1 与 ω_2 内切的共同点。由于是内切关系，距离AB=为15减6=等于9，且B点位于直线AB上。

我们来建立坐标系。将A点放在原点？或许更简单：设 ω_1 以(0,0)为中心，半径为6。那么B点位于圆 ω_1 上，同时也在 ω_2 上。由于 ω_2 半径更大为15，且以O为中心？假设O是 ω_2 的中心。OA的距离=为9（因为AB=为9），而AB=也是9？等等，AB=表示圆心之间的距离=为15-6=等于9，对。B点位于OA连线上，在外侧？实际上是内切：小圆在大圆内；它们在圆心连线上相接触，从小圆指向大圆外。因此，如果我们设A在(0,0)，O在(9,0)（即O在右侧），那么B点是两圆在AO连线上A点右侧的交点？即从A向O方向距离A6单位长度的点，也就是B在(6,0)。实际上O到B的距离：从O(9,0)到B(6,0)的距离是3，而半径是15？等等， ω_2 的半径是15，O到B应该是15。但O(9,0)到B(6,0)的距离是3，不是15。哪里出错了。

让我们将O设为(0,0)可能更简单。将 ω_2 以O(0,0)为中心，半径为15放置。 ω_1 半径为6，与 ω_2 在B点内切；其中心A距离O为15-6=9，沿某一方向。选择B作为切点，位于OA线上从A向外指向O？实际上是内切：小圆在大圆内，两圆在接触点B相遇。圆心连线通过B。O到B的距离为15（半径）。A到B的距离为6。由于O到A是9。B是否在OA线上超过A的位置？等等，O到A是9，小圆半径为6，所以从O到A再到B是同一直线方向：O—A—B？因为B在两圆的圆周上。O到B的距离=15=OA+AB？OA=9，AB=6得出OA+AB=15，所以B确实是从O通过A向外延伸。因此，O在原点，A在距离O为9的位置，例如正x方向。设O在(0,0)，A在(9,0)。那么B沿x轴更远处，O到B的距离为15，所以B在(15,0)。验证：A(9,0)到B(15,0)的距离=6，正确。很好。

现在BC是 ω_2 的直径，意味着从B到C穿过O（ ω_2 的中心）。由于B位于(15,0)，在 ω_2 上与之相对的点C位于(-15,0)（直径通过O）。因此，C位于(-15,0)。所以直线BC沿着x轴延伸。

给定BC $\perp$ AD，因此AD垂直于x轴，意味着AD是通过A的垂直线？等待AD线段连接A(9,0)到 ω_2 上的点D，使得AD垂直于BC，即通过A的垂直线（x=9）。由于AD必须与 ω_2 在点D相交。所以D是垂直线x=9与 ω_2 （半径15）的交点。方程 $x^2 + y^2 = 225$ 。代入x=9 $\Rightarrow 81 + y^2 = 225 \Rightarrow y^2 = 144 \Rightarrow y = \pm 12$ 。哪一个？由于方向可能D在上方？未明确。我们可能考虑D在(9,12)（上方）。也可能在下方，但矩形的方向可能选择其一。

现在矩形EFGH内接于以A(9,0)为中心、半径为6的圆内。该矩形不一定与坐标轴对齐？已知EF平行于GH，FG平行于EH。假设EF垂直于BC（BC为水平线），因此EF（及GH）为垂直线？等等，EF垂直于水平的BC，故EF为垂直。所以矩形的一边是垂直的。因此，在BC为水平线的坐标系中，矩形的边与垂直和水平方向对齐：EF垂直，FG水平等。即矩形是与坐标轴对齐的（垂直/水平）。因此，矩形的边平行于坐标轴（因为BC水平，EF垂直）。很好。

现在C离GH比离EF更近。GH位于EF的对侧：也许是一个具有垂直边EF（左）和GH（右）的矩形？我们来确定方向：通常矩形按顺序标记为E-F-G-H，可能是顺时针方向；但这并非关键。如果EF是垂直的，那么FG就是水平的，GH是垂直的，HE是水平的。因此EF在左侧，GH在右侧（如果矩形位于EF的右侧）。不确定。

C位于(-15,0)，在两者的最左侧。“C离GH比离EF更近”意味着C到直线GH的距离小于到直线EF的距离。由于C在最左边，这意味着GH在左侧，EF在右侧？等等，C到垂直线的距离是水平距离。如果GH在左侧（更靠左），它到C的距离比EF（右侧）的距离更小。这与C离GH更近的说法相符。因此，GH在矩形的左侧（更靠左），EF在右侧。很好。

同样地，D点距离FG比EH更近。由于FG是上边（水平），EH是下边（水平）。D点位于(9,12)的高处；到上边FG的距离小于到下边EH的距离（若矩形靠近顶部，则此情况合理）。因此，FG为上边，EH为下边。由此推测，矩形EFGH的摆放位置可能是上边靠近D点，左侧靠近C点。

... Omitted for illustrative purposes ...

似乎没有整数分解。可以用带无理系数的二次式分解，但无济于事。因此x可能是无理数；因此k不是整数或有理数。那么面积就是无理数？与题目陈述矛盾。由于时间已到，我想我之前的假设——矩形是轴对齐的——可能是错的；或许矩形旋转了，导致面积为有理数。鉴于复杂性，我认为答案可能是 $m+n$ = 类似207？猜一下？不太好。由于时间有限，我将输出占位符。assistantfinal 207



表8 | OSS-120B-medium 对示例问题的正确输出。

使用DTR = 19.0%和词元数 = 3,725的正确输出。

我们需要解析几何图形。先定义坐标系。有两个圆： ω_2 半径为15， ω_1 半径为6，圆心在A点，两圆在B点内切。因此A位于 ω_2 内部，距离AB为=半径差=15-6=9。切点B位于直线AB上。设定坐标系：让AB垂直？或许将B点放在原点更简便。将 ω_2 圆心设在O点（称为O2），或者直接称O？实际上 ω_2 的圆心是某点O（称为O）。 ω_1 的圆心A与O相距9，B点是两圆沿O-A直线的公共切点。设O在(0,0)，AB沿x轴正方向：B点可能在(15,0)？那么 ω_2 半径为15，圆心在O(0,0)。若B是 ω_1 与 ω_2 内切的切点，则B位于 ω_2 上，距O15单位。因此B在(15,0)。A位于OB线段内侧，距B6单位（因 ω_1 半径为6）。O到A距离为9（因OA=15-6=9）。故O(0,0)，B(15,0)，A在(9,0)（因O到A沿同直线距离9）。确认A在(9,0)。于是 ω_1 半径为6，圆心(9,0)。接下来，点C和D位于 ω_2 上，且BC为 ω_2 的直径。因此BC穿过圆心O，长度30（直径）。因B在(15,0)，直径另一端C满足O为中点：O=(0,0)是B与C的中点。故C=(-15,0)。确实，B(15,0)关于原点对称得C(-15,0)。因此BC为水平线（x轴）。完成。

... Omitted for illustrative purposes ...

三角形DGF： 其底边GF的长度为 w ；从顶点D(9, 12)到直线 $y = h/2$ （包含GF的直线）的垂直距离为 $12 - \frac{h}{2}$ 。因此

$$[DGF] = \frac{1}{2}w\left(12 - \frac{h}{2}\right).$$

三角形CHG：边HG为垂直边，长度为 h ；从C(-15, 0)到直线 $x = 9 - \frac{w}{2}$ （包含HG的直线）的水平距离为 $24 - \frac{w}{2}$ 。因此

$$[CHG] = \frac{1}{2}h\left(24 - \frac{w}{2}\right).$$

题目陈述为 $[DGF] = [CHG]$ 。约去因子 $\frac{1}{2}$ 后

$$w\left(12 - \frac{h}{2}\right) = h\left(24 - \frac{w}{2}\right).$$

项 $-\frac{wh}{2}$ 在两边同时出现并相互抵消，剩下

$$12w = 24h \implies w = 2h. \quad (2)$$

— 求解 w 和 h

将(2)代入(1)：

$$(2h)^2 + h^2 = 144 \implies 5h^2 = 144 \implies h^2 = \frac{144}{5}.$$

因此

$$h = \frac{12}{\sqrt{5}} = \frac{12\sqrt{5}}{5}, \quad w = 2h = \frac{24}{\sqrt{5}} = \frac{24\sqrt{5}}{5}.$$

矩形EFGH的面积为

$$\text{Area} = wh = 2h^2 = 2\left(\frac{144}{5}\right) = \frac{288}{5}.$$

因此 $m = 288$, $n = 5$ （互质），且

$$m + n = 288 + 5 = 293.$$